Biometria da Interação Genótipos × Ambientes (G×A)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

18 de março de 2026

Roteiro da aula 2: Modelo linear clássico, ANOVA conjunta e decomposição de variância em G×A

1 Introdução

Em ensaios multiambiente (*multi-environment trials*, MET), o desempenho fenotípico observado resulta da combinação entre efeitos de genótipos, efeitos de ambientes e da Interação Genótipos × Ambientes (G×A). A análise conjunta organiza essa variação em fontes interpretáveis e fornece estatísticas para tomada de decisão no melhoramento: comparação de médias, quantificação da heterogeneidade entre ambientes e estimação de componentes de variância.

Esta segunda aula formaliza o conceito de G×A no arcabouço da ANOVA conjunta clássica: parte-se do modelo linear que representa cada observação individual, identificam-se as fontes de variação e seus graus de liberdade, derivam-se as esperanças dos quadrados médios que orientam os testes F e os estimadores por método dos momentos, e conectam-se esses componentes às métricas práticas de herdabilidade e ganho de seleção. Ao final desta aula, o aluno deverá ser capaz de: (i) montar e interpretar a ANOVA conjunta de um MET balanceado em DBC; (ii) justificar os denominadores dos testes F a partir das expressões $E(QM)$; (iii) estimar σ^2_g, σ^2_{ga} e r_g por método dos momentos; e (iv) calcular e interpretar herdabilidade e eficiência de seleção no contexto multiambiente.

O foco desta aula é o modelo linear com ambientes fixos e a ANOVA conjunta em dados balanceados — incluindo a decomposição de variância via $E(QM)$, a decomposição da G×A em partes simples e complexa, a estratificação de ambientes por testes F par a par e as implicações dos componentes de variância sobre herdabilidade e ganhos de seleção. Os exemplos práticos desta aula utilizam o conjunto de dados `soy_MET.txt`, disponível no repositório da disciplina.

2 Modelo linear para G×A

2.1 Notação e modelo geral

Considere I genótipos ($i = 1, \ldots, I$), J ambientes ($j = 1, \ldots, J$) e K repetições por ambiente. Em delineamento em blocos casualizados (DBC) dentro de cada ambiente, o modelo é:

$$y_{ijk} = \mu + g_i + a_j + (ga)_{ij} + b_{k(j)} + \varepsilon_{ijk}, \tag{1}$$

em que μ é a média geral; g_i é o efeito do genótipo i; a_j é o efeito do ambiente j; $(ga)_{ij}$ é o efeito de G×A; $b_{k(j)}$ é o efeito do bloco k aninhado no ambiente j; e ε_{ijk} é o erro experimental.

Em palavras: cada observação y_{ijk} é a soma de um nível geral (μ), de um mérito genético médio do genótipo (g_i, estável entre ambientes), de uma produtividade média do local (a_j), de um desvio específico da combinação genótipo × ambiente ($(ga)_{ij}$, a G×A propriamente dita), de um efeito de bloco dentro do local e de um resíduo. A ANOVA conjunta decompõe SQ_{Total} nessas fontes, permitindo estimar e testar cada componente separadamente — o que é impossível com um único ensaio.

2.2 Análise em um único ambiente e a absorção da interação

Fixando o ambiente j, o modelo (1) reduz-se a:

$$y_{ik} = \mu_j + \underbrace{(g_i + (ga)_{ij})}_{\text{efeito do genótipo no ambiente } j} + b_k + \varepsilon_{ik}, \tag{2}$$

onde $\mu_j = \mu + a_j$. Em um único ambiente, a parte estável do desempenho (g_i) e a parte específica ($(ga)_{ij}$) são indistinguíveis. A decomposição exige pelo menos $J \geq 2$ ambientes com conectividade adequada entre genótipos.

A consequência para o melhoramento é direta: selecionar com base em um único ambiente equivale a selecionar sobre $g_i + (ga)_{ij}$, não sobre g_i. Genótipos que se destacam porque $(ga)_{ij}$ é favorável naquele local podem ser medíocres na rede — o que superestima o ganho real esperado fora daquele ambiente. A quantificação precisa desse fenômeno será feita pelas equações de ganho de seleção e resposta correlacionada da Seção 8.

2.3 Especificação dos efeitos: ambientes fixos e genótipos aleatórios

A escolha de quais efeitos são fixos ou aleatórios tem consequências diretas sobre os $E(QM)$ e os denominadores dos testes F. Nesta disciplina, adota-se o seguinte modelo (caso "**c**", pág. 112, de Cruz, Regazzi e Carneiro, 2012):

- **Ambientes (a_j): fixos** — os J ambientes da rede são os ambientes de interesse; a inferência é condicional a eles.
- **Genótipos (g_i), G×A ($(ga)_{ij}$), blocos ($b_{k(j)}$) e erro (ε_{ijk}): aleatórios** — genótipos são uma amostra de uma população maior; a G×A representa variação aleatória específica da combinação genótipo × ambiente.

A justificativa é pragmática: em programas de melhoramento, os J locais da rede são predefinidos para representar as principais condições de cultivo da região-alvo, e a inferência deve ser condicional a esses locais específicos. Tratar genótipos como aleatórios permite estimar componentes de variância interpretáveis na população sob seleção — o objetivo central da Seção 4.

Sob esse modelo:

$$\begin{aligned} g_i &\sim \mathcal{N}(0, \sigma_g^2), & (ga)_{ij} &\sim \mathcal{N}(0, \sigma_{ga}^2), \\ b_{k(j)} &\sim \mathcal{N}(0, \sigma_{b(a)}^2), & \varepsilon_{ijk} &\sim \mathcal{N}(0, \sigma^2), \end{aligned} \tag{3}$$

com independência entre componentes. Note que σ_a^2 **não** é um componente de variância nessa especificação: efeitos fixos não têm distribuição de probabilidade e não possuem variância no sentido dos componentes aleatórios. A heterogeneidade entre os J ambientes fixos é representada pelo parâmetro $\phi_a = \sum_j a_j^2/(J-1)$, que mede a dispersão das produtividades médias dos locais ao redor da média geral — análogo a um quadrado médio para efeitos fixos; $\phi_a = 0$ somente se todos os ambientes tiverem produtividade média idêntica. As consequências dessa escolha para os denominadores dos testes F são detalhadas na Seção 3.

3 ANOVA conjunta (DBC, ambientes fixos)

3.1 Particionamento de graus de liberdade

Com $N = IJK$ observações, o particionamento é:

$$\begin{aligned} GL_A &= J-1, & GL_{B(A)} &= J(K-1), \\ GL_G &= I-1, & GL_{G\times A} &= (I-1)(J-1), \\ GL_E &= J(I-1)(K-1), \end{aligned} \tag{4}$$

e a decomposição de somas de quadrados satisfaz:

$$SQ_{\text{Total}} = SQ_A + SQ_{B(A)} + SQ_G + SQ_{G\times A} + SQ_E. \tag{5}$$

A soma dos graus de liberdade totaliza $N - 1 = IJK - 1$, como se verifica algebricamente. Os blocos estão aninhados nos ambientes: cada um dos J locais contribui com $K-1$ graus de liberdade para blocos, daí $GL_{B(A)} = J(K-1)$ — e não simplesmente $K-1$ como em um delineamento individual.

3.2 Esperanças dos quadrados médios e testes F

Com ambientes fixos (caso "**c**" de Cruz et al., 2012), definindo $\ell = J/(J-1)$:

$$\begin{aligned} E(QM_E) &= \sigma^2, \\ E(QM_{G\times A}) &= \sigma^2 + K\ell\,\sigma^2_{ga}, \\ E(QM_G) &= \sigma^2 + JK\,\sigma^2_g, \\ E(QM_{B(A)}) &= \sigma^2 + I\,\sigma^2_{b(a)}, \\ E(QM_A) &= \sigma^2 + K\ell\,\sigma^2_{ga} + I\,\sigma^2_{b(a)} + IK\,\phi_a. \end{aligned} \tag{6}$$

Dois resultados merecem atenção especial, pois diferem do modelo com todos os efeitos aleatórios:

1. **Por que $E(QM_G)$ não contém σ^2_{ga}?** Quando os ambientes são fixos, a teoria dos modelos lineares impõe a restrição $\sum_j (ga)_{ij} = 0$ para cada genótipo i: a interação é, por definição, um desvio em torno dos efeitos principais fixos e não tem componente médio ao longo dos J locais. Como consequência, a variabilidade entre médias de genótipos $\bar{y}_{i..}$ reflete exclusivamente σ^2_g — a adaptação ampla, consistente ao longo da rede. O denominador correto para F_G é, portanto, QM_E. Usar $QM_{G\times A}$ como denominador inflacionaria o denominador (pois $E(QM_{G\times A}) > \sigma^2$ quando $\sigma^2_{ga} > 0$) e tornaria o teste conservador, reduzindo o poder de detectar variação genética real — um erro que não ocorreria no modelo com todos os efeitos aleatórios, onde $E(QM_G)$ contém σ^2_{ga} e o denominador correto de F_G seria $QM_{G\times A}$.

2. **Por que o coeficiente de σ^2_{ga} em $E(QM_{G\times A})$ é $K\ell = KJ/(J-1)$ e não simplesmente K?** A mesma restrição $\sum_j (ga)_{ij} = 0$ reduz o número de parâmetros de interação livres de IJ para $I(J-1)$. Ao igualar somas de quadrados às suas esperanças, esse grau de restrição inflaciona o coeficiente de σ^2_{ga} pelo fator $J/(J-1) > 1$. Esse fator precisa ser incorporado ao estimador de σ^2_{ga} (Seção 4), e seu não cumprimento superestimaria a interação em experimentos com ambientes fixos.

Fonte	**GL**	$E(QM)$	**Teste** F
Ambientes (A)	$J-1$	$\sigma^2 + K\ell\sigma^2_{ga} + I\sigma^2_{b(a)} + IK\phi_a$	$F_A = QM_A/QM_{B(A)}$
Blocos dentro de A	$J(K-1)$	$\sigma^2 + I\sigma^2_{b(a)}$	—
Genótipos (G)	$I-1$	$\sigma^2 + JK\sigma^2_g$	$F_G = QM_G/QM_E$
G×A	$(I-1)(J-1)$	$\sigma^2 + K\ell\sigma^2_{ga}$	$F_{G\times A} = QM_{G\times A}/QM_E$
Erro	$J(I-1)(K-1)$	σ^2	—

Tabela 1: $E(QM)$ e testes F para ANOVA conjunta balanceada (DBC) com ambientes fixos, genótipos e G×A aleatórios (caso "**c**" de Cruz, Regazzi e Carneiro, 2012). $\ell = J/(J-1)$.

Biologicamente: $F_{G\times A}$ significativo indica que o ranking dos genótipos muda entre ambientes além do esperado por acaso — os genótipos não respondem de forma proporcional às diferenças ambientais. F_G significativo, mesmo quando $F_{G\times A}$ é significativo, indica que existe variação genética consistente explorável por seleção para ampla adaptação. Um $F_{G\times A}$ não significativo simplificaria consideravelmente o problema: a análise em qualquer ambiente único bastaria para ranquear os genótipos na rede.

Nota sobre F_A: O teste $F_A = QM_A/QM_{B(A)}$ é formalmente válido para testar $H_0 : \phi_a = 0$ somente quando $\sigma^2_{ga} = 0$. Quando $\sigma^2_{ga} > 0$, o numerador $E(QM_A)$ excede $E(QM_{B(A)})$ mesmo sob $H_0 : \phi_a = 0$, tornando o teste anti-conservador para o efeito de ambientes. Na prática, isso raramente importa: diferenças de produtividade média entre locais são quase sempre evidentes em redes de melhoramento, e F_A significativo é o resultado esperado — não o foco da análise.

Os testes F da ANOVA revelam a existência e a magnitude relativa de cada fonte de variação; os estimadores da próxima seção traduzem esses resultados em componentes de variância interpretáveis no melhoramento.

3.3 Tabela de médias e gráfico de interação

Antes de qualquer decomposição formal, calcule a tabela de médias $\bar{y}_{ij.}$ e construa o *interaction plot*: médias dos genótipos no eixo y, ambientes no eixo x, uma linha por genótipo. Esse gráfico é o primeiro diagnóstico visual da G×A:

- Linhas aproximadamente paralelas → interação simples (mudança de magnitude, ranking preservado).
- Cruzamento de linhas → interação complexa (*crossover*), com troca de ranking entre ambientes.

Padrões com muitos cruzamentos já antecipam que a parte complexa $C_{jj'}$ da decomposição de Robertson–Cruz & Castoldi (Seção 5) será dominante, e que recomendações regionalizadas precisam ser consideradas.

4 Estimadores dos componentes de variância (A fixo)

4.1 Método dos momentos

Igualando os QM observados às expressões de $E(QM)$ em (6):

$$\widehat{\sigma}^2 = QM_E, \tag{7}$$

$$\widehat{\sigma}^2_{ga} = \frac{(QM_{G\times A} - QM_E)(J-1)}{KJ}, \tag{8}$$

$$\widehat{\sigma}^2_{g} = \frac{QM_G - QM_E}{JK}, \tag{9}$$

$$\widehat{\sigma}^2_{b(a)} = \frac{QM_{B(A)} - QM_E}{I}. \tag{10}$$

O fator $(J-1)/J$ em (8) — em relação ao modelo com todos os efeitos aleatórios, onde o estimador seria $(QM_{G\times A} - QM_E)/K$ — é a consequência direta da restrição $\sum_j (ga)_{ij} = 0$ imposta pelos ambientes fixos: parte da variação de G×A é absorvida pelos efeitos fixos de ambiente e não se manifesta como variância aleatória. Usar o estimador do modelo totalmente aleatório neste contexto *superestimaria* σ^2_{ga} pelo fator $J/(J-1)$. O estimador (9) usa $QM_G - QM_E$ no numerador — e não $QM_G - QM_{G\times A}$ como no modelo totalmente aleatório — pois $E(QM_G)$ não contém σ^2_{ga} quando os ambientes são fixos.

Estimativas negativas ocorrem quando $QM_{G\times A} < QM_E$ ou $QM_G < QM_E$, o que pode acontecer por flutuação amostral mesmo quando os parâmetros verdadeiros são não negativos. A convenção prática adotada nesta disciplina é truncar em zero: $\widehat{\sigma}^2_{ga} = \max(0, \ldots)$. O tratamento formal desse problema — incluindo intervalos de confiança e estimadores que evitam valores inadmissíveis por construção — é feito via REML na Aula 6.

4.2 Proporções relativas

A variância fenotípica total de uma observação individual é:

$$\sigma^2_P = \sigma^2_g + \sigma^2_{ga} + \sigma^2_{b(a)} + \sigma^2. \tag{11}$$

As proporções $\widehat{\sigma}^2_g/\widehat{\sigma}^2_P$, $\widehat{\sigma}^2_{ga}/\widehat{\sigma}^2_P$ e $\widehat{\sigma}^2/\widehat{\sigma}^2_P$ informam, respectivamente, o quanto da variação total é atribuível a diferenças genéticas consistentes, à interação específica por ambiente e ao erro experimental. Uma proporção $\widehat{\sigma}^2_{ga}/\widehat{\sigma}^2_P$ elevada (tipicamente $> 50\%$) sinaliza que a maior parte da variação fenotípica é específica por ambiente: cultivares distintas tendem a "vencer" em locais distintos, e uma recomendação única para toda a rede seria ineficiente. Quando $\widehat{\sigma}^2_g/\widehat{\sigma}^2_P$ domina, há base sólida para recomendar cultivares de ampla adaptação. Essas proporções e sua relação com herdabilidade e ganho de seleção são retomadas na Seção 8.

5 Decomposição da G×A em partes simples e complexa

5.1 Partição de Robertson (1959) e Cruz & Castoldi (1991)

Para cada par de ambientes (j, j'), o quadrado médio da interação pode ser decomposto em uma parte simples (S) e uma parte complexa (C):

$$QMG\times A_{jj'} = S_{jj'} + C_{jj'}, \tag{12}$$

com:

$$S_{jj'} = \frac{1}{2}(\sqrt{Q_j} - \sqrt{Q_{j'}})^2, \tag{13}$$

$$C_{jj'} = \sqrt{(1 - r_{jj'})^3\, Q_j\, Q_{j'}}, \tag{14}$$

onde Q_j é o quadrado médio entre genótipos no ambiente j (ANOVA individual), $Q_{j'}$ é o quadrado médio no ambiente j', e $r_{jj'}$ é o coeficiente de correlação de Pearson entre as médias dos genótipos nos ambientes j e j'. A expressão (14) foi proposta por Cruz e Castoldi (1991) como aprimoramento da formulação original de Robertson (1959), $C_{\text{Rob}} = (1 - r_{jj'})\sqrt{Q_j Q_{j'}}$, por ponderar de forma mais eficiente a contribuição conjunta da correlação e da diferença de variabilidade genotípica entre os dois ambientes.

Atenção sobre a natureza da partição: Na formulação de Robertson (1959), $S_{jj'} + C_{\text{Rob}} = QMG \times A_{jj'}$ de forma exata — trata-se de uma partição aditiva estrita, derivável algebricamente a partir das somas de quadrados. Na formulação de Cruz e Castoldi (1991), $S_{jj'} + C_{jj'} \neq QMG \times A_{jj'}$ em geral: $C_{jj'}$ é um *índice* de complexidade, não um complemento aditivo. Em consequência, $\%C_{jj'}$ deve ser calculado como proporção de $QMG \times A_{jj'}$ obtido diretamente da ANOVA, e não como $100 \cdot C_{jj'}/(S_{jj'} + C_{jj'})$.

Interpretação:

- $S_{jj'}$ reflete diferença de *magnitude*: genótipos respondem de forma mais ou menos intensa nos dois ambientes, mas o ranking é preservado. Quanto maior a diferença $\sqrt{Q_j} - \sqrt{Q_{j'}}$, mais um ambiente é discriminante que o outro.
- $C_{jj'}$ reflete *mudança de ranking*: quanto mais negativo $r_{jj'}$, maior a parte complexa e maior o risco de recomendações opostas nos dois ambientes.
- $\%C_{jj'} = 100 \cdot C_{jj'}/QMG \times A_{jj'}$: proporção da interação de natureza complexa. Valores acima de 100% ocorrem quando $r_{jj'} < 0$. Na prática do melhoramento, $\%C > 50\%$ já é sinal de alerta para recomendação regionalizada; $\%C > 80\%$ indica que o par de ambientes tende a selecionar cultivares distintas, tornando indefensável uma recomendação única.

5.2 Cálculo do $QMG \times A$ par a par e de Q_j

O quadrado médio entre genótipos no ambiente j, a partir da ANOVA individual, é:

$$Q_j = \frac{SQ_{G(j)}}{I-1}, \qquad SQ_{G(j)} = \frac{1}{K}\sum_i \bar{y}_{ij.}^2 - \frac{T_{.j.}^2}{IK}, \tag{15}$$

onde $T_{.j.} = \sum_i \sum_k y_{ijk}$. A soma de quadrados da interação entre genótipos e o par (j, j') é:

$$\theta_{jj'} = \frac{1}{2}\left[\sum_i (\bar{y}_{ij.} - \bar{y}_{ij'.})^2 - \frac{(T_{.j.} - T_{.j'.})^2}{I}\right], \tag{16}$$

de modo que $QMG \times A_{jj'} = \theta_{jj'}/(I-1)$. Os valores Q_j e $r_{jj'}$ obtidos aqui entram diretamente nas fórmulas (13)–(14); o mesmo $r_{jj'}$ é o coeficiente utilizado no teste F par a par (Seção 6) e na análise de correlações genéticas (Seção 7).

6 Estratificação de ambientes via testes F par a par

Com a decomposição (16), testa-se para cada par (j, j') se a G×A entre esses dois ambientes é significativa:

$$F_{jj'} = \frac{\theta_{jj'}/(I-1)}{QM_E/K}, \tag{17}$$

com $(I-1)$ e $J(I-1)(K-1)$ graus de liberdade. O denominador QM_E/K é adequado porque $\theta_{jj'}$ é construído sobre médias $\bar{y}_{ij.}$ (médias de K repetições), cuja variância experimental é $\approx \sigma^2/K$; usa-se o QM_E da ANOVA conjunta — e não o erro individual de cada ambiente — para aproveitar os $J(I-1)(K-1)$ graus de liberdade disponíveis e obter um denominador mais estável.

Pares com $F_{jj'}$ não significativo indicam que os dois ambientes discriminam genótipos de forma similar e são candidatos a compor um mesmo grupo de recomendação: os genótipos superiores em j seriam também os superiores em j', não havendo ganho em avaliá-los separadamente. Pares com $F_{jj'}$ significativo e $\%C_{jj'}$ elevado indicam o oposto: a seleção em j pode levar a escolhas ineficientes ou até equivocadas para j'. Esse conjunto de testes par a par fundamenta o algoritmo de estratificação ambiental de Cruz et al. (2012), desenvolvido em detalhe na Aula 12.

7 Correlações genéticas entre ambientes

7.1 Correlação genética homogênea

Para o genótipo i no ambiente j, defina $u_{ij} = g_i + (ga)_{ij}$. Sob o modelo (3):

$$\begin{aligned} \mathrm{Var}(u_{ij}) &= \sigma_g^2 + \sigma_{ga}^2, \\ \mathrm{Cov}(u_{ij},\, u_{ij'}) &= \sigma_g^2 \quad (j \neq j'). \end{aligned} \tag{18}$$

A covariância entre ambientes é σ_g^2 porque os termos $(ga)_{ij}$ e $(ga)_{ij'}$ são independentes por suposição do modelo: o único elo entre o desempenho de um genótipo em j e em j' é a parte estável g_i. A correlação genética homogênea entre qualquer par de ambientes é então:

$$r_g = \frac{\sigma_g^2}{\sigma_g^2 + \sigma_{ga}^2}, \tag{19}$$

estimada por $\widehat{r}_g = \widehat{\sigma}_g^2/(\widehat{\sigma}_g^2 + \widehat{\sigma}_{ga}^2)$ com os estimadores de (8)–(9). Note que r_g é a correlação intraclasse do desempenho genotípico entre quaisquer dois ambientes sob este modelo — um resumo da estrutura de dependência, assumida homogênea (igual para todos os pares).

Quando $r_g \to 1$ ($\sigma_{ga}^2 \ll \sigma_g^2$), o ranking tende a ser preservado entre ambientes; quando $r_g \to 0$ ($\sigma_{ga}^2 \gg \sigma_g^2$): recomendação regionalizada! Na prática do melhoramento de plantas, valores de $r_g < 0{,}5$ costumam indicar que a rede deve ser dividida em zonas de recomendação distintas; $r_g > 0{,}8$ sugere que uma recomendação única para toda a rede é defensável. Esses limiares não são absolutos, mas balizam a interpretação dos resultados da Atividade.

7.2 Correlações par a par observadas

A correlação homogênea (19) resume a estrutura *média* de dependência entre ambientes, mas pode mascarar heterogeneidade importante. Uma abordagem complementar é calcular, para cada par (j, j'), a correlação de Pearson entre as médias dos genótipos:

$$r_{jj'} = \frac{\sum_i (\bar{y}_{ij.} - \bar{y}_{j..})(\bar{y}_{ij'.} - \bar{y}_{j'..})}{\sqrt{\sum_i (\bar{y}_{ij.} - \bar{y}_{j..})^2 \sum_i (\bar{y}_{ij'.} - \bar{y}_{j'..})^2}}. \tag{20}$$

Organizar os $r_{jj'}$ em uma matriz $J \times J$ permite identificar quais pares de ambientes são mais (ou menos) concordantes quanto ao ranking de genótipos. Note que $r_{jj'}$ é o mesmo coeficiente que entra na decomposição $S + C$ da Seção 5: quanto menor $r_{jj'}$, maior a parte complexa $C_{jj'}$ e maior o risco de recomendações conflitantes entre esses dois locais. Dois ambientes com $r_{jj'} \approx 0$ ou negativo podem coexistir em uma rede com $\widehat{r}_g$ moderado — um par problemático que a correlação global mascararia.

8 Herdabilidade e implicações nos ganhos de seleção

8.1 Herdabilidade no contexto multiambiente

A herdabilidade no sentido amplo para a média de genótipos avaliados em J ambientes e K blocos é:

$$h^2_{\mathsf{MET}} = \frac{\sigma_g^2}{\sigma_g^2 + \dfrac{\sigma_{ga}^2}{J} + \dfrac{\sigma^2}{JK}}, \tag{21}$$

pois $\mathrm{Var}(\bar{y}_{i..}) = \sigma_g^2 + \sigma_{ga}^2/J + \sigma^2/(JK)$. Para a média em um único ambiente j (sobre K blocos):

$$h_j^2 = \frac{\sigma_g^2 + \sigma_{ga}^2}{\sigma_g^2 + \sigma_{ga}^2 + \sigma^2/K}. \tag{22}$$

A diferença entre (21) e (22) é biologicamente fundamental: h_j^2 usa $\sigma_g^2 + \sigma_{ga}^2$ no numerador porque, em um único ambiente, a parte estável e a parte específica do valor genético são indistinguíveis (equação (2)) — ambas constituem variação herdável *naquele local*. Já h_{MET}^2 usa apenas σ_g^2 no numerador porque a seleção pela média da rede visa identificar genótipos superiores *em qualquer ambiente*: a componente σ_{ga}^2 tende a se cancelar ao longo dos J locais, não contribuindo para o numerador. As duas grandezas medem coisas distintas: h_j^2 mede a confiabilidade para classificar genótipos naquele ambiente; h_{MET}^2 mede a confiabilidade para identificar genótipos de ampla adaptação.

A relação entre h_j^2 e h_{MET}^2 não é fixa: quando J é grande, $\sigma_{ga}^2/J \to 0$ e $\sigma^2/(JK) \to 0$, de modo que $h_{\mathsf{MET}}^2 \to 1$ independentemente de σ_{ga}^2; para J pequeno e σ_{ga}^2 grande, é comum que $h_j^2 > h_{\mathsf{MET}}^2$. Note que $h_j^2 > h_{\mathsf{MET}}^2$ não necessariamente implica que selecionar em j seja mais eficiente do que selecionar na rede completa: a vantagem de usar J ambientes está em reduzir σ_{ga}^2/J no denominador, melhorando a discriminação da adaptação ampla. O efeito de blocos ($\sigma_{b(a)}^2$) foi omitido dos denominadores — convenção padrão que assume médias ajustadas pelo controle local do DBC.

8.2 Ganho de seleção direto

O ganho esperado com seleção baseada na média de genótipos em J ambientes é:

$$\Delta G_{\mathsf{MET}} = i\, h_{\mathsf{MET}}\, \sigma_g, \tag{23}$$

onde i é a intensidade de seleção e $h_{\mathsf{MET}} = \sqrt{h_{\mathsf{MET}}^2}$. Para seleção em um único ambiente j:

$$\Delta G_j = i\, h_j\, \sigma_{g(j)}, \qquad \sigma_{g(j)} = \sqrt{\sigma_g^2 + \sigma_{ga}^2}. \tag{24}$$

Em ΔG_j, o desvio-padrão genotípico efetivo no ambiente j é $\sigma_{g(j)} = \sqrt{\sigma_g^2 + \sigma_{ga}^2}$, pois no ambiente j o melhorista seleciona sobre a soma $g_i + (ga)_{ij}$. O ganho ΔG_j é esperado para *aquele ambiente específico*; o quanto desse ganho se transfere para outros locais depende de r_g e é capturado pela resposta correlacionada a seguir.

8.3 Resposta correlacionada entre ambientes

Selecionando em j com o objetivo de melhorar o desempenho em j':

$$RC(j' \mid j) = i\, r_g\, h_j\, \sigma_{g(j')}, \tag{25}$$

onde r_g é a correlação genética de (19). A eficiência relativa da seleção indireta em comparação à seleção direta em j' é:

$$\mathsf{ER}(j \to j') = \frac{RC(j' \mid j)}{\Delta G_{j'}} = r_g\, \frac{h_j}{h_{j'}}. \tag{26}$$

A equação (26) tem implicação direta para o delineamento de redes de ensaios: quando r_g é baixo, selecionar em um único ambiente é uma estratégia ineficiente para ganhos em outros ambientes, justificando o uso de redes multiambiente. Além disso, a razão $h_j/h_{j'}$ indica se o ambiente j é mais preciso (maior h_j) do que j' para discriminar genótipos. Quando ER > 1, a seleção indireta via j é mais eficiente do que a seleção direta em j', mesmo que $r_g < 1$.

9 Limitações sob desbalanceamento

As expressões (6)–(10) dependem de balanceamento e ortogonalidade. Em desbalanceamento: (i) os QM deixam de ter $E(QM)$ únicos e simples; (ii) testes F ficam sensíveis à escolha do denominador; (iii) estimadores por método dos momentos podem perder interpretação e estabilidade numérica. Imbalanceamentos leves — como parcelas perdidas isoladas — geralmente não comprometem a análise, mas imbalanceamentos moderados ou estruturais (número de blocos diferente por ambiente, conjuntos de genótipos não-conectados entre locais) exigem abordagem diferente.

Sob desbalanceamento, a ortogonalidade é perdida e as somas de quadrados passam a depender da ordem de ajuste dos efeitos no modelo. No Tipo I (sequencial), $SQ_{G\times A}$ é calculada após ajustar G e A, mas os valores mudam se a ordem for alterada; no Tipo III (marginal), cada efeito é ajustado para todos os demais simultaneamente, o que é conceitualmente mais adequado para testar $G \times A$ na presença de efeitos principais desiguais. Na prática do melhoramento, desbalanceamentos moderados a severos tornam os testes F por qualquer tipo de SS instáveis e difíceis de interpretar — e a solução não é escolher o "melhor tipo", mas abandonar o arcabouço de somas de quadrados e migrar para verossimilhança restrita (REML), que estima os componentes de variância sem depender de ortogonalidade. Esse é o ponto de entrada da Aula 6, que também tratará formalmente o problema das estimativas negativas de componentes de variância, abordado nesta aula apenas pela convenção de truncamento em zero.

10 Atividade

Utilize os resultados obtidos com o script da aula (`soy_MET.txt`: 40 genótipos, 6 ambientes, DBC, $n = 720$). Não é necessário rodar código adicional — todos os valores estão no output do script (`https://github.com/rtresende/Biometria-da-Interacao-GxA/aula2`). Os entregáveis devem ser respondidos de forma objetiva.

Entregáveis:

1. **Testes F e denominadores.** No output da ANOVA conjunta, os testes F para Genótipos e para G×A usaram o mesmo denominador (QM_E). Explique, a partir das expressões de $E(QM)$ da Tabela 1, por que isso é correto sob o modelo com ambientes fixos — e por que seria *incorreto* usar $QM_{G\times A}$ como denominador de F_G nesse caso.

2. **Componentes de variância e efeito do modelo.** Apresente $\widehat{\sigma}^2_g$, $\widehat{\sigma}^2_{ga}$, $\widehat{\sigma}^2_{b(a)}$ e $\widehat{\sigma}^2$ com suas proporções relativas. O script imprime diretamente a comparação $\widehat{\sigma}^2_{ga}$ sob ambientes fixos vs. totalmente aleatório. Explique em 3 a 4 linhas por que os dois valores diferem e qual deles é o correto para este experimento.

3. **Decomposição simples e complexa.** Com base nas matrizes $\%C$ obtidas em aula, selecione e discuta três pares de ambientes: o par com maior $r_{jj'}$, o par com menor $r_{jj'}$ e um par intermediário. Para cada um, reporte $r_{jj'}$, S, C e $\%C$, e classifique a natureza predominante da interação. Considerando que todos os $\%C$ obtidos nessa rede foram elevados (acima de 80%), o que isso implica para a recomendação de cultivares no Cerrado?

4. **Herdabilidade, eficiência de seleção e implicações práticas.** Com base em $\widehat{h}^2_{\text{MET}}$, $\widehat{h}^2_j$ e $\widehat{r}_g$ obtidos em aula: (a) explique por que $\widehat{h}^2_{\text{MET}} \approx \widehat{h}^2_j$ nesse conjunto de dados, deixando claro que as duas expressões *não* são equivalentes em geral; (b) calcule ER$(j \to j')$ para o par com menor $r_{jj'}$ e interprete o valor; (c) escreva um parágrafo (4 a 6 linhas) discutindo se seria racional concentrar todos os esforços de seleção em um único ambiente nessa rede, à luz dos valores de $\widehat{r}_g$, $\%C$ e ER obtidos.

Referencial teórico

Cruz, C. D., Regazzi, A. J., & Carneiro, P. C. S. (2012). *Modelos biométricos aplicados ao melhoramento genético*, Vol. 1 (4. ed.). Editora UFV.

Cruz, C. D., & Castoldi, F. L. (1991). Decomposição da interação genótipos × ambientes em partes simples e complexa. *Ceres*, 38(219), 422–430.

Gomez, K. A., & Gomez, A. A. (1984). *Statistical Procedures for Agricultural Research* (2nd ed.). Wiley.

Kang, M. S., & Gauch, H. G. (Eds.). (1996). *Genotype-by-Environment Interaction*. CRC Press.

Robertson, A. (1959). Experimental design in the evaluation of genetic parameters. *Biometrics*, 15(2), 219–226.

Searle, S. R., Casella, G., & McCulloch, C. E. (1992). *Variance Components*. Wiley.

Yates, F., & Cochran, W. G. (1938). The analysis of groups of experiments. *The Journal of Agricultural Science*, 28(4), 556–580.

Nota: Material assistido pelo ChatGPT 5.3 e 5.4, Claude Sonnet 4.6 e Overleaf.