Biometria da Interação Genótipos $\times$ Ambientes (G$\times$A)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

15 de abril de 2026

Roteiro da Aula 6: Modelos Mistos I — Introdução ao BLUP Multiambiente

1 Introdução

Até a Aula 5, a disciplina examinou a interação genótipos $\times$ ambientes por métodos formulados, em sua base, sob efeitos fixos, com ênfase em médias, contrastes, regressões e decomposições da tabela $G \times A$. Esses procedimentos são úteis para descrever padrões de resposta e para interpretar a interação sob diferentes perspectivas biométricas. Ainda assim, essa formulação apresenta limitações quando os dados são desbalanceados, isto é, quando os genótipos não são avaliados no mesmo conjunto de ambientes, anos, safras ou repetições. Além disso, em melhoramento, o interesse analítico nem sempre se restringe à comparação dos materiais observados. Em muitas situações, busca-se predizer valores genotípicos ajustados com base na estrutura do experimento e na informação disponível para cada material.

A análise passa a ser conduzida por modelos lineares mistos, nos quais parte da variação é descrita por componentes de variância e alguns efeitos são tratados como aleatórios. Com isso, a abordagem deixa de estar centrada apenas na estimação de médias ou contrastes por mínimos quadrados e passa a incorporar a predição de efeitos não observáveis, entre eles os valores genotípicos dos materiais avaliados. É nessa formulação que se insere o BLUP, *best linear unbiased prediction*.

O objetivo desta aula é apresentar o BLUP multiambiente no contexto do modelo linear misto, estabelecer a distinção entre efeitos fixos e aleatórios, introduzir a estimação de componentes de variância por REML e discutir a interpretação biométrica do encolhimento (*shrinkage*) dos efeitos preditos. A abordagem é introdutória. A modelagem de estruturas de variância-covariância entre ambientes, os modelos fator-analíticos, os índices de adaptabilidade baseados em BLUP, a regressão aleatória e a predição em ambientes não observados serão tratados nas aulas seguintes.

2 O Modelo Linear Misto

2.1 Formulação geral

O modelo linear misto pode ser escrito como

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \mathbf{e}, \tag{1}$$

em que $\mathbf{y}$ é o vetor de observações; $\mathbf{X}$ é a matriz de incidência dos efeitos fixos; $\boldsymbol{\beta}$ é o vetor de parâmetros fixos; $\mathbf{Z}$ é a matriz de incidência dos efeitos aleatórios; $\mathbf{u}$ é o vetor de efeitos aleatórios, cujos valores são preditos no contexto do modelo; e $\mathbf{e}$ é o vetor de erros residuais.

Assume-se, na forma mais geral,

$$\mathbf{u} \sim \mathcal{N}(\mathbf{0}, \mathbf{G}), \qquad \mathbf{e} \sim \mathcal{N}(\mathbf{0}, \mathbf{R}), \tag{2}$$

com independência entre $\mathbf{u}$ e $\mathbf{e}$. Nessas condições, a variância marginal de $\mathbf{y}$ é

$$\mathrm{Var}(\mathbf{y}) = \mathbf{V} = \mathbf{Z}\mathbf{G}\mathbf{Z}' + \mathbf{R}. \tag{3}$$

A Equação 3 mostra o ponto que diferencia os modelos mistos da formulação clássica: a variabilidade total das observações é decomposta em parcelas associadas aos efeitos aleatórios e ao erro residual, e essa decomposição entra diretamente tanto na estimação dos parâmetros fixos quanto na predição dos efeitos aleatórios.

2.2 Um modelo introdutório para dados multiambiente

Para fixar ideias, considere um experimento multiambiente em que genótipos são avaliados em ambientes e repetições dentro de ambiente. Uma formulação introdutória bastante utilizada é

$$y_{ijk} = \mu + a_j + b_{k(j)} + g_i + (ga)_{ij} + e_{ijk}, \tag{4}$$

em que μ é a média geral; a_j é o efeito do ambiente j; $b_{k(j)}$ é o efeito do bloco k dentro do ambiente j; g_i é o efeito do genótipo i; $(ga)_{ij}$ é o efeito da interação entre o genótipo i e o ambiente j; e e_{ijk} é o erro residual.

A Equação 4 não deve ser entendida como a única formulação possível, mas como um ponto de partida. Seu papel, nesta aula, é tornar explícito que o desempenho observado em parcela resulta da combinação entre uma parte sistemática, associada aos efeitos fixos, e uma parte aleatória, associada aos genótipos, à interação e ao resíduo.

3 Efeitos Fixos e Aleatórios

3.1 Escopo da inferência

A distinção entre efeito fixo e efeito aleatório depende do objetivo da análise. Um efeito é tratado como fixo quando a inferência se restringe aos níveis observados daquele fator. Um efeito é tratado como aleatório quando os níveis observados são entendidos como realizações de uma população de referência, e o interesse se desloca para a variância entre esses níveis e para a predição de seus efeitos.

Essa distinção é central em melhoramento. Quando genótipos entram como fixos, o foco recai sobre as médias dos materiais avaliados naquele conjunto de ensaios. Quando entram como aleatórios, o foco recai sobre a variabilidade genética e sobre a predição dos valores genotípicos, já ajustados pela estrutura do experimento e pela informação conjunta da rede.

3.2 Uma formulação de referência para esta aula

Nesta aula, para introduzir o BLUP multiambiente sem antecipar estruturas mais complexas, será adotada a formulação em que os ambientes entram como efeitos fixos, enquanto genótipos, blocos e interação genótipo $\times$ ambiente entram como efeitos aleatórios. Essa escolha é didática e muito comum em MET. Ela permite concentrar a discussão em três pontos: a estimação dos componentes de variância; a obtenção de BLUEs para os efeitos fixos; e a obtenção de BLUPs para os efeitos aleatórios.

É importante registrar que essa alocação não é universal. Em outros contextos, ambientes podem ser tratados como aleatórios, e outras parametrizações podem ser mais adequadas. O ponto central, aqui, é compreender o papel estatístico de cada componente e o motivo pelo qual a modelagem aleatória dos genótipos muda a natureza da inferência.

4 Componentes de Variância e Estimação por REML

4.1 Componentes de variância

Quando um efeito entra no modelo como aleatório, seu interesse primário deixa de ser o valor individual de cada nível e passa a ser a variância associada àquele efeito. No modelo da Equação 4, com ambientes fixos e demais termos aleatórios, os componentes de interesse são σ_g^2, σ_{ga}^2, σ_b^2 e σ_e^2, que descrevem, respectivamente, a variação entre genótipos, a variação da interação $G \times A$, a variação entre blocos dentro de ambiente e a variação residual entre parcelas.

Essa passagem, da linguagem de médias e quadrados médios para a linguagem de variâncias e covariâncias, é um dos marcos da transição entre a abordagem clássica e a abordagem por modelos mistos. Na ANOVA conjunta, o termo $G \times A$ é detectado e testado. Aqui, ele passa a ser também modelado como fonte própria de variação.

4.2 REML – *Restricted Maximum Likelihood*

Em modelos com efeitos aleatórios, a estimação dos componentes de variância não pode ser conduzida, de forma adequada, apenas com a lógica usual de mínimos quadrados. A razão é que a incerteza associada aos efeitos fixos e aleatórios entra diretamente na decomposição da variabilidade dos dados. A estimação por máxima verossimilhança restrita, ou REML, tornou-se a abordagem padrão para essa situação (Patterson e Thompson, 1971).

A ideia do REML é estimar os componentes de variância a partir de combinações lineares dos dados que não dependem dos efeitos fixos. Com isso, a estimação da variância não é contaminada pela presença dos parâmetros fixos no mesmo sistema. Em termos práticos, o REML produz estimativas consistentes com a estrutura do modelo e lida de forma mais adequada com situações de desbalanceamento.

Nesta aula, não será feita a derivação da função de verossimilhança restrita. O encadeamento lógico que importa é: primeiro, estima-se a estrutura de variâncias e covariâncias do modelo; em seguida, usa-se essa estrutura para obter BLUEs e BLUPs.

4.3 Herdabilidade em base de médias

Uma vez obtidos os componentes de variância por REML, duas expressões de herdabilidade são imediatamente deriváveis. A herdabilidade em base de parcela individual,

$$h^2 = \frac{\hat{\sigma}_g^2}{\hat{\sigma}_g^2 + \hat{\sigma}_{ga}^2 + \hat{\sigma}_b^2 + \hat{\sigma}_e^2}, \tag{5}$$

é tipicamente baixa em MET porque o denominador inclui a interação $G \times A$ e o resíduo em escala de parcela, sem qualquer redução pela replicação. Quando a seleção é feita sobre médias de genótipos avaliados em a ambientes com r blocos, a herdabilidade em base de médias é

$$\hat{H}^2 = \frac{\hat{\sigma}_g^2}{\hat{\sigma}_g^2 + \hat{\sigma}_{ga}^2/a + \hat{\sigma}_e^2/(ar)}, \tag{6}$$

em que a divisão por a e ar reflete a redução do erro pela replicação. Em dados desbalanceados, essas expressões são aproximações. A forma exata, válida para qualquer estrutura de desbalanceamento e obtida diretamente das MME, é

$$\hat{H}^2 = 1 - \frac{\overline{\mathrm{PEV}}}{\hat{\sigma}_g^2}, \tag{7}$$

em que $\overline{\mathrm{PEV}}$ é a média das variâncias do erro de predição dos BLUPs genotípicos — conceito que será detalhado na seção seguinte. Os componentes de variância $\hat{\sigma}_g^2$, $\hat{\sigma}_{ga}^2$, $\hat{\sigma}_b^2$ e $\hat{\sigma}_e^2$ serão descritos com maior detalhe na Seção seguinte.

5 Equações de Modelos Mistos e Predição

5.1 Sistema de Henderson

Uma vez especificadas as matrizes de variância, a estimação dos efeitos fixos e a predição dos efeitos aleatórios são obtidas conjuntamente pelas equações de modelos mistos de Henderson (1975):

$$\begin{bmatrix} \mathbf{X}'\mathbf{R}^{-1}\mathbf{X} & \mathbf{X}'\mathbf{R}^{-1}\mathbf{Z} \\ \mathbf{Z}'\mathbf{R}^{-1}\mathbf{X} & \mathbf{Z}'\mathbf{R}^{-1}\mathbf{Z}+\mathbf{G}^{-1} \end{bmatrix} \begin{bmatrix} \hat{\boldsymbol{\beta}} \\ \hat{\mathbf{u}} \end{bmatrix} = \begin{bmatrix} \mathbf{X}'\mathbf{R}^{-1}\mathbf{y} \\ \mathbf{Z}'\mathbf{R}^{-1}\mathbf{y} \end{bmatrix}. \tag{8}$$

O bloco superior está ligado aos efeitos fixos; o bloco inferior, aos efeitos aleatórios. O termo $\mathbf{G}^{-1}$ é o mecanismo pelo qual a variância dos efeitos aleatórios entra na predição. É justamente essa presença explícita de $\mathbf{G}$ e $\mathbf{R}$ que faz com que os efeitos aleatórios não sejam tratados como simples médias ajustadas.

5.2 BLUE e BLUP

A solução para $\hat{\boldsymbol{\beta}}$ fornece os BLUEs (*best linear unbiased estimators*) dos efeitos fixos. A solução para $\hat{\mathbf{u}}$ fornece os BLUPs (*best linear unbiased predictors*) dos efeitos aleatórios. Uma forma compacta de escrever o BLUP é

$$\hat{\mathbf{u}} = \mathbf{G}\mathbf{Z}'\mathbf{V}^{-1}(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}). \tag{9}$$

A Equação 9 mostra que o BLUP é construído a partir dos resíduos ajustados para os efeitos fixos, ponderados pela estrutura de variância do modelo. Logo, o BLUP nunca é apenas a média observada corrigida; ele depende do quanto o modelo atribui de informação àquele efeito e do quanto o ruído residual limita sua precisão.

5.3 A variância do erro de predição

O sistema da Equação 8 é um sistema linear cujos coeficientes são as próprias matrizes que descrevem a estrutura de variância do modelo. Seja $\mathbf{C}$ a matriz de coeficientes desse sistema, particionada como

$$\mathbf{C} = \begin{bmatrix} \mathbf{C}^{11} & \mathbf{C}^{12} \\ \mathbf{C}^{21} & \mathbf{C}^{22} \end{bmatrix} = \begin{bmatrix} \mathbf{X}'\mathbf{R}^{-1}\mathbf{X} & \mathbf{X}'\mathbf{R}^{-1}\mathbf{Z} \\ \mathbf{Z}'\mathbf{R}^{-1}\mathbf{X} & \mathbf{Z}'\mathbf{R}^{-1}\mathbf{Z}+\mathbf{G}^{-1} \end{bmatrix}. \tag{10}$$

A inversa de $\mathbf{C}$ fornece as variâncias e covariâncias associadas tanto à estimação dos efeitos fixos quanto à predição dos efeitos aleatórios. Em particular, o bloco inferior direito de $\mathbf{C}^{-1}$, denotado $[\mathbf{C}^{-1}]^{22}$, contém a **variância do erro de predição** (*prediction error variance*, PEV):

$$\mathrm{PEV}(\hat{\mathbf{u}}) = \mathrm{Var}(\hat{\mathbf{u}} - \mathbf{u}) = [\mathbf{C}^{-1}]^{22}. \tag{11}$$

A PEV não mede a variância de $\hat{\mathbf{u}}$, mas sim a variância do *erro* entre o preditor e o valor verdadeiro. Ela emerge diretamente da inversão da matriz de coeficientes das MME: quanto mais informação o modelo dispuser para predizer um efeito — seja por meio de mais observações, seja por meio de estrutura de parentesco — menor será a PEV correspondente.

Uma forma alternativa, equivalente à Equação 11, é

$$\mathrm{PEV}(\hat{\mathbf{u}}) = \mathbf{G} - \mathbf{G}\mathbf{Z}'\mathbf{P}\mathbf{Z}\mathbf{G}, \tag{12}$$

em que $\mathbf{P} = \mathbf{V}^{-1} - \mathbf{V}^{-1}\mathbf{X}(\mathbf{X}'\mathbf{V}^{-1}\mathbf{X})^{-}\mathbf{X}'\mathbf{V}^{-1}$ é o operador de projeção que remove a informação dos efeitos fixos. A Equação 12 deixa explícito que a PEV é sempre menor ou igual a $\mathbf{G}$: a análise dos dados sempre reduz a incerteza sobre os efeitos aleatórios em relação à incerteza *a priori* expressa por $\mathbf{G}$.

6 Interpretação Biométrica do BLUP

6.1 O encolhimento dos efeitos preditos

Uma das propriedades mais importantes do BLUP é o encolhimento dos efeitos preditos em direção à média do modelo. Esse encolhimento é consequência direta do compromisso entre sinal e ruído no processo de predição.

Em uma situação simplificada, com um único efeito aleatório de genótipo e observações independentes dentro de genótipo, o preditor pode ser representado por

$$\hat{g}_i = \left(\frac{\sigma_g^2}{\sigma_g^2 + \sigma_e^2/n_i} \right) (\bar{y}_i - \hat{\mu}), \tag{13}$$

em que $\bar{y}_i$ é a média observada do genótipo i, $\hat{\mu}$ é a média ajustada pelo modelo, e n_i é a quantidade de informação disponível para esse genótipo. Quanto maior n_i e quanto maior a relação σ_g^2/σ_e^2, mais próximo o BLUP estará da média observada. Quanto menor a informação disponível, maior será a contração do efeito predito em direção à média da população.

6.2 Acurácia seletiva

A PEV fornece uma medida direta da qualidade da predição para cada genótipo individualmente. A partir dela, define-se a **acurácia seletiva** r_i como

$$r_i = \sqrt{1 - \frac{\mathrm{PEV}_i}{\sigma_g^2}}, \tag{14}$$

em que PEV_i é o elemento diagonal de $[\mathbf{C}^{-1}]^{22}$ correspondente ao genótipo i. A acurácia varia entre 0 e 1: quando $\mathrm{PEV}_i \to 0$, a predição converge para o valor verdadeiro e $r_i \to 1$; quando $\mathrm{PEV}_i \to \sigma_g^2$, a predição não vai além da média da população e $r_i \to 0$.

É imediato que genótipos avaliados em mais ambientes terão PEVs menores e, portanto, acurácias maiores. Essa relação entre a quantidade de informação experimental e a precisão da predição é uma das justificativas formais para o uso de redes de ensaios amplas em programas de melhoramento.

A acurácia da Equação 14 é, em essência, a raiz quadrada do coeficiente de determinação entre $\hat{g}_i$ e g_i. Por isso, ela é também interpretável como o coeficiente de correlação esperado entre os valores preditos e os valores verdadeiros dos efeitos genotípicos, e é diretamente relacionada ao ganho genético esperado com a seleção.

6.3 Por que isso importa em MET?

Em dados multiambiente, é comum que diferentes genótipos tenham quantidades distintas de informação. Alguns materiais aparecem em muitos ambientes; outros, em poucos. Nessa situação, comparar médias brutas ou mesmo médias ajustadas como se toda informação tivesse o mesmo peso pode induzir a leituras inadequadas.

O BLUP atua exatamente nesse ponto. Ele pondera a evidência disponível para cada genótipo e reduz a influência de observações escassas ou pouco informativas. Por isso, dois genótipos com a mesma média fenotípica observada podem receber BLUPs diferentes, e essa diferença reflete o fato de que a qualidade estatística da informação não é a mesma entre eles.

6.4 BLUP e seleção

Sob a ótica do melhoramento, essa propriedade é importante porque a seleção raramente é feita em cenários perfeitamente balanceados. O BLUP permite trabalhar com tabelas incompletas, manter genótipos com diferentes números de observações e produzir predições coerentes com a estrutura do experimento. Ao mesmo tempo, ele mantém a interpretação genética do problema: o foco continua sendo a comparação entre materiais, mas agora em uma base ajustada pelo modelo.

7 A Interação $G \times A$ no Modelo Misto

7.1 Da detecção à modelagem da interação

Nas aulas anteriores, a interação $G \times A$ apareceu como objeto de teste, decomposição ou interpretação gráfica. No modelo misto, ela passa a ocupar também o papel de componente de variância. Em vez de apenas concluir que a interação existe, passa-se a quantificar quanto da variabilidade do desempenho decorre dessa interação e a incorporar essa fonte de variação na predição dos valores genotípicos.

No modelo da Equação 4, o termo $(ga)_{ij}$ representa essa parcela. Sua inclusão impede que diferenças de resposta entre genótipos nos ambientes sejam absorvidas indevidamente pelo resíduo ou pelo efeito genotípico principal. Com isso, a predição do valor genotípico passa a refletir não apenas a média geral do material, mas também o fato de que seu desempenho varia de ambiente para ambiente.

A razão σ^2_{ga}/σ^2_g é um indicador da magnitude relativa da interação em relação à variação genotípica principal. Valores altos dessa razão indicam que o ordenamento dos genótipos muda substancialmente entre ambientes, o que tem implicações diretas para a estratégia de recomendação de cultivares.

7.2 O que esta aula ainda não faz

Embora a interação já entre formalmente no modelo, esta aula não discute como modelar a dependência entre ambientes por estruturas específicas de covariância. Em outras palavras, a interação $G \times A$ está sendo introduzida aqui como efeito aleatório com estrutura de variância identidade, sem considerar parametrizações como diagonal heterogênea, simetria composta, não estruturada, autorregressiva ou fator-analítica. Esse passo será dado na sequência da disciplina.

A diferença é importante. Nesta aula, o objetivo é compreender por que a interação deve estar no modelo e como ela afeta o BLUP multiambiente. A discussão sobre a forma específica da matriz de covariância entre ambientes pertence à Aula 7.

8 Extensão Conceitual: da Independência entre Genótipos ao Parentesco

8.1 O caso base: genótipos independentes

Na formulação introdutória mais simples, assume-se que os efeitos genotípicos são independentes entre si. Nesse caso, a matriz de variâncias dos efeitos genotípicos é

$$\mathbf{G}_g = \mathbf{I}\sigma^2_g, \tag{15}$$

em que $\mathbf{I}$ é a matriz identidade. Essa escolha é útil para introduzir o BLUP porque separa, de forma limpa, a ideia de predição da ideia de relacionamento genético entre materiais.

8.2 Quando existe informação de parentesco

Se houver informação genealógica ou genômica (SNPs – *Single Nucleotide Polymorphism*), a hipótese de independência pode ser substituída por uma estrutura que represente o relacionamento entre genótipos. No caso de pedigree, usa-se tipicamente

$$\mathbf{G}_g = \mathbf{A}\sigma^2_g, \tag{16}$$

em que $\mathbf{A}$ é a matriz de parentesco numerador (Wright, 1922). No caso de marcadores moleculares, uma formulação análoga pode ser construída com uma matriz de relacionamento genômico, dando origem ao GBLUP.

A interpretação biométrica muda de forma direta. Quando $\mathbf{G}_g = \mathbf{I}\sigma^2_g$, a predição de um genótipo depende da sua própria informação e da estrutura geral do experimento. Quando $\mathbf{G}_g = \mathbf{A}\sigma^2_g$, a predição também incorpora informação dos parentes. Isso ocorre porque a PEV, que determina o encolhimento de cada preditor, é obtida a partir da inversa da matriz de coeficientes das MME, a qual passa a conter $\mathbf{A}^{-1}$ no

lugar de $\mathbf{I}^{-1}$. Genótipos com poucos dados próprios, mas aparentados a materiais bem avaliados, têm sua PEV reduzida pelo parentesco, e seus BLUPs são deslocados na direção dos parentes.

Esta extensão deve ser entendida como um prolongamento natural da lógica do BLUP, não como o núcleo da aula. O ponto principal, neste momento, é perceber que o BLUP não exige, por definição, independência entre genótipos. A matriz de variância dos efeitos aleatórios pode ser enriquecida sempre que houver informação biológica ou experimental que justifique isso. As consequências dessa escolha sobre componentes de variância, acurácia e ganho genético podem ser aprofundadas em discussões posteriores.

9 Fechamento

A introdução do BLUP multiambiente marca a passagem de uma leitura puramente descritiva da interação para uma leitura modelada em termos de variâncias, covariâncias e predição. O modelo misto reorganiza o problema estatístico do MET em torno de dois eixos: a estimação dos efeitos fixos por BLUE e a predição dos efeitos aleatórios por BLUP. Ao fazer isso, acomoda desbalanceamento, separa fontes de variação e produz valores genotípicos ajustados de acordo com a quantidade e a qualidade da informação disponível.

A variância do erro de predição (PEV) e a acurácia seletiva emergem naturalmente das equações de modelos mistos de Henderson: são propriedades da predição, não da amostragem. Elas permitem quantificar, para cada genótipo individualmente, o quanto a análise reduziu a incerteza sobre seu valor verdadeiro — e, por extensão, o quanto o programa de melhoramento pode confiar naquela predição para fins de seleção.

O ponto mais importante desta aula é que o BLUP não é uma alternativa computacional à média. Ele é a consequência direta de um modelo probabilístico em que genótipos e interação $G \times A$ são tratados como fontes aleatórias de variação. É essa formulação que abre caminho, nas próximas aulas, para discutir estruturas de covariância entre ambientes, medidas de adaptabilidade e estabilidade derivadas de BLUP, regressão aleatória e predição em cenários mais complexos.

10 Atividade

Os dados utilizados nesta atividade são o conjunto `data_ge`, disponível no pacote `metan` (Olivoto & Lúcio, 2020). O conjunto contém observações de produtividade de grãos de soja (`GY`, Mg/ha) para 14 genótipos avaliados em 14 ambientes em delineamento de blocos completos casualizados com 3 repetições. Para aproximar a situação de uma rede de ensaios real, os dados são artificialmente desbalanceados antes da análise: 20% das combinações genótipo × ambiente são removidas de forma aleatória, de modo que nem todos os genótipos aparecem em todos os ambientes. O objetivo é ajustar um modelo misto via `lme4`, estimar os componentes de variância por REML, extrair os BLUPs genotípicos e suas PEVs, e comparar o ranking obtido pelo BLUP com o ranking por média aritmética.

```r
library(metan)
library(lme4)

data(data_ge)

# desbalanceamento: remover 20% das combinacoes gen x ambiente
set.seed(10.03) # substitua pela data do seu aniversario 'dia.mes'
combos   <- unique(data_ge[, c("GEN","ENV")])
drop     <- combos[sample(nrow(combos), size = round(0.20 * nrow(combos))), ]
dat      <- merge(data_ge, drop, by = c("GEN","ENV"), all = TRUE)
dat      <- dat[!(paste(dat$GEN, dat$ENV) %in% paste(drop$GEN, drop$ENV)), ]
dat$GEN  <- factor(dat$GEN)
dat$ENV  <- factor(dat$ENV)
dat$REP  <- factor(dat$REP)
```

Após o carregamento e o desbalanceamento, o aluno deverá: (i) ajustar o modelo misto com `lme4` e extrair os componentes de variância por REML; (ii) calcular h^2, $\hat{H}^2$ e a acurácia seletiva a partir das PEVs; e (iii) comparar o ranking por BLUP com o ranking por média aritmética, identificando os genótipos mais afetados pelo desbalanceamento.

Referências

Comstock, R. E., & Robinson, H. F. (1952). Estimation of average dominance of genes. In J. W. Gowen (Ed.), *Heterosis* (pp. 494–516). Iowa State College Press.

Henderson, C. R. (1975). Best linear unbiased estimation and prediction under a selection model. *Biometrics*, 31(2), 423–447.

Lynch, M., & Walsh, B. (1998). *Genetics and Analysis of Quantitative Traits*. Sinauer Associates.

Patterson, H. D., & Thompson, R. (1971). Recovery of inter-block information when block sizes are unequal. *Biometrika*, 58(3), 545–554.

Piepho, H. P., Möhring, J., Melchinger, A. E., & Büchse, A. (2008). BLUP for phenotypic selection in plant breeding and variety testing. *Euphytica*, 161(1–2), 209–228.

Resende, M. D. V. (2007). *Matemática e Estatística na Análise de Experimentos e no Melhoramento Genético*. Embrapa Florestas.

Searle, S. R., Casella, G., & McCulloch, C. E. (1992). *Variance Components*. Wiley.

Nota: Material assistido pelo Claude Sonnet 4.6, ChatGPT 5.2 e Overleaf.