Biometria da Interação Genótipos $\times$ Ambientes (G$\times$A)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

22 de abril de 2026

Roteiro da Aula 7: Modelos Mistos II — Estruturas de Variância-Covariância

1 Introdução

Na Aula 6, os efeitos de genótipo e de interação G$\times$A foram tratados como termos aleatórios escalares: uma única variância para o efeito principal de genótipo e uma única variância para o desvio de interação. Essa formulação é amplamente utilizada, mas carrega uma hipótese estatística embutida sobre a estrutura de associação genética entre os ambientes. A Aula 7 torna essa hipótese explícita. A pergunta passa a ser qual estrutura de variância-covariância (VCOV) está sendo assumida para os efeitos genéticos ao longo dos ambientes (e será estimada via REML). A resposta determina como o modelo interpreta padrões de reclassificação de genótipos, como os BLUPs são calculados, qual o grau de compartilhamento de informação entre ensaios e quais as correlações genéticas estimadas entre ambientes.

Esta aula cobre:

1. A reformulação da G$\times$A em termos de uma matriz de variâncias e covariâncias genéticas entre ambientes, $\mathbf{G}$, com o produto de Kronecker ($\otimes$) como notação unificadora.
2. O catálogo das principais estruturas VCOV — Identidade (ID), Diagonal (DIAG), Simetria Composta (CS), Simetria Composta Heterogênea (CSH), Não Estruturada (UN), Autorregressiva de primeira ordem [AR(1)] e Fatorial Analítica (FA) — com a correlação genética implícita em cada uma.
3. A derivação formal da equivalência entre o modelo $g + ga$ e a estrutura CS.
4. Os critérios de escolha de estrutura e as implicações sobre os BLUPs.

2 Do modelo misto multiambiente à matriz genética entre ambientes

2.1 Formulação do modelo

Considere I genótipos avaliados em J ambientes, com K blocos por ambiente (DBC). O modelo linear misto para y_{ijk} é:

$$y_{ijk} \;=\; \mu + a_j + b_{k(j)} + u_{ij} + e_{ijk}, \tag{1}$$

em que μ é a média geral, a_j é o efeito fixo do ambiente j, $b_{k(j)}$ é o efeito fixo do bloco k dentro do ambiente j, u_{ij} é o valor genético do genótipo i no ambiente j, e $e_{ijk} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0, \sigma_e^2)$. Em notação matricial:

$$\mathbf{y} \;=\; \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u} + \mathbf{e}, \qquad \mathbf{u} \;\sim\; \mathcal{N}(\mathbf{0},\; \mathbf{G} \otimes \mathbf{I}_I)\,, \qquad \mathbf{e} \;\sim\; \mathcal{N}(\mathbf{0}, \mathbf{R}), \tag{2}$$

em que $\mathbf{G}$ é a matriz $J \times J$ de variâncias e covariâncias genéticas entre ambientes, $\mathbf{I}_I$ é a identidade de ordem I, $\otimes$ denota o produto de Kronecker e $\mathbf{R}$ é a matriz residual. O produto $\mathbf{G} \otimes \mathbf{I}_I$ produz uma

matriz bloco-diagonal $IJ \times IJ$: genótipos distintos têm covariância nula; o mesmo genótipo em ambientes j e j' tem covariância $[\mathbf{G}]_{jj'}$. Com informação de parentesco ou marcadores moleculares, a expressão generaliza-se para $\mathbf{G} \otimes \mathbf{K}$; nesta aula adota-se $\mathbf{K} = \mathbf{I}_I$.

2.2 A matriz G como hipótese sobre a G×A

Os elementos de $\mathbf{G}$ têm interpretação direta:

- $[\mathbf{G}]_{jj} = \sigma^2_{g_j}$: variância genética no ambiente j — amplitude das diferenças entre genótipos naquele ambiente.
- $[\mathbf{G}]_{jj'} = \sigma_{g_{jj'}}$: covariância genética entre os ambientes j e j' — tendência de genótipos superiores em j também o serem em j'.

Modelar a G×A equivale a modelar $\mathbf{G}$. Cada especificação traduz uma hipótese biométrica distinta sobre a distribuição da variância genética entre ambientes e a intensidade da associação genética entre pares de ambientes. A escolha da estrutura altera componentes estimados, correlações genéticas, BLUPs e a interpretação da interação (Smith, Cullis & Thompson, 2005).

3 Estruturas de variância-covariância para a G×A

As estruturas são apresentadas em ordem crescente de flexibilidade. Para cada uma são indicados: forma da matriz, número de parâmetros em função de J, correlação genética implícita e contexto biométrico de uso. A Tabela 1 resume o conjunto.

3.1 Identidade (ID)

$$\mathbf{G}^{\mathrm{ID}} = \sigma^2_g \mathbf{I}_J = \begin{pmatrix} \sigma^2_g & 0 & \cdots & 0 \\ 0 & \sigma^2_g & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2_g \end{pmatrix}. \tag{3}$$

Parâmetros: 1.

Correlação genética implícita: $r_g(j, j') = 0$ para todo $j \neq j'$.

A estrutura ID impõe mesma variância genética em todos os ambientes e covariâncias nulas entre quaisquer dois ambientes. Assim, o desempenho de um genótipo em um ambiente não informa seu desempenho em outro, e toda a matriz genética entre ambientes fica restrita à diagonal. Trata-se da estrutura mais simples e mais restritiva.

A estrutura ID está no nível de cada efeito aleatório individual. Num modelo, "ID básico", $y = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{u}$, o vetor $\mathbf{u}$ é assumido com matriz identidade: mesma variância e covariâncias nulas entre níveis (tal como observado na Eq. 3). O mesmo ocorre em $y = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}_1\mathbf{g} + \mathbf{Z}_2\mathbf{u}$: tanto $\mathbf{g}$ (aqui '$\mathbf{g}$' são os efeitos aleatórios de genótipos, sem a interação) quanto $\mathbf{u}$ são, individualmente, modelados com estrutura ID. O que muda é a estrutura resultante quando esses termos são somados (veremos melhor sobre isso nos tópicos **3.3** e **4**).

3.2 Diagonal (DIAG)

$$\mathbf{G}^{\mathrm{DIAG}} = \begin{pmatrix} \sigma^2_{g_1} & 0 & \cdots & 0 \\ 0 & \sigma^2_{g_2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2_{g_J} \end{pmatrix}. \tag{4}$$

Parâmetros: J. **Correlação genética implícita:** $r_g(j, j') = 0$ para todo $j \neq j'$.

Variâncias genéticas distintas por ambiente, mas covariâncias nulas. Captura heterogeneidade de amplitude genética entre ambientes — alguns ambientes discriminam mais os genótipos do que outros — mas ainda trata os pares de ambientes como geneticamente independentes. Útil para testar se a heterogeneidade de variâncias é necessária antes de introduzir covariâncias.

3.3 Simetria Composta (CS)

$$\mathbf{G}^{\mathrm{CS}} \;=\; \sigma_s^2\,\mathbf{I}_J + \sigma_c^2\,\mathbf{J}_J \;=\; \begin{pmatrix} \sigma_s^2+\sigma_c^2 & \sigma_c^2 & \cdots & \sigma_c^2 \\ \sigma_c^2 & \sigma_s^2+\sigma_c^2 & \cdots & \sigma_c^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_c^2 & \sigma_c^2 & \cdots & \sigma_s^2+\sigma_c^2 \end{pmatrix}, \tag{5}$$

em que $\mathbf{J}_J = \mathbf{1}_J\mathbf{1}_J^\top$ é a matriz $J \times J$ de uns, $\sigma_s^2 \geq 0$ é a variância específica (dentro de ambiente) e σ_c^2 é a covariância comum entre quaisquer dois ambientes.

Parâmetros: 2 (σ_s^2 e σ_c^2), independente de J.

Correlação genética implícita:

$$r_g \;=\; \frac{\sigma_c^2}{\sigma_s^2+\sigma_c^2}, \tag{6}$$

uniforme para todos os pares (j, j').

CS é a mais parcimoniosa das estruturas com covariância não nula. O componente σ_c^2 é compartilhado por todos os ambientes (análogo ao efeito principal de genótipo) e σ_s^2 é o desvio local. A imposição de correlação uniforme pode ser biologicamente rígida em redes com ambientes muito contrastantes. A equivalência entre CS e o modelo $g + ga$ é derivada na Seção 4.

Restrição de positividade: exige-se $\sigma_c^2 \geq -\sigma_s^2/(J-1)$, implicando $r_g \geq -1/(J-1)$.

3.4 Simetria Composta Heterogênea (CSH)

$$\mathbf{G}^{\mathrm{CSH}} \;=\; \begin{pmatrix} \sigma_{g_1}^2 & \rho\,\sigma_{g_1}\sigma_{g_2} & \cdots & \rho\,\sigma_{g_1}\sigma_{g_J} \\ \rho\,\sigma_{g_2}\sigma_{g_1} & \sigma_{g_2}^2 & \cdots & \rho\,\sigma_{g_2}\sigma_{g_J} \\ \vdots & \vdots & \ddots & \vdots \\ \rho\,\sigma_{g_J}\sigma_{g_1} & \rho\,\sigma_{g_J}\sigma_{g_2} & \cdots & \sigma_{g_J}^2 \end{pmatrix}, \tag{7}$$

ou seja, $[\mathbf{G}^{\mathrm{CSH}}]_{jj'} = \sigma_{g_j}^2$ se $j = j'$ e $\rho\,\sigma_{g_j}\sigma_{g_{j'}}$ se $j \neq j'$, em que $\mathbf{D} = \mathrm{diag}(\sigma_{g_1}^2, \ldots, \sigma_{g_J}^2)$ e ρ é a correlação comum.

Parâmetros: $J + 1$ ($\sigma_{g_1}^2, \ldots, \sigma_{g_J}^2$ e ρ).

Correlação genética implícita: $r_g(j, j') = \rho$ para todo $j \neq j'$.

CSH é um meio-termo entre DIAG e UN: acomoda variâncias genéticas heterogêneas entre ambientes e mantém uma correlação comum. É adequada quando a amplitude genética varia entre ambientes, mas a estrutura de associação permanece aproximadamente uniforme.

3.5 Não Estruturada (UN)

$$\mathbf{G}^{\mathrm{UN}} \;=\; \begin{pmatrix} \sigma_{g_1}^2 & \sigma_{g_{12}} & \cdots & \sigma_{g_{1J}} \\ \sigma_{g_{12}} & \sigma_{g_2}^2 & \cdots & \sigma_{g_{2J}} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{g_{1J}} & \sigma_{g_{2J}} & \cdots & \sigma_{g_J}^2 \end{pmatrix}. \tag{8}$$

Parâmetros: $J(J+1)/2$.

Correlação genética implícita:

$$r_g(j, j') \;=\; \frac{\sigma_{g_{jj'}}}{\sqrt{\sigma_{g_j}^2\,\sigma_{g_{j'}}^2}}, \tag{9}$$

estimada de forma livre e independente para cada par (j, j').

UN é a estrutura de máxima flexibilidade: cada par de ambientes tem sua própria covariância e as variâncias são heterogêneas. Serve como referência superior de ajuste, mas o custo paramétrico cresce quadraticamente com J, por exemplo, com $J = 10$ implica 55 parâmetros; $J = 20$, implica 210. Em METs com poucos genótipos ou dados desbalanceados, a estimação tende a ser instável e a matriz estimada pode não ser positiva definida (Smith, Cullis & Thompson, 2001).

3.6 Autorregressiva de Primeira Ordem [AR(1)]

$$\mathbf{G}^{\mathrm{AR}(1)} = \sigma_g^2 \begin{pmatrix} 1 & \rho & \rho^2 & \cdots & \rho^{J-1} \\ \rho & 1 & \rho & \cdots & \rho^{J-2} \\ \rho^2 & \rho & 1 & \cdots & \rho^{J-3} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \rho^{J-1} & \rho^{J-2} & \rho^{J-3} & \cdots & 1 \end{pmatrix}, \quad |\rho| < 1, \tag{10}$$

ou seja, $[\mathbf{G}^{\mathrm{AR}(1)}]_{jj'} = \sigma_g^2\, \rho^{|j-j'|}$.

Parâmetros: 2 (σ_g^2 e ρ).

Correlação genética implícita: $r_g(j, j') = \rho^{|j-j'|}$, decaindo exponencialmente com a distância ordinal entre os ambientes.

AR(1) é adequada apenas quando os ambientes possuem **ordenamento natural** — anos consecutivos, doses crescentes de um insumo, gradiente espacial defensável. O parâmetro ρ representa a correlação entre ambientes adjacentes; ambientes distantes na sequência são menos associados. Sem ordenamento substantivamente justificado, o uso de AR(1) é infundado.

3.7 Fatorial Analítica (FA)

$$\mathbf{G}^{\mathrm{FA}(k)} = \mathbf{\Lambda}\mathbf{\Lambda}^\top + \mathbf{\Psi}, \tag{11}$$

em que

$$\mathbf{\Lambda} = \begin{pmatrix} \lambda_{11} & \lambda_{12} & \cdots & \lambda_{1k} \\ \lambda_{21} & \lambda_{22} & \cdots & \lambda_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_{J1} & \lambda_{J2} & \cdots & \lambda_{Jk} \end{pmatrix}, \qquad \mathbf{\Psi} = \begin{pmatrix} \psi_1 & 0 & \cdots & 0 \\ 0 & \psi_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \psi_J \end{pmatrix}, \tag{12}$$

com os elementos resultantes:

$$\left[\mathbf{G}^{\mathrm{FA}(k)}\right]_{jj'} = \begin{cases} \displaystyle\sum_{l=1}^{k} \lambda_{jl}^2 + \psi_j & \text{se } j = j', \\ \displaystyle\sum_{l=1}^{k} \lambda_{jl}\, \lambda_{j'l} & \text{se } j \neq j'. \end{cases} \tag{13}$$

Parâmetros: $kJ - k(k-1)/2 + J$ (cargas identificadas mais variâncias específicas).

Correlação genética implícita: aproximação de posto k de UN; correlações distintas para cada par de ambientes, determinadas pelas cargas fatoriais λ_{jl}.

A parte $\mathbf{\Lambda}\mathbf{\Lambda}^\top$ descreve a covariação genética compartilhada entre ambientes, enquanto $\mathbf{\Psi}$ representa a parte específica de cada ambiente. Assim, a covariância entre dois ambientes depende do quanto eles compartilham os mesmos fatores latentes, e a variância marginal resulta da soma entre componente comum e componente específica.

FA(k) é uma aproximação parcimoniosa de UN para METs com muitos ambientes: com poucos fatores latentes, captura os padrões dominantes de covariação genética sem estimar livremente todas as covariâncias. Com $k = 1$, FA se aproxima de um modelo de componente comum com variâncias específicas,

próximo de CSH. Com k crescente, a aproximação a UN melhora progressivamente, embora a vantagem da FA esteja justamente em representar a matriz $\mathbf{G}$ com poucos fatores, e não em reproduzir uma estrutura quase não estruturada (Piepho, 1997; Smith, Cullis & Thompson, 2001; Burguenõ et al., 2008).

3.8 Síntese comparativa

A Tabela 1 resume as principais estruturas de VCOV utilizadas para modelar a matriz genética entre ambientes. A comparação conjunta dessas estruturas ajuda a visualizar o compromisso entre parcimônia, flexibilidade e interpretação biométrica, bem como o tipo de correlação genética implícita em cada caso.

Tabela 1: Comparativo das principais estruturas VCOV para $\mathbf{G}$ em METs.
J = número de ambientes; k = número de fatores.

Estrutura	Parâmetros	Hipótese estatística	Leitura biométrica
ID	1	Mesma variância; covariâncias nulas	Sem associação genética entre ambientes; escala idêntica
DIAG	J	Variâncias distintas; covariâncias nulas	Ambientes diferem em amplitude genética; sem troca de informação entre eles
CS	2	Variância homogênea; covariância uniforme	Componente genético comum a todos os ambientes; r_g uniforme
CSH	$J+1$	Variâncias distintas; correlação uniforme	Como CS, mas com amplitudes genéticas heterogêneas
UN	$J(J+1)/2$	Variâncias e covariâncias livres	Máxima flexibilidade; r_g distinto para cada par de ambientes
AR(1)	2	Covariância decai com a distância ordinal	Ambientes próximos na sequência são geneticamente mais semelhantes
FA(k)	$kJ - k(k-1)/2 + J$	Aproximação por k fatores latentes	Boa flexibilidade com custo paramétrico reduzido em relação a UN

3.9 Correlação genética entre ambientes

Para uma estrutura geral $\mathbf{G}$, a correlação genética entre os ambientes j e j' é:

$$r_g(j,j') = \frac{[\mathbf{G}]_{jj'}}{\sqrt{[\mathbf{G}]_{jj}\,[\mathbf{G}]_{j'j'}}}. \tag{14}$$

Essa quantidade mede o grau de concordância genética entre ambientes (Lynch & Walsh, 1998). Os valores são interpretados da seguinte forma:

- $r_g(j,j') \approx 1$: genótipos mantêm praticamente o mesmo *ranking* nos dois ambientes; interação predominantemente de escala; seleção em j é eficiente para j'.
- $r_g(j,j')$ moderado (0,4–0,7): reclassificação parcial; ganho indireto de seleção existe, mas com eficiência reduzida.
- $r_g(j,j') \approx 0$: desempenhos geneticamente independentes; os ambientes se comportam como populações geneticamente distintas.

- $r_g(j, j') < 0$: antagonismo genético; interação cruzada (*crossover*) severa; recomendações diferenciadas são necessárias (van Eeuwijk, Bustos-Korts & Malosetti, 2016).

Correlação genética alta não significa ausência de G×A; indica que a componente de reclassificação é pequena em relação à componente de escala. A estrutura CS impõe um único valor de r_g para todos os pares de ambientes; UN e FA($k \geq 2$) permitem correlações distintas para cada par.

4 Derivação: equivalência entre o modelo $g + ga$ e a estrutura CS

4.1 O modelo clássico

O modelo da Aula 6 decompõe o efeito genético em componente principal e desvio de interação:

$$y_{ijk} \;=\; \mu + a_j + b_{k(j)} + g_i + (ga)_{ij} + e_{ijk}, \tag{15}$$

com

$$g_i \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\, \sigma_g^2), \qquad (ga)_{ij} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\, \sigma_{ga}^2), \qquad e_{ijk} \overset{\text{i.i.d.}}{\sim} \mathcal{N}(0,\, \sigma_e^2), \tag{16}$$

com g_i, $(ga)_{ij}$ e e_{ijk} mutualmente independentes.

4.2 Variância e covariância entre ambientes

Defina $u_{ij} = g_i + (ga)_{ij}$.

Variância marginal no ambiente j:

$$\mathrm{Var}(u_{ij}) \;=\; \mathrm{Var}(g_i) + \mathrm{Var}((ga)_{ij}) \;=\; \sigma_g^2 + \sigma_{ga}^2. \tag{17}$$

Covariância entre os ambientes j e j' ($j \neq j'$), para o genótipo i:

$$\begin{aligned}
\mathrm{Cov}(u_{ij},\, u_{ij'}) \;&=\; \mathrm{Cov}(g_i + (ga)_{ij},\; g_i + (ga)_{ij'}) \\
&=\; \mathrm{Var}(g_i) + \underbrace{\mathrm{Cov}(g_i,\, (ga)_{ij'})}_{=\,0} + \underbrace{\mathrm{Cov}((ga)_{ij},\, g_i)}_{=\,0} + \underbrace{\mathrm{Cov}((ga)_{ij},\, (ga)_{ij'})}_{=\,0} \\
&=\; \sigma_g^2.
\end{aligned} \tag{18}$$

O componente σ_g^2 persiste porque g_i é compartilhado entre os ambientes. Os termos $(ga)_{ij}$ e $(ga)_{ij'}$ são i.i.d. e independentes entre si e de g_i.

4.3 A matriz $\mathbf{G}$ implícita

As equações (17) e (18) determinam completamente a matriz $J \times J$ implícita no modelo (15):

$$\mathbf{G}^{g+ga} \;=\; \begin{pmatrix} \sigma_g^2 + \sigma_{ga}^2 & \sigma_g^2 & \cdots & \sigma_g^2 \\ \sigma_g^2 & \sigma_g^2 + \sigma_{ga}^2 & \cdots & \sigma_g^2 \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_g^2 & \sigma_g^2 & \cdots & \sigma_g^2 + \sigma_{ga}^2 \end{pmatrix} \;=\; \sigma_{ga}^2\, \mathbf{I}_J + \sigma_g^2\, \mathbf{J}_J. \tag{19}$$

Comparando com a equação (5), esta é exatamente uma estrutura CS com:

$$\boxed{\sigma_s^2 \;=\; \sigma_{ga}^2 \qquad \text{e} \qquad \sigma_c^2 \;=\; \sigma_g^2.} \tag{20}$$

O modelo $g + ga$ com efeitos aleatórios i.i.d. é portanto **parametricamente equivalente** ao modelo com efeito genético único estruturado por CS entre ambientes. Ambos produzem a mesma verossimilhança e os mesmos BLUPs.

4.4 Correlação genética uniforme implícita

Substituindo (20) em (6):

$$\boxed{r_g \;=\; \frac{\sigma_g^2}{\sigma_g^2 + \sigma_{ga}^2}.} \tag{21}$$

A decomposição $g + ga$ induz estrutura CS sobre a matriz genética entre ambientes e impõe correlação genética uniforme para todos os pares — hipótese que estava embutida na formulação clássica da Aula 6, mas raramente enunciada.

Da equação (21): quando $\sigma_g^2 \gg \sigma_{ga}^2$, $r_g \approx 1$ e os *rankings* são estáveis entre ambientes; quando $\sigma_g^2 \ll \sigma_{ga}^2$, $r_g \approx 0$ e a interação domina. O modelo CS não admite correlações negativas entre pares específicos de ambientes, pois $\sigma_c^2 < 0$ violaria a positividade semidefinida de $\mathbf{G}$. Para capturar antagonismos entre pares de ambientes, estruturas mais flexíveis (CSH, UN ou FA) são necessárias.

5 Critérios para escolha da estrutura

A escolha de $\mathbf{G}$ deve considerar três dimensões simultaneamente.

Plausibilidade biométrica. A estrutura deve ser compatível com a natureza da rede experimental. Ambientes com marcada heterogeneidade de capacidade discriminativa justificam variâncias genéticas distintas (DIAG, CSH, UN, FA). Gradiente temporal ou espacial claro e defensável justifica AR(1); sem esse gradiente, AR(1) não tem fundamento biométrico. CS é adequada quando os ambientes são relativamente homogêneos e a interação de reclassificação é moderada. FA(k) com k pequeno é preferida em redes amplas, quando poucos fatores latentes explicam a maior parte da covariação genética entre ambientes (Smith, Cullis & Thompson, 2005).

Estabilidade numérica. Estruturas mais flexíveis exigem mais informação para convergência. UN com J grande e poucos genótipos gera frequentemente estimativas na fronteira do espaço paramétrico (variâncias nulas, correlações ± 1) ou não convergência. Dados desbalanceados prejudicam especialmente a estimação de covariâncias em UN. FA(k) com k excessivo produz cargas indetermináveis (*Heywood cases*).

Critérios formais de ajuste. Para modelos aninhados com a mesma parte fixa, aplica-se o teste da razão de verossimilhança (LRT) baseado em REML (Patterson & Thompson, 1971):

$$\Lambda \;=\; -2\big[\ell_{\text{restrito}} - \ell_{\text{completo}}\big] \;\dot{\sim}\; \chi^2_{\nu}, \tag{22}$$

em que ν é a diferença no número de parâmetros de variância. Quando os modelos diferem na parte fixa, o LRT deve ser baseado em ML ordinário. Para comparações entre modelos não aninhados, empregam-se os critérios de informação (Gilmour, Thompson & Cullis, 1995):

$$\text{AIC} \;=\; -2\ell_{\text{REML}} + 2p, \qquad \text{BIC} \;=\; -2\ell_{\text{REML}} + p\ln(n^*), \tag{23}$$

em que p é o número de parâmetros de variância e n^* é a dimensão do espaço residual. O BIC penaliza mais fortemente modelos complexos. O procedimento mais defensável é iniciar com estruturas simples e avançar para estruturas mais flexíveis apenas quando houver evidência de que a forma mais simples é excessivamente restritiva. Menor AIC não é critério suficiente: a estrutura escolhida deve ser também biométricamente plausível.

6 Implicações da estrutura sobre os BLUPs

A especificação de $\mathbf{G}$ afeta diretamente os BLUPs dos genótipos nos ambientes. A estrutura CS impõe o mesmo grau de *shrinkage* para todos os ambientes, pois assume variância genética homogênea. Estruturas como CSH e UN permitem *shrinkage* diferenciado: ambientes com menor variância genética estimada geram predições mais encolhidas, refletindo maior incerteza local.

Quando a correlação genética entre dois ambientes é alta, o desempenho observado em um informa fortemente a predição no outro. Quando é baixa, o BLUP depende mais da evidência local. A matriz $\mathbf{G}$ define, portanto, a geometria pela qual o modelo compartilha informação entre ensaios.

Na prática, comparar os BLUPs e o *ranking* genotípico entre o modelo $g + ga$ (equivalente a CS) e um modelo mais flexível (UN ou FA) revela se a hipótese de correlação uniforme está distorcendo as predições. Quando CS e UN produzem resultados similares, a parcimônia de CS é preferida; quando divergem substancialmente, há evidência de que a estrutura real é mais complexa.

7 Nota sobre a prática computacional

Na prática desta aula, o objetivo é comparar um conjunto curto de estruturas e interpretar cada resultado com cuidado, sem transformar a sessão em competição entre pacotes computacionais. Recomenda-se trabalhar com um banco MET de dimensão moderada e estrutura experimental simples.

Uma sequência conveniente: (i) ajustar o modelo clássico $g + ga$; (ii) ajustar a parametrização equivalente sob CS e verificar a correspondência dos componentes estimados; (iii) ajustar DIAG e avaliar se a heterogeneidade de variâncias é relevante; (iv) ajustar UN como referência superior de ajuste. Os produtos a explorar são: componentes de variância, matrizes $\hat{\mathbf{G}}$, correlações genéticas $\hat{r}_g(j, j')$ e BLUPs dos genótipos por ambiente. Esse encadeamento materializa a equivalência $g + ga \equiv \mathrm{CS}$ e evidencia como diferentes estruturas alteram a leitura da interação e os valores preditos.

8 Síntese

Em modelos mistos multiambiente, especificar a G×A equivale a especificar a matriz de variâncias e covariâncias genéticas entre ambientes, $\mathbf{G}$. As estruturas ID, DIAG, CS, CSH, UN, AR(1) e FA representam níveis distintos de flexibilidade e traduzem hipóteses biométricas distintas sobre a natureza da associação genética entre ambientes. O ponto central desta aula é a equivalência formal entre o modelo com $g + ga$ independentes e a estrutura CS: o modelo clássico assume implicitamente correlação genética uniforme entre todos os pares de ambientes, hipótese razoável em muitos cenários, mas potencialmente restritiva em redes com ambientes contrastantes. A escolha da estrutura deve combinar plausibilidade biométrica, estabilidade numérica e critérios formais de ajuste.

9 Atividade

Utilize o mesmo conjunto de dados empregado na aula prática, isto é, o arquivo `maize_safrinha_MET.txt`. Nesta atividade, considere **blocos dentro de ensaio como efeito aleatório**. O objetivo é comparar como diferentes estruturas de variância-covariância para a G×A alteram os componentes estimados, a matriz genética entre ambientes, as correlações genéticas e os BLUPs dos genótipos.

Considere o modelo

$$y_{ijk} = \mu + a_j + b_{k(j)} + u_{ij} + e_{ijk},$$

em que a_j é o efeito fixo do ambiente j, $b_{k(j)}$ é o efeito aleatório do bloco k dentro do ambiente j, u_{ij} é o valor genético do genótipo i no ambiente j, e e_{ijk} é o erro residual. Assuma

$$b_{k(j)} \sim \mathcal{N}(0, \sigma_b^2), \qquad u \sim \mathcal{N}(0, \mathbf{G} \otimes \mathbf{I}), \qquad e_{ijk} \sim \mathcal{N}(0, \sigma_e^2),$$

com independência entre os termos aleatórios.

a) Ajuste aos dados três estruturas para a matriz genética entre ambientes, $\mathbf{G}$: ID, DIAG e UN. Para cada modelo, apresente os componentes de variância estimados e a matriz $\widehat{\mathbf{G}}$. Em seguida, obtenha as correlações genéticas entre ambientes.

b) A estrutura CS não será ajustada separadamente nesta atividade. Explique por que, neste contexto, a parametrização usada para o modelo ID já leva a uma estrutura genética equivalente à CS. Sua resposta deve deixar claro quais componentes do modelo correspondem à parte comum entre ambientes e à parte específica de ambiente.

c) Obtenha os BLUPs dos genótipos em cada ambiente para os modelos ID, DIAG e UN. Compare os *rankings* dos genótipos entre essas estruturas e comente se a escolha da VCOV altera apenas a escala dos valores preditos ou se também modifica a ordenação dos materiais.

d) Com base nos resultados, escreva uma conclusão curta sobre este conjunto de dados, comentando: a heterogeneidade de variâncias genéticas entre ambientes parece importante? As correlações genéticas sugerem associação uniforme ou contrastante entre ambientes? Considerando interpretação biométrica, número de parâmetros e comportamento dos BLUPs, qual estrutura você adotaria para descrever a G×A neste banco de dados?

Referências

Burguenõ, J., Crossa, J., Cornelius, P. L., & Yang, R.-C. (2008). Using factor analytic models for joining environments and genotypes without crossover genotype × environment interaction. *Crop Science*, *48*(4), 1291–1305.

Gilmour, A. R., Thompson, R., & Cullis, B. R. (1995). Average information REML: an efficient algorithm for variance parameter estimation in linear mixed models. *Biometrics*, *51*(4), 1440–1450.

Lynch, M., & Walsh, B. (1998). *Genetics and Analysis of Quantitative Traits*. Sinauer Associates, Sunderland, Massachusetts.

Patterson, H. D., & Thompson, R. (1971). Recovery of inter-block information when block sizes are unequal. *Biometrika*, *58*(3), 545–554.

Piepho, H. P. (1997). Analyzing genotype-environment data by mixed models with multiplicative terms. *Biometrics*, *53*(2), 761–766.

Smith, A. B., Cullis, B. R., & Thompson, R. (2001). Analysing variety by environment data using multiplicative mixed models and adjustments for spatial field trend. *Biometrics*, *57*(4), 1138–1147.

Smith, A. B., Cullis, B. R., & Thompson, R. (2005). The analysis of crop cultivar breeding and evaluation trials: an overview of current mixed model approaches. *The Journal of Agricultural Science*, *143*(6), 449–462.

van Eeuwijk, F. A., Bustos-Korts, D. V., & Malosetti, M. (2016). What should students in plant breeding know about the statistical aspects of genotype × environment interactions? *Crop Science*, *56*(5), 2119–2140.

Nota: Material assistido pelo ChatGPT 5.3 e Claude Sonnet 4.6, compilado no Overleaf.