Estrutura de Variância-Covariância em Modelos $g + ga$

Prof. Rafael Tassinari Resende — PPGGMP/UFG — Abril de 2026

Por que a diagonal de G é $\sigma_g^2 + \sigma_{ga}^2$ e fora dela é σ_g^2?

Defina, para o mesmo genótipo i,

$$u_{ij} = g_i + (ga)_{ij}, \tag{1}$$

em que u_{ij} é o valor genético do genótipo i no ambiente j.

Agora organize os valores desse genótipo ao longo dos J ambientes no vetor

$$\mathbf{u}_i = \begin{pmatrix} u_{i1} \\ u_{i2} \\ \vdots \\ u_{iJ} \end{pmatrix}. \tag{2}$$

A matriz genética entre ambientes é

$$\mathbf{G} = \mathrm{Var}(\mathbf{u}_i), \tag{3}$$

isto é, cada elemento de $\mathbf{G}$ é dado por

$$[\mathbf{G}]_{jj'} = \mathrm{Cov}(u_{ij}, u_{ij'}). \tag{4}$$

Há então dois casos:

1. Elementos da diagonal ($j = j'$)

Na diagonal, temos

$$[\mathbf{G}]_{jj} = \mathrm{Var}(u_{ij}). \tag{5}$$

Como

$$u_{ij} = g_i + (ga)_{ij}, \tag{6}$$

segue que

$$\mathrm{Var}(u_{ij}) = \mathrm{Var}(g_i + (ga)_{ij}). \tag{7}$$

Como g_i e $(ga)_{ij}$ são independentes,

$$\mathrm{Var}(u_{ij}) = \sigma_g^2 + \sigma_{ga}^2. \tag{8}$$

Portanto, na diagonal entra

$$\sigma_g^2 + \sigma_{ga}^2. \tag{9}$$

2. Elementos fora da diagonal ($j \neq j'$)

Agora considere dois ambientes diferentes:

$$[\mathbf{G}]_{jj'} = \mathrm{Cov}(u_{ij}, u_{ij'}). \tag{10}$$

Substituindo u_{ij} e $u_{ij'}$,

$$\begin{aligned} \mathrm{Cov}(u_{ij}, u_{ij'}) &= \mathrm{Cov}(g_i + (ga)_{ij},\ g_i + (ga)_{ij'}) \\ &= \mathrm{Var}(g_i) \\ &\quad + \mathrm{Cov}(g_i, (ga)_{ij'}) \\ &\quad + \mathrm{Cov}((ga)_{ij}, g_i) \\ &\quad + \mathrm{Cov}((ga)_{ij}, (ga)_{ij'}). \end{aligned} \tag{11}$$

Pelas hipóteses do modelo,

$$\begin{aligned} \mathrm{Cov}(g_i, (ga)_{ij'}) &= 0, \\ \mathrm{Cov}((ga)_{ij}, g_i) &= 0, \\ \mathrm{Cov}((ga)_{ij}, (ga)_{ij'}) &= 0. \end{aligned} \tag{12}$$

Logo, $\mathrm{Cov}(u_{ij}, u_{ij'}) = \sigma_g^2$. Portanto, claro, fora da diagonal entra σ_g^2.

Exemplo com três ambientes ($J = 3$)

$$\mathbf{G} = \begin{pmatrix} \mathrm{Var}(u_{i1}) & \mathrm{Cov}(u_{i1}, u_{i2}) & \mathrm{Cov}(u_{i1}, u_{i3}) \\ \mathrm{Cov}(u_{i2}, u_{i1}) & \mathrm{Var}(u_{i2}) & \mathrm{Cov}(u_{i2}, u_{i3}) \\ \mathrm{Cov}(u_{i3}, u_{i1}) & \mathrm{Cov}(u_{i3}, u_{i2}) & \mathrm{Var}(u_{i3}) \end{pmatrix}, \tag{13}$$

o que resulta em

$$\mathbf{G} = \begin{pmatrix} \sigma_g^2 + \sigma_{ga}^2 & \sigma_g^2 & \sigma_g^2 \\ \sigma_g^2 & \sigma_g^2 + \sigma_{ga}^2 & \sigma_g^2 \\ \sigma_g^2 & \sigma_g^2 & \sigma_g^2 + \sigma_{ga}^2 \end{pmatrix}. \tag{14}$$

Assim, a diagonal contém $\sigma_g^2 + \sigma_{ga}^2$, enquanto os elementos fora da diagonal contêm apenas σ_g^2, refletindo que a covariância entre ambientes vem exclusivamente do componente genético comum.

• **Portanto, a matriz resultante pode ser escrita como**

$$\mathbf{G} = \sigma_{ga}^2 \mathbf{I}_J + \sigma_g^2 \mathbf{J}_J, \tag{15}$$

o que corresponde exatamente à estrutura de simetria composta (CS), em que σ_g^2 representa a covariância comum entre ambientes e σ_{ga}^2 a variação específica de cada ambiente.

Nota: Material assistido pelo ChatGPT 5.3 e 5.4, Claude Sonnet 4.6 e Overleaf.