Biometria da Interação Genótipos $\times$ Ambientes (G$\times$A)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

29 de abril de 2026

Roteiro da aula 8: WAASB, WAASBY e índices BLUP-based

1 Introdução

Esta aula foi ministrada pelo Prof. Tiago Olivoto, da Universidade Federal de Santa Catarina (UFSC), com foco nos índices WAASB e WAASBY aplicados à análise da interação genótipos $\times$ ambientes. Na sequência da disciplina, a aula se conecta aos modelos mistos multiambiente discutidos nas aulas anteriores, pois utiliza predições via BLUP para descrever a interação G$\times$A e construir critérios de estabilidade, adaptabilidade e produtividade.

O objetivo da aula é mostrar como a interação pode ser quantificada a partir da matriz de efeitos genótipos $\times$ ambientes obtida por modelo misto. Em vez de trabalhar apenas com médias observadas, como em parte dos métodos clássicos, a abordagem usa valores preditos e combina a lógica dos modelos mistos com a decomposição por componentes principais. Assim, aproxima-se a interpretação gráfica do AMMI com a estrutura preditiva do BLUP.

Além de WAASB e WAASBY, esta síntese inclui os índices MHVG, PRVG e MHPRVG, também usados no contexto REML/BLUP para seleção simultânea de produtividade, estabilidade e adaptabilidade. No pacote `metan`, esses índices aparecem com a nomenclatura em inglês: HMGV para MHVG, RPGV para PRVG e HMRPGV para MHPRVG. Conceitualmente, MHVG usa a média harmônica dos valores genotípicos para penalizar genótipos com desempenho irregular; PRVG expressa o desempenho genotípico relativo à média de cada ambiente; e MHPRVG aplica a média harmônica sobre essas performances relativas, combinando estabilidade, adaptabilidade e produtividade em um único critério.

2 Da interação G$\times$A à matriz de efeitos

A interação genótipos $\times$ ambientes pode ser representada como o desvio da resposta observada em relação aos efeitos principais de genótipos e ambientes. Em termos médios, a interação pode ser descrita por

$$\widehat{ge}_{ij} = \bar{Y}_{ij} - \bar{Y}_{i.} - \bar{Y}_{.j} + \bar{Y}_{..}.$$

Essa decomposição separa a parte aditiva da resposta média da parte associada à mudança relativa do comportamento dos genótipos entre ambientes. Em experimentos multiambiente, essa matriz de interação é a base para métodos como AMMI, GGE e, no contexto desta aula, WAASB.

No WAASB, a matriz usada não precisa ser apenas a matriz de desvios baseada em médias observadas. A proposta é utilizar a matriz dos efeitos da interação preditos por modelo misto, isto é, a matriz de BLUPs para os efeitos genótipos $\times$ ambientes. Assim, a análise passa a combinar duas ideias: predição via modelo misto e decomposição da matriz de interação por SVD.

3 AMMI, BLUP e decomposição por SVD

O AMMI tradicional decompõe a interação G×A usando componentes principais. A matriz de interação é escrita como uma soma de termos multiplicativos, associando escores de genótipos, escores de ambientes e valores singulares. Essa estrutura permite interpretar padrões de interação e construir biplots.

A limitação prática é que o AMMI clássico depende de uma estrutura baseada em médias, tende a lidar pior com dados desbalanceados e não incorpora diretamente a natureza aleatória dos efeitos genotípicos. Os modelos mistos, por outro lado, fornecem BLUPs para os efeitos genotípicos e para a interação, com maior adequação a dados desbalanceados e maior coerência quando genótipos são tratados como efeitos aleatórios.

A proposta do WAASB é usar a matriz dos BLUPs da interação e aplicar a decomposição por valores singulares:

$$\mathbf{B} = \mathbf{U}\mathbf{\Lambda}\mathbf{V}'.$$

Nessa expressão, $\mathbf{B}$ representa a matriz de efeitos preditos da interação G×A, $\mathbf{U}$ contém os autovetores associados aos genótipos, $\mathbf{V}$ contém os autovetores associados aos ambientes, e $\mathbf{\Lambda}$ contém os valores singulares. Essa decomposição permite obter escores de genótipos e ambientes, mantendo a interpretação gráfica típica dos modelos multiplicativos.

4 Índice WAASB

WAASB significa *Weighted Average of Absolute Scores from the singular value decomposition of the matrix of BLUPs*. O índice quantifica a estabilidade genotípica com base na média ponderada dos escores absolutos dos genótipos nos componentes principais da interação.

De forma geral, para o genótipo i,

$$WAASB_i = \frac{\sum_{k=1}^{p} |PC_{ik}| \times EP_k}{\sum_{k=1}^{p} EP_k},$$

em que PC_{ik} é o escore do genótipo i no componente principal k, e EP_k é a proporção da interação explicada por esse componente. Como o índice usa valores absolutos dos escores, valores menores de WAASB indicam menor participação do genótipo na interação e, portanto, maior estabilidade.

A interpretação é direta: genótipos com baixo WAASB são mais estáveis; genótipos com alto WAASB são mais responsivos ou mais instáveis, dependendo do contexto. No entanto, WAASB sozinho não mede produtividade. Por isso, ele deve ser interpretado junto com a média ou combinado com ela por meio do WAASBY.

5 Produtividade, estabilidade e interpretação por quadrantes

A relação entre produtividade média e WAASB pode ser visualizada em um gráfico de dispersão. No eixo horizontal, coloca-se a produtividade média; no eixo vertical, o WAASB. Essa representação permite classificar genótipos em quatro grupos principais.

Genótipos com alta produtividade e baixo WAASB são desejáveis para recomendação ampla, pois combinam desempenho médio elevado e estabilidade. Genótipos com alta produtividade e alto WAASB podem ser interessantes para adaptação específica, pois apresentam desempenho superior em parte dos ambientes, mas maior contribuição para a interação. Genótipos com baixa produtividade e baixo WAASB são estáveis, mas pouco interessantes do ponto de vista produtivo. Genótipos com baixa produtividade e alto WAASB tendem a ser menos desejáveis para seleção direta.

Esse gráfico substitui, em parte, a leitura do AMMI1 quando o objetivo é interpretar simultaneamente produtividade e estabilidade a partir de uma abordagem com modelos mistos.

6 Índice WAASBY

O WAASBY combina produtividade e estabilidade em um único critério. Para isso, a produtividade média e o WAASB são reescalonados para o intervalo de 0 a 100. Em seguida, os dois componentes são combinados por pesos definidos pelo usuário.

A forma geral é

$$WAASBY_i = \frac{rY_i \times \theta_Y + rW_i \times \theta_W}{\theta_Y + \theta_W},$$

em que rY_i representa a produtividade reescalonada do genótipo i, rW_i representa a estabilidade reescalonada com base no WAASB, θ_Y é o peso atribuído à produtividade e θ_W é o peso atribuído à estabilidade.

Quando $\theta_Y = \theta_W$, produtividade e estabilidade recebem o mesmo peso. Quando θ_Y é maior, o índice favorece produtividade. Quando θ_W é maior, o índice favorece estabilidade. Portanto, o WAASBY permite ajustar o ranking de genótipos conforme o objetivo do programa de melhoramento.

7 MHVG, PRVG e MHPRVG

Os índices MHVG, PRVG e MHPRVG são critérios baseados em valores genotípicos preditos e foram propostos para interpretação da produtividade, estabilidade e adaptabilidade no contexto de modelos mistos. No pacote `metan`, as siglas equivalentes são HMGV, RPGV e HMRPGV, respectivamente.

A base desses índices é o valor genotípico predito do genótipo i no ambiente j, representado por GV_{ij}. Em um modelo multiambiente simples, esse valor pode ser interpretado como

$$GV_{ij} = \hat{\mu}_j + \hat{g}_i + \widehat{ge}_{ij},$$

em que $\hat{\mu}_j$ é o efeito médio do ambiente j, $\hat{g}_i$ é o efeito genotípico predito e $\widehat{ge}_{ij}$ é o efeito predito da interação genótipos $\times$ ambientes.

7.1 MHVG

A MHVG, ou média harmônica dos valores genotípicos, é dada por

$$MHVG_i = \frac{E}{\sum_{j=1}^{E} \frac{1}{GV_{ij}}}.$$

A média harmônica penaliza valores baixos. Portanto, um genótipo que apresenta desempenho muito baixo em um ambiente terá seu índice reduzido, mesmo que apresente bom desempenho em outros ambientes. Por isso, a MHVG combina produtividade e estabilidade, favorecendo genótipos com valores genotípicos altos e consistentes entre ambientes.

7.2 PRVG

A PRVG, ou performance relativa dos valores genotípicos, compara o valor genotípico de cada genótipo com a média do ambiente correspondente. Pode ser escrita como

$$PRVG_i = \frac{1}{E} \sum_{j=1}^{E} \frac{GV_{ij}}{\mu_j},$$

em que μ_j é a média do ambiente j. Valores de PRVG acima de 1 indicam desempenho médio superior à média dos ambientes avaliados. Por expressar o desempenho em escala relativa, a PRVG é interpretada como medida de adaptabilidade, pois avalia a capacidade do genótipo de manter desempenho proporcionalmente superior nos diferentes ambientes.

7.3 MHPRVG

A MHPRVG, ou média harmônica da performance relativa dos valores genotípicos, é dada por

$$MHPRVG_i = \frac{E}{\sum_{j=1}^{E} \frac{1}{GV_{ij}/\mu_j}}.$$

Esse índice aplica a média harmônica sobre os desempenhos relativos. Assim, combina a interpretação relativa da PRVG com a penalização por instabilidade da MHVG. Genótipos com alta MHPRVG apresentam desempenho relativo alto e consistente entre ambientes.

Na prática, a MHPRVG é um critério de seleção simultânea para produtividade, estabilidade e adaptabilidade. Quando multiplicada pela média geral, pode ser expressa na escala da variável original, facilitando a interpretação em termos de valor genotípico esperado já penalizado pela instabilidade e capitalizado pela adaptabilidade.

8 Comparação entre os índices

WAASB, WAASBY, MHVG, PRVG e MHPRVG pertencem à mesma família conceitual de análise baseada em valores preditos, mas respondem a perguntas diferentes.

O WAASB mede a contribuição do genótipo para a interação G×A, usando a decomposição da matriz de BLUPs da interação. Seu foco é estabilidade estrutural. O WAASBY combina WAASB e produtividade média em um índice ponderado, permitindo construir rankings conforme o peso atribuído a desempenho e estabilidade.

A MHVG mede estabilidade produtiva com base na média harmônica dos valores genotípicos. A PRVG mede adaptabilidade por desempenho relativo à média dos ambientes. A MHPRVG combina essas duas dimensões, pois aplica a média harmônica sobre o desempenho relativo.

Assim, os índices podem ser organizados da seguinte forma:

Índice	Base principal	Interpretação
WAASB	Escores absolutos da SVD dos BLUPs G×A	Estabilidade
WAASBY	WAASB + produtividade reescalonada	Produtividade + estabilidade
MHVG	Média harmônica dos valores genotípicos	Produtividade + estabilidade
PRVG	Valores genotípicos relativos à média ambiental	Adaptabilidade
MHPRVG	Média harmônica das performances relativas	Produtividade + estabilidade + adaptabilidade

9 Atividade

A atividade deve ser realizada com o arquivo `soy_MET.txt`. O objetivo é simular uma situação de desbalanceamento em dados multiambiente, ajustar um modelo misto com estrutura genética entre ambientes do tipo não estruturada, usar predições BLUP para reconstruir sinteticamente a matriz dupla entrada G×A, e aplicar os índices discutidos nesta aula.

Primeiro, os estudantes devem carregar os dados e remover alguns genótipos de alguns ambientes. A remoção deve ser reprodutível, usando como semente o dia e o mês do próprio aniversário, no formato `ddmm`. Por exemplo, uma pessoa nascida em 7 de maio usaria `set.seed(0705)`.

Em seguida, deve-se ajustar, com `lme4`, um modelo com ambientes como efeitos fixos, blocos dentro de ambiente como efeito aleatório e genótipos com resposta aleatória específica por ambiente. Em `lme4`, a estrutura `(0 + env | gen)` estima uma matriz de variâncias e covariâncias entre os efeitos genotípicos específicos de ambiente, funcionando como uma estrutura do tipo US para os efeitos genotípicos entre ambientes.

Após o ajuste, os estudantes devem predizer todas as combinações genótipos × ambientes, inclusive aquelas removidas artificialmente. Com isso, será produzida uma matriz G×A sintética balanceada, formada por valores preditos. Essa matriz deve ser usada para obter e comparar os índices WAASB, WAASBY, MHVG, PRVG e MHPRVG no pacote `metan`. A comparação final deve discutir se os rankings por produtividade, estabilidade e adaptabilidade selecionam os mesmos genótipos ou se há mudanças relevantes conforme o critério usado.

O código abaixo fornece apenas a estrutura da atividade. Ele não resolve a análise; os estudantes devem completar os pontos indicados, conferir os nomes das colunas do arquivo e interpretar os resultados.

```r
# Load packages
library(lme4); library(metan)
library(dplyr); library(tidyr)


# Load and prepare data
dat <- read.table("soy_MET.txt", header = TRUE) %>%
  mutate(across(c(env, gen, rep), factor))

# Use your birthday as seed: ddmm
set.seed(DDMM)

# Create artificial imbalance
cells_to_drop <- dat %>%
  distinct(gen, env) %>%
  sample_frac(0.15)

dat_unbal <- dat %>%
  anti_join(cells_to_drop, by = c("gen", "env"))

# Fit US-like model in lme4
mod_us <- lmer(
  y ~ env + (1 | env:rep) + (0 + env | gen),
  data = dat_unbal,
  REML = TRUE)

# Predict all genotype-environment combinations
pred_grid <- expand.grid(
  gen = levels(dat$gen),
  env = levels(dat$env),
  rep = levels(dat$rep)[1])

pred_grid$y_blup <- predict(
  mod_us,
  newdata = pred_grid,
  re.form = ~(0 + env | gen))

# Synthetic balanced GxE table
gxe_pred <- pred_grid %>%
  select(env, gen, y_blup) %>%
  mutate(rep = "BLUP")

# Run WAASB/WAASBY and BLUP-based indexes
waasb_model <- waasb(...)
waasby_tab  <- wsmp(waasb_model, ...)

blup_tab <- blup_indexes(...)

# Compare rankings
# rank_table <- ...
```

Referências

Almeida Filho, J. E., Tardin, F. D., Daher, R. F., Silva, K. J., Xavier Neto, J. B., Bastos, E. A., Lopes, V. S., Barbé, T. C., & Menezes, C. B. (2014). Genetic evaluation of grain sorghum hybrids in Brazilian environments using the REML/BLUP procedure. *Scientia Agricola*, 71(2), 146–150.

Colombari Filho, J. M., Resende, M. D. V. de, Morais, O. P. de, Castro, A. P. de, Guimarães, E. P., Pereira, J. A., Utumi, M. M., & Breseghello, F. (2013). Upland rice breeding in Brazil: A simultaneous genotypic evaluation of stability, adaptability and grain yield. *Euphytica*, 192, 117–129.

Olivoto, T., Lúcio, A. D. C., Silva, J. A. G. da, Marchioro, V. S., Souza, V. Q. de, & Jost, E. (2019). Mean performance and stability in multi-environment trials I: Combining features of AMMI and BLUP techniques. *Agronomy Journal*, 111(6), 2949–2960.

Olivoto, T., Lúcio, A. D. C., Silva, J. A. G. da, Sari, B. G., & Diel, M. I. (2019). Mean performance and stability in multi-environment trials II: Selection based on multiple traits. *Agronomy Journal*, 111(6), 2961–2969.

Olivoto, T., & Lúcio, A. D. C. (2020). *metan*: An R package for multi-environment trial analysis. *Methods in Ecology and Evolution*, 11(6), 783–789.

Oliveira, R. A. de, Resende, M. D. V. de, Daros, E., Bespalhok Filho, J. C., Zambon, J. L. C., Ido, O. T., Weber, H., Koehler, H. S., & Zeni Neto, H. (2005). Genotypic evaluation and selection of sugarcane clones in three environments in the state of Paraná. *Crop Breeding and Applied Biotechnology*, 5, 426–434.

Resende, M. D. V. de. (2007). *Matemática e estatística na análise de experimentos e no melhoramento genético*. Colombo: Embrapa Florestas.

Nota: Material assistido pelo ChatGPT 5.3 e 5.4, Claude Sonnet 4.6 e Overleaf.