

Biometria da Interação Genótipos $\times$ Ambientes ($G \times A$)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

6 de maio de 2026

Roteiro da aula 9: Modelos Mistos IV – Regressão Aleatória e Normas de Reação

1 Introdução

Nas aulas anteriores, a interação genótipos $\times$ ambientes foi tratada por diferentes ângulos. Rapidamente recapitulando: a ANOVA conjunta decompôs a variação fenotípica em efeitos de genótipos, ambientes e interação $G \times A$; a regressão conjunta de Finlay–Wilkinson e Eberhart–Russell descreveu adaptabilidade e estabilidade por meio da resposta linear ao índice ambiental; os modelos mistos introduziram REML/BLUP, efeitos aleatórios, componentes de variância e estruturas de variância-covariância entre ambientes. Nesta aula, esses conceitos se conectam em uma formulação única: a regressão aleatória para $G \times A$.

Em vez de tratar a resposta genotípica ao ambiente como uma regressão ajustada separadamente para cada genótipo, colocamos essa regressão dentro do modelo misto, especificamente na matriz $\mathbf{Z}$ de efeitos aleatórios. Cada genótipo passa então a ter seus próprios coeficientes aleatórios de intercepto e inclinação: o intercepto descreve o desempenho genotípico no ambiente médio; a inclinação descreve a sensibilidade ao gradiente ambiental.

Nesta aula, o gradiente ambiental será definido exclusivamente pela média fenotípica do ambiente. Não serão usadas covariáveis climáticas, edáficas, geográficas ou ambientais externas — esses temas pertencem às aulas posteriores de SIG, estratificação, ambientipagem e ambientômica. Aqui, o ambiente é resumido por um índice fenotípico interno ao próprio MET (*Multiple Environmental Trial*).

2 Da regressão de Finlay–Wilkinson à regressão aleatória

Vamos voltar rapidinho à regressão de Finlay–Wilkinson. A ideia, já vista anteriormente, é representar o desempenho médio de cada genótipo como função de um índice ambiental. Esse índice resume o nível produtivo de cada ambiente e permite descrever como os genótipos respondem quando passamos de ambientes menos favoráveis para ambientes mais favoráveis.

Em sua forma conceitual, o modelo pode ser escrito como:

$$\bar{y}_{ij} = \mu_i + \beta_i I_j + \varepsilon_{ij}, \quad (1)$$

em que $\bar{y}_{ij}$ é o desempenho médio do genótipo i no ambiente j , μ_i é o desempenho médio do genótipo, β_i é a inclinação de resposta ao índice ambiental, I_j é o índice ambiental e ε_{ij} é o desvio associado à média observada.

Na leitura biométrica clássica, μ_i descreve o nível médio do genótipo, enquanto β_i descreve sua sensibilidade ao gradiente ambiental. Genótipos com β_i próximo de 1 apresentam resposta média ao gradiente; com $\beta_i > 1$, respondem mais em ambientes favoráveis; com $\beta_i < 1$, apresentam menor sensibilidade. Portanto, a inclinação é uma medida de adaptabilidade. Eberhart–Russell estende essa ideia ao incluir os desvios da regressão como medida de estabilidade, mas esse acoplamento não será feito agora. Primeiro, entendemos a lógica da reta genotípica e do índice ambiental; depois, colocamos essa reta dentro da matriz $\mathbf{Z}$.

Finlay–Wilkinson transforma a interação $G \times A$ em uma pergunta sobre retas. Cada genótipo tem uma reta própria: o intercepto indica seu nível; a inclinação indica sua resposta ao gradiente. A regressão aleatória mantém essa ideia, mas muda o modo de estimação — em vez de ajustar uma reta separada para cada genótipo, os coeficientes dessas retas entram dentro de um modelo misto.

2.1 Construção do índice ambiental

O índice ambiental será definido a partir da média fenotípica de cada ambiente. Para o ambiente j , considere:

$$\bar{y}_{.j} = \frac{1}{n_j} \sum_{i=1}^m \sum_{k=1}^{r_{ij}} y_{ijk}, \quad (2)$$

em que $\bar{y}_{.j}$ é a média fenotípica do ambiente j , n_j é o número de observações no ambiente j , m é o número de genótipos e r_{ij} é o número de observações do genótipo i no ambiente j . Em dados balanceados, r_{ij} é constante; em dados desbalanceados, r_{ij} pode variar.

A média geral do conjunto de dados é:

$$\bar{y}_{..} = \frac{1}{N} \sum_{j=1}^J \sum_{i=1}^m \sum_{k=1}^{r_{ij}} y_{ijk}, \quad (3)$$

em que N é o número total de observações. A partir dessas médias, o índice ambiental centralizado é:

$$I_j = \bar{y}_{.j} - \bar{y}_{..} \quad (4)$$

Com essa centralização, ambientes com $I_j < 0$ estão abaixo da média geral, ambientes com $I_j > 0$ estão acima, e o ambiente médio fica em $I_j = 0$. Isso melhora a interpretação do intercepto: quando o índice é zero, a regressão está sendo avaliada no ambiente médio. Também podemos usar o índice padronizado:

$$x_j = \frac{\bar{y}_{.j} - \bar{y}_{..}}{s_{\bar{y}_{.j}}}, \quad (5)$$

em que $s_{\bar{y}_{.j}}$ é o desvio-padrão das médias ambientais. Nesse caso, uma unidade em x_j corresponde a um desvio-padrão no gradiente de produtividade ambiental. Daqui em diante, usaremos x_j para representar o índice ambiental centralizado ou padronizado:

$x_j < 0$: ambiente abaixo da média; $x_j = 0$: ambiente médio; $x_j > 0$: ambiente acima da média.

Esse índice é fenotípico — ele não representa temperatura, chuva, altitude, solo ou qualquer covariável ambiental externa. Ele resume o nível produtivo observado de cada ambiente no MET. Com esse índice, a regressão de Finlay–Wilkinson pode ser reescrita como:

$$\bar{y}_{ij} = \mu_i + \beta_i x_j + \varepsilon_{ij}. \quad (6)$$

Quando $x_j = 0$, temos $\bar{y}_{ij} = \mu_i + \varepsilon_{ij}$, de modo que μ_i é o nível esperado do genótipo i no ambiente médio e β_i é a sensibilidade ao gradiente.

2.2 Revisitando a teoria básica dos modelos mistos

Agora, segure um pouco com os conceitos de índice ambiental, e vamos recordar os modelos mistos. A resposta observada é representada como:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{g} + \mathbf{e}, \quad (7)$$

em que $\mathbf{y}$ é o vetor de observações, $\mathbf{X}$ é a matriz de incidência dos efeitos fixos, $\boldsymbol{\beta}$ é o vetor de efeitos fixos, $\mathbf{Z}$ é a matriz de incidência dos efeitos aleatórios, $\mathbf{g}$ é o vetor de efeitos aleatórios e $\mathbf{e}$ é o vetor de resíduos.

No modelo misto convencional com genótipos aleatórios, $\mathbf{g}$ contém um único efeito aleatório para cada genótipo:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}_g\mathbf{g} + \mathbf{e}, \quad \mathbf{g} = \begin{bmatrix} g_1 \\ g_2 \\ \vdots \\ g_m \end{bmatrix}, \quad \mathbf{g} \sim N(\mathbf{0}, \sigma_g^2 \mathbf{I}_m). \quad (8)$$

O BLUP de cada genótipo é um desvio genotípico médio — um intercepto aleatório. O genótipo pode ter desempenho médio maior ou menor, mas sua resposta ao gradiente ambiental não muda, porque o modelo não inclui inclinação genotípica.

Para visualizar isso, considere três genótipos (G_1, G_2, G_3) avaliados em três ambientes (E_1, E_2, E_3), com uma observação por combinação e observações ordenadas por genótipo:

$$\mathbf{y} = \begin{bmatrix} y_{11} \\ y_{12} \\ y_{13} \\ y_{21} \\ y_{22} \\ y_{23} \\ y_{31} \\ y_{32} \\ y_{33} \end{bmatrix}, \quad \mathbf{Z}_g = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{g} = \begin{bmatrix} g_1 \\ g_2 \\ g_3 \end{bmatrix}, \quad \mathbf{Z}_g\mathbf{g} = \begin{bmatrix} g_1 \\ g_1 \\ g_1 \\ g_2 \\ g_2 \\ g_2 \\ g_3 \\ g_3 \\ g_3 \end{bmatrix}. \quad (9)$$

Observe: G_1 recebe o mesmo efeito g_1 nos três ambientes; idem para G_2 e G_3 . O BLUP é um deslocamento médio — não há inclinação genotípica. Para obtê-la, precisamos mudar a estrutura de $\mathbf{Z}$. No modelo convencional, $\mathbf{Z}_g$ apenas identifica qual genótipo está em cada linha. Na regressão aleatória, a nova matriz $\mathbf{Z}_u$ continuará identificando o genótipo, mas também carregará o valor do índice ambiental associado àquela observação.

2.2.1 A matriz $\mathbf{Z}$ na regressão aleatória

No modelo clássico de Finlay–Wilkinson, cada genótipo tem seus próprios μ_i e β_i . Ajusta-se uma reta para cada genótipo usando as médias genotípicas nos ambientes:

$$\hat{y}_{ij} = \hat{\mu}_i + \hat{\beta}_i x_j. \quad (10)$$

Essa formulação é didática, mas tem limitações: os coeficientes são ajustados separadamente, sem tomar emprestada força de outros genótipos. Em redes MET reais com desbalanceamento, isso pode afetar a qualidade das estimativas.

Retomando o exemplo com $x_1 = -1$, $x_2 = 0$, $x_3 = 1$, na regressão aleatória cada genótipo possui dois coeficientes aleatórios — intercepto e inclinação:

$$\mathbf{u}_i = \begin{bmatrix} u_{0i} \\ u_{1i} \end{bmatrix}, \quad g_i(x_j) = u_{0i} + u_{1i}x_j, \quad \mathbf{u} = \begin{bmatrix} u_{01} \\ u_{11} \\ u_{02} \\ u_{12} \\ u_{03} \\ u_{13} \end{bmatrix}. \quad (11)$$

Aqui, u_{0i} é o intercepto aleatório e u_{1i} é a inclinação aleatória. Para os três genótipos do exemplo, os dois primeiros elementos de $\mathbf{u}$ pertencem a G_1 , os dois seguintes a G_2 , e os dois últimos a G_3 . A matriz $\mathbf{Z}_u$ é construída para combinar cada observação com o intercepto e a inclinação do seu genótipo:

$$\mathbf{Z}_u = \begin{bmatrix} 1 & -1 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & -1 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 \end{bmatrix}, \quad \mathbf{u} = \begin{bmatrix} u_{01} \\ u_{11} \\ u_{02} \\ u_{12} \\ u_{03} \\ u_{13} \end{bmatrix}. \quad (12)$$

Para cada genótipo, há um bloco com duas colunas: a primeira é a coluna de incidência (gera o intercepto aleatório); a segunda contém x_j (gera a inclinação aleatória). A multiplicação $\mathbf{Z}_u \mathbf{u}$ resulta em:

$$\mathbf{Z}_u \mathbf{u} = \begin{bmatrix} u_{01} - u_{11} \\ u_{01} \\ u_{01} + u_{11} \\ u_{02} - u_{12} \\ u_{02} \\ u_{02} + u_{12} \\ u_{03} - u_{13} \\ u_{03} \\ u_{03} + u_{13} \end{bmatrix}. \quad (13)$$

Por exemplo, para G_1 :

$$g_1(x_1 = -1) = u_{01} - u_{11}, \quad g_1(x_2 = 0) = u_{01}, \quad g_1(x_3 = 1) = u_{01} + u_{11}. \quad (14)$$

Quando $x_j = 0$, o valor genotípico aleatório é o próprio intercepto:

$$g_i(0) = u_{0i}. \quad (15)$$

Se $u_{1i} > 0$, o genótipo aumenta seu valor em ambientes favoráveis. Se $u_{1i} < 0$, perde valor relativo. Se $u_{1i} \approx 0$, a resposta ao gradiente é pequena.

De forma geral, para uma observação do genótipo i no ambiente j , a linha de $\mathbf{Z}_u$ é:

$$\mathbf{z}_{ij} = \begin{bmatrix} 0 & 0 & \cdots & 0 & 0 & 1 & x_j & 0 & 0 & \cdots \\ 0 & 0 & & & & & & & & \end{bmatrix}, \quad (16)$$

onde o par $\begin{bmatrix} 1 & x_j \end{bmatrix}$ aparece apenas no bloco do genótipo observado. Quando as observações estão ordenadas por genótipo, $\mathbf{Z}_u$ tem estrutura de blocos diagonais:

$$\mathbf{Z}_u = \begin{bmatrix} \mathbf{W}_1 & \mathbf{0} & \cdots & \mathbf{0} \\ \mathbf{0} & \mathbf{W}_2 & \cdots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{0} & \mathbf{0} & \cdots & \mathbf{W}_m \end{bmatrix}, \quad \mathbf{W}_i = \begin{bmatrix} 1 & x_{j_1} \\ 1 & x_{j_2} \\ \vdots & \vdots \\ 1 & x_{j_{n_i}} \end{bmatrix}. \quad (17)$$

Se o genótipo foi avaliado em poucos ambientes, $\mathbf{W}_i$ terá poucas linhas; se foi avaliado em muitos, terá mais. O desbalanceamento entra naturalmente, e o modelo aplica shrinkage conforme a quantidade e qualidade da informação disponível para cada genótipo.

Com essa construção, a forma escalar do modelo misto de regressão aleatória é:

$$y_{ijk} = \mu + a_j + b_{k(j)} + u_{0i} + u_{1i}x_j + e_{ijk}, \quad (18)$$

em que μ é a média geral, a_j é o efeito fixo do ambiente, $b_{k(j)}$ é o efeito aleatório de bloco dentro de ambiente, u_{0i} é o intercepto aleatório do genótipo, u_{1i} é a inclinação aleatória e e_{ijk} é o erro aleatório. Em notação matricial:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}_b\mathbf{b} + \mathbf{Z}_u\mathbf{u} + \mathbf{e}. \quad (19)$$

A regressão aleatória não é uma regressão separada do modelo misto. Ela está dentro dele, especificamente na construção de $\mathbf{Z}_u$ e do vetor $\mathbf{u}$.

2.2.2 Matriz de variâncias e covariância dos coeficientes

Para cada genótipo i :

$$\mathbf{u}_i = \begin{bmatrix} u_{0i} \\ u_{1i} \end{bmatrix} \sim N\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \mathbf{G}_u\right), \quad \mathbf{G}_u = \begin{bmatrix} \sigma_{u0}^2 & \sigma_{u01} \\ \sigma_{u01} & \sigma_{u1}^2 \end{bmatrix}. \quad (20)$$

σ_{u0}^2 é a variância dos interceptos: mede quanto os genótipos diferem no ambiente médio. σ_{u1}^2 é a variância das inclinações: mede quanto diferem em sensibilidade ao gradiente. σ_{u01} é a covariância entre intercepto e inclinação, com correlação:

$$r_{u01} = \frac{\sigma_{u01}}{\sqrt{\sigma_{u0}^2 \sigma_{u1}^2}}. \quad (21)$$

Se $r_{u01} > 0$, genótipos superiores no ambiente médio tendem a ser mais responsivos. Se $r_{u01} < 0$, tendem a ser menos responsivos. Se $r_{u01} \approx 0$, desempenho médio e sensibilidade têm pouca associação linear.

Para todos os genótipos, o vetor completo de efeitos aleatórios distribui-se como:

$$\mathbf{u} = \begin{bmatrix} \mathbf{u}_1 \\ \mathbf{u}_2 \\ \vdots \\ \mathbf{u}_m \end{bmatrix}, \quad \mathbf{u} \sim N(\mathbf{0}, \mathbf{I}_m \otimes \mathbf{G}_u), \quad (22)$$

em que $\mathbf{I}_m$ é a identidade de ordem m e $\otimes$ é o produto de Kronecker. Todos os genótipos compartilham a mesma estrutura $\mathbf{G}_u$, mas cada um possui seus próprios BLUPs. Para três genótipos:

$$\mathbf{V}(\mathbf{u}) = \mathbf{I}_3 \otimes \mathbf{G}_u = \begin{bmatrix} \sigma_{u0}^2 & \sigma_{u01} & 0 & 0 & 0 & 0 \\ \sigma_{u01} & \sigma_{u1}^2 & 0 & 0 & 0 & 0 \\ 0 & 0 & \sigma_{u0}^2 & \sigma_{u01} & 0 & 0 \\ 0 & 0 & \sigma_{u01} & \sigma_{u1}^2 & 0 & 0 \\ 0 & 0 & 0 & 0 & \sigma_{u0}^2 & \sigma_{u01} \\ 0 & 0 & 0 & 0 & \sigma_{u01} & \sigma_{u1}^2 \end{bmatrix}. \quad (23)$$

Dentro de cada genótipo, intercepto e inclinação podem ser correlacionados; entre genótipos distintos, as covariâncias são zero neste exemplo simples. Se houver parentesco ou relação genômica entre genótipos, $\mathbf{I}_m$ pode ser substituída por uma matriz de relacionamento:

$$\mathbf{u} \sim N(\mathbf{0}, \mathbf{A} \otimes \mathbf{G}_u) \quad \text{ou} \quad \mathbf{u} \sim N(\mathbf{0}, \mathbf{G} \otimes \mathbf{G}_u). \quad (24)$$

Essa extensão não será desenvolvida nesta aula, mas a ideia é direta. A conclusão desta parte é que, no modelo misto convencional, o BLUP do genótipo é um único desvio — um intercepto aleatório. Na regressão aleatória, o BLUP é um par: intercepto e inclinação. Cada genótipo passa a ter sua própria reta de resposta ao índice ambiental, e essa reta é a sua norma de reação linear.

3 Interpretação dos componentes

A interpretação dos três componentes de $\mathbf{G}_u$ é direta, mas exige cuidado. Veja:

- σ_{u0}^2 indica quanto os genótipos diferem no ponto médio do gradiente. Quando maior, há maior separação genotípica no ambiente médio.
- σ_{u1}^2 indica quanto os genótipos diferem em sensibilidade ambiental. Próxima de zero, os genótipos têm inclinações semelhantes e a interação associada ao gradiente é pequena. Alta, há genótipos visivelmente mais ou menos responsivos.
- σ_{u01} indica se genótipos superiores no ambiente médio tendem a responder mais ou menos ao gradiente. Positiva, maior intercepto implica maior inclinação; negativa, o inverso; próxima de zero, desempenho médio e sensibilidade são quase independentes.

4 Variância genética e covariância entre ambientes ao longo do gradiente

Uma propriedade central da regressão aleatória é que a variância genética não precisa ser constante entre ambientes. Como o valor genotípico no ponto x_j é

$$g_i(x_j) = u_{0i} + u_{1i}x_j, \quad (25)$$

a variância genética nesse ponto é obtida diretamente de $\mathbf{G}_u$:

$$V\{g_i(x_j)\} = \sigma_{u0}^2 + 2x_j\sigma_{u01} + x_j^2\sigma_{u1}^2. \quad (26)$$

Essa equação mostra que, mesmo com normas de reação lineares, a variância genética ao longo do gradiente é uma função quadrática de x_j . Ela pode aumentar, diminuir ou apresentar curvatura, dependendo dos sinais e magnitudes de σ_{u0}^2 , σ_{u01} e σ_{u1}^2 .

A covariância genética entre dois ambientes j e j' também é induzida pelo gradiente. Para um mesmo genótipo:

$$\text{Cov}\{g_i(x_j), g_i(x_{j'})\} = \sigma_{u0}^2 + (x_j + x_{j'})\sigma_{u01} + x_jx_{j'}\sigma_{u1}^2. \quad (27)$$

Portanto, a regressão aleatória gera uma estrutura de covariância entre ambientes a partir da posição de cada ambiente no gradiente. Essa é a conexão com a Aula 7: antes, as estruturas CS, DIAG, UN, AR(1) e FA eram especificadas diretamente sobre os ambientes; agora, a covariância entre ambientes surge da função de resposta genotípica ao índice ambiental, com apenas três parâmetros — σ_{u0}^2 , σ_{u01} e σ_{u1}^2 — descrevendo toda a estrutura.

Uma nota sobre a variância residual

No modelo desta aula, a variância residual σ_e^2 é assumida homogênea entre ambientes. Essa é a hipótese padrão e a mais comum na literatura de regressão aleatória aplicada a $\mathbf{G} \times \mathbf{A}$.

Vale registrar, contudo, que ambientes com diferentes níveis produtivos tendem a apresentar variabilidades experimentais distintas. A possibilidade de que σ_e^2 também varie ao longo do gradiente ambiental é reconhecida na literatura de modelos mistos — onde resíduos heterogêneos por ambiente são tratados como parâmetros discretos, um por ambiente. Uma extensão natural seria modelar σ_e^2 como função contínua de x_j , de modo análogo ao que a regressão aleatória faz com a variância genética. Nesse caso, a herdabilidade também passaria a ser uma função contínua do gradiente:

$$h^2(x_j) = \frac{\sigma_g^2(x_j)}{\sigma_g^2(x_j) + \sigma_e^2(x_j)}. \quad (28)$$

5 Normas de reação

Uma norma de reação descreve o fenótipo esperado de um genótipo como função do ambiente. No contexto desta aula, a norma de reação é a curva predita por

$$\hat{g}_i(x) = \hat{u}_{0i} + \hat{u}_{1i}x. \quad (29)$$

Como o modelo é linear no índice ambiental, cada norma de reação é uma reta. Modelos com polinômios, splines ou bases de Legendre são extensões possíveis, mas não serão desenvolvidos nesta aula. O objetivo aqui é compreender a versão linear, que é a ponte mais direta entre Finlay–Wilkinson e os modelos mistos.

A interpretação gráfica é parte central da aula. O eixo horizontal representa o índice ambiental, indo de ambientes restritivos a favoráveis; o eixo vertical representa o desvio genotípico predito em torno da média. Cada linha representa um genótipo. Linhas paralelas indicam ausência de variação em sensibilidade. Linhas divergentes indicam que a diferença genética aumenta com a melhoria ambiental. Linhas convergentes indicam que ela diminui. Linhas cruzadas indicam interação complexa: o ordenamento dos genótipos muda ao longo do gradiente.

Padrão	Interpretação	Leitura biométrica
Intercepto alto e inclinação próxima de zero	Desempenho acima da média e pouca variação relativa ao gradiente	Candidato a adaptação ampla, sobretudo quando a estabilidade é desejável.
Intercepto alto e inclinação positiva	Desempenho bom no ambiente médio e resposta maior em ambientes favoráveis	Genótipo responsivo, com potencial para ambientes de maior produtividade.
Intercepto médio e inclinação alta	Desempenho intermediário no ambiente médio, mas forte resposta ao gradiente	Candidato a adaptação específica a ambientes favoráveis.
Intercepto alto e inclinação negativa	Bom desempenho em ambientes restritivos, com perda relativa em ambientes favoráveis	Candidato a ambientes de menor potencial produtivo.
Intercepto baixo e inclinação baixa	Desempenho inferior e pouca resposta ao gradiente	Geralmente pouco atrativo, salvo em contextos específicos de seleção.

6 Tipos de resposta genotípica

A regressão aleatória permite classificar genótipos pela combinação entre intercepto e inclinação. Essa classificação deve ser vista como interpretação biométrica, não como índice automático de recomendação.

Essa leitura deve sempre ser associada à incerteza das predições. Dois genótipos podem ter linhas visualmente diferentes, mas as diferenças podem não ser bem sustentadas pelos dados se houver poucos ambientes, baixa repetição, desbalanceamento ou alta variância residual.

7 Predição em ambientes intermediários e extrapolação

Uma vantagem conceitual da regressão aleatória é descrever a tendência genotípica em pontos intermediários do gradiente. Se os ambientes observados cobrem uma faixa de x , é possível visualizar a curva genotípica em valores entre o menor e o maior índice observado. Esse uso é melhor entendido como interpolação dentro da faixa amostrada.

A extrapolação fora da faixa observada deve ser tratada com cautela. O modelo linear gera previsões matematicamente simples, mas a validade biométrica dessas previsões depende de o gradiente ambiental continuar representando o mesmo processo biológico. Fora da faixa dos dados, a inclinação estimada pode não descrever a resposta real dos genótipos.

Essa distinção prepara a próxima aula, na qual a predição em ambientes não observados, a imputação da tabela $G \times A$ e a estratificação ambiental serão discutidas de forma própria.

8 Cuidados na interpretação

A regressão aleatória é sensível à definição do índice ambiental. Como esse índice é derivado da própria resposta fenotípica, ele não deve ser interpretado como causa ambiental específica. Uma inclinação alta não significa necessariamente resposta a temperatura, chuva ou manejo; significa resposta ao gradiente fenotípico definido pelas médias dos ambientes no MET.

Outro ponto é a separação entre efeito de ambiente e índice ambiental. No modelo, o ambiente entra como efeito fixo para controlar diferenças médias entre ambientes, enquanto x_j entra como covariável associada à inclinação aleatória dos genótipos. Isso evita confundir a média ambiental com a resposta genotípica diferencial.

Também é necessário observar a escala do índice. Se centralizado, o intercepto é interpretado no ambiente médio. Se padronizado, a inclinação fica em escala comparável entre análises. Se não centralizado, a covariância entre intercepto e inclinação pode ficar difícil de interpretar.

9 Síntese da aula

A regressão aleatória é a generalização mista da regressão conjunta. Ela mantém a ideia de um gradiente ambiental, mas trata interceptos e inclinações genotípicas como efeitos aleatórios. Com isso, permite estimar componentes de variância associados ao desempenho no ambiente médio, à sensibilidade ambiental e à associação entre desempenho médio e responsividade.

As normas de reação são a representação gráfica desse modelo. Cada genótipo passa a ser descrito por uma reta de resposta ao ambiente. Quando essas retas têm inclinações diferentes, há interação $G \times A$ associada ao gradiente. Quando há cruzamento entre retas, a interação é complexa e afeta a recomendação genotípica. A variância genética, por sua vez, não é constante ao longo do gradiente — ela é uma função quadrática de x_j , emergindo analiticamente dos três parâmetros de $\mathbf{G}_u$.

A mensagem final da aula é que a $G \times A$ pode ser vista como variação na forma da resposta genotípica ao ambiente. A regressão aleatória oferece uma forma de modelar essa variação dentro do arcabouço REML/BLUP, sem abandonar a interpretação biométrica da regressão conjunta.

10 Atividade

Considere o conjunto de dados abaixo, com quatro genótipos avaliados em cinco ambientes. O conjunto é propositalmente simples (para ser didático) e desbalanceado: $G01$ aparece nos cinco ambientes; $G02$, em quatro ambientes; $G03$, em dois ambientes; e $G04$, apenas no primeiro ambiente.

Genótipo	E1		E2		E3		E4		E5	
	Obs.	y	Obs.	y	Obs.	y	Obs.	y	Obs.	y
G01	1	42	1	51	1	59	1	67	1	74
G02	1	39	1	50	—	—	1	70	1	82
G03	—	—	1	47	—	—	—	—	1	69
G04	1	46	—	—	—	—	—	—	—	—

a) Organize os dados em formato longo, com as colunas `env`, `gen` e `y`. Em seguida, leia a tabela no R e calcule a média fenotípica de cada ambiente, $\bar{y}_{.j}$, a média geral, $\bar{y}_{..}$ e o índice ambiental centralizado $I_j = \bar{y}_{.j} - \bar{y}_{..}$. Se preferir, use o índice padronizado $x_j = (\bar{y}_{.j} - \bar{y}_{..})/s_{\bar{y}_{.j}}$. Apresente uma tabela com $\bar{y}_{.j}$, I_j e/ou x_j .

b) Antes de ajustar o modelo, escreva manualmente a matriz $\mathbf{Z}_u$ para os registros observados. Para cada observação do genótipo i no ambiente j , a linha correspondente de $\mathbf{Z}_u$ deve conter o bloco $[1 \ x_j]$ apenas nas colunas daquele genótipo, e zeros nas demais colunas. Use a ordem dos efeitos aleatórios $\mathbf{u} = (u_{01}, u_{11}, u_{02}, u_{12}, u_{03}, u_{13}, u_{04}, u_{14})'$.

c) Ajuste no lme4 o modelo de regressão aleatória $y_{ij} = \beta_0 + \beta_1 x_j + u_{0i} + u_{1i} x_j + e_{ij}$. Na fórmula do lme4, use o índice ambiental como efeito fixo e intercepto + inclinação como efeitos aleatórios de genótipo, isto é, uma estrutura do tipo `y ~ x + (1 + x | gen)`. Esse ajuste é didático: o conjunto é pequeno e desbalanceado, portanto os componentes de variância e os BLUPs devem ser interpretados como ilustração do método.

d) Extraia os BLUPs de intercepto e inclinação dos genótipos. Interprete a inclinação total de cada genótipo como $\hat{\beta}_1 + \hat{u}_{1i}$, e não apenas como $\hat{u}_{1i}$, pois $\hat{u}_{1i}$ é o desvio da inclinação do genótipo em relação à inclinação média da população.

e) Extraia a matriz de variâncias e covariância dos coeficientes aleatórios, $\mathbf{G}_u$. Interprete $\hat{\sigma}_{u0}^2$, $\hat{\sigma}_{u1}^2$, $\hat{\sigma}_{u01}$ e a correlação entre intercepto e inclinação. Discuta, em poucas linhas, se genótipos com maior desempenho no ambiente médio tendem a ser mais ou menos responsivos ao gradiente ambiental.

f) Obtenha a variância genética ao longo do gradiente ambiental usando $\hat{\sigma}_g^2(x_j) = \hat{\sigma}_{u0}^2 + 2x_j\hat{\sigma}_{u01} + x_j^2\hat{\sigma}_{u1}^2$. Faça uma tabela ou gráfico com $\hat{\sigma}_g^2(x_j)$ para os valores observados de x_j . Interprete se a variância genética aumenta, diminui ou apresenta curvatura ao longo do gradiente.

g) Construa um gráfico das normas de reação. O gráfico pode ser feito na escala do desvio genotípico, usando $\hat{g}_i(x) = \hat{u}_{0i} + \hat{u}_{1i}x$, ou na escala da resposta, usando $\hat{y}_i(x) = \hat{\beta}_0 + \hat{\beta}_1x + \hat{u}_{0i} + \hat{u}_{1i}x$. Interprete quais genótipos foram mais responsivos ao gradiente ambiental.

h) Comente o que ocorre com $G03$ e $G04$, que têm pouca informação para estimar suas próprias normas de reação. Explique por que $G04$, com apenas uma observação, não permite estimar uma inclinação própria por regressão clássica, mas ainda recebe uma predição de inclinação no modelo misto.

i) Suponha agora que esses quatro genótipos fossem aparentados. Por exemplo, $G04$ seria irmão completo de $G01$, e $G03$ seria irmão completo de $G02$. Como o ajuste deveria mudar? Discuta conceitualmente como a matriz identidade entre genótipos, $\mathbf{I}_m$, poderia ser substituída por uma matriz de relacionamento genético, $\mathbf{A}$, de modo que $V(\mathbf{u}) = \mathbf{A} \otimes \mathbf{G}_u$. O que você esperaria que acontecesse com os BLUPs de $G03$ e $G04$, que têm pouca informação própria, mas passariam a compartilhar informação com seus irmãos completos?

Referências

- Alves, R. S., Teodoro, P. E., Peixoto, L. A., Silva, L. A., Rodrigues, E. V., Resende, M. D. V., Laviola, B. G., & Bhering, L. L. (2020). Adaptability and stability analyses of plants using random regression models. *PLOS ONE*, 15(5), e0233200. <https://doi.org/10.1371/journal.pone.0233200>
- Eberhart, S. A., & Russell, W. A. (1966). Stability parameters for comparing varieties. *Crop Science*, 6(1), 36–40. <https://doi.org/10.2135/cropsci1966.0011183X000600010011x>
- Finlay, K. W., & Wilkinson, G. N. (1963). The analysis of adaptation in a plant-breeding programme. *Australian Journal of Agricultural Research*, 14(6), 742–754. <https://doi.org/10.1071/AR9630742>
- Kolmodin, R. (2003). *Reaction norms for the study of genotype by environment interaction in animal breeding*. Doctoral dissertation, Swedish University of Agricultural Sciences.
- Piepho, H.-P., & Blancon, J. (2023). Extending Finlay–Wilkinson regression with environmental covariates. *Plant Breeding*, 142(5), 621–631. <https://doi.org/10.1111/pbr.13130>
- Rebollo, I., Aguilar, I., Pérez de Vida, F., Molina, F., Gutiérrez, L., & Rosas, J. E. (2023). Genotype by environment interaction characterization and its modeling with random regression to climatic variables in two rice breeding populations. *Crop Science*, 63(4), 2220–2240. <https://doi.org/10.1002/csc2.21029>

Nota: Material assistido pelo ChatGPT 5.5, Claude Sonnet 4.6 e Overleaf.