

Biometria da Interação Genótipos $\times$ Ambientes ($G \times A$)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

13 de maio de 2026

Roteiro da Aula 10: Predição de Desempenho em Múltiplos Ambientes

1 Introdução

Redes de ensaios multiambiente (MET) raramente produzem matrizes $G \times A$ completas. Genótipos entram e saem de ciclos de avaliação, locais falham por questões climáticas ou logísticas, e recursos limitados impedem que todos os materiais sejam testados em todos os locais a cada ano. O resultado é uma matriz de dupla entrada com células faltantes. Em geral, o desbalanceamento é a regra, não a exceção. E tá tudo bem! Usando dados desbalanceados é possível avaliar um maior número de locais e experimentos. Ferramentas para lidar com isso são muitas! Eu avalio isso como “oportunidade”, e não um problema.

Diante disso, duas situações distintas demandam estratégias diferentes. A primeira é o desbalanceamento *interno* à rede: o genótipo foi avaliado em alguns ambientes, mas não em todos. A segunda é a predição para um *ambiente externo*, nunca observado (um novo local, um ano futuro, ou uma condição hipotética de cenário climático). Ambas situações compartilham a mesma estrutura formal: deseja-se estimar $\hat{y}_{ij}$ para combinações (i, j) onde y_{ij} não existe.

Esta aula trata dos fundamentos teóricos e das estratégias práticas para resolver esse problema. O ponto de partida é a escolha do *input* adequado para a imputação; em seguida, são apresentadas as três famílias de imputadores; por fim, discute-se como a matriz preenchida orienta as estratégias de seleção.

2 O Input para Imputação: BLUEs, BLUPs e Desregressão

Antes de escolher o método de imputação, é necessário definir *o que* será imputado. A escolha aparentemente trivial entre médias ajustadas (BLUEs) e valores genotípicos preditos (BLUPs) tem consequências diretas sobre a validade estatística das análises subsequentes.

2.1 O problema do duplo encolhimento

O BLUP é, por construção, um preditor com encolhimento (*shrinkage*): os valores genotípicos são contraídos em direção à média geral de acordo com a acurácia de cada observação. Formalmente, para o modelo univariado simples, o BLUP de um efeito genotípico g_i pode ser escrito como:

$$\hat{g}_i = r_i^2 \bar{y}_i^* \quad (1)$$

onde r_i^2 é a acurácia ao quadrado (confiabilidade) do preditor e $\bar{y}_i^*$ é a média corrigida para efeitos fixos. Essa contração é desejável para a seleção direta, pois reduz o risco de seleção de indivíduos com alta performance por acaso. Entretanto, se os BLUPs são usados como *variável resposta* em um segundo modelo — por exemplo, como input para um algoritmo de imputação que ajusta internamente um novo modelo misto — aplica-se encolhimento duas vezes sobre a mesma informação. Isso resulta em estimativas de variância subestimadas e métricas de acurácia infladas artificialmente. O problema é referido na literatura como “BLUP do BLUP”, e sua consequência mais prática é a superestimação da acurácia de seleção em análises de duas etapas.

2.2 Desregressão: recuperando a escala fenotípica

A solução canônica para o problema acima é a desregressão do BLUP (*deregression*), proposta por Garrick et al. (2009) no contexto de seleção genômica, mas com aplicabilidade direta a qualquer análise em dois estágios. A ideia é “desfazer” o encolhimento para recuperar um pseudo-fenótipo na escala original:

$$\hat{g}_i^{\text{dr}} = \frac{\hat{g}_i}{r_i^2} \quad (2)$$

O valor desregressado $\hat{g}_i^{\text{dr}}$ é então ponderado por um peso proporcional à sua confiabilidade, de forma que observações com alta acurácia contribuem mais para a análise subsequente. Trata-se, em essência, de tratar o BLUP desregressado como um fenótipo com herdabilidade efetiva variável entre indivíduos.

Na prática, a necessidade de desregressar depende do fluxo analítico. Se a imputação opera diretamente sobre médias fenotípicas por ambiente (BLUEs de ensaios individuais, sem componente de encolhimento genotípico), a desregressão é dispensável. O problema surge exclusivamente quando BLUPs genotípicos de um primeiro estágio são usados como resposta em um segundo modelo que também trata genótipos como efeitos aleatórios.

3 Estratégias de Imputação (ou Predição) da Matriz $G \times A$

Com o input corretamente definido, apresentam-se três famílias de imputadores organizadas por lógica operacional: decomposição matricial, modelos mistos e algoritmos de aprendizado de máquina.

3.1 Decomposição matricial: EM-AMMI e SVD iterativo

A família de métodos baseados em decomposição em valores singulares (SVD) parte do princípio de que a matriz $G \times A$ possui uma estrutura de baixo posto (*low-rank*): a variação da interação pode ser bem aproximada por poucos componentes multiplicativos, conforme capturado pelo modelo AMMI:

$$y_{ij} = \mu + \alpha_i + \beta_j + \sum_{k=1}^K \lambda_k \gamma_{ik} \delta_{jk} + \rho_{ij} + \varepsilon_{ij} \quad (3)$$

onde α_i e β_j são os efeitos aditivos de genótipo e ambiente, λ_k , γ_{ik} e δ_{jk} são os valores singulares e vetores do k -ésimo componente de interação, e ρ_{ij} é o resíduo de interação não explicado.

A premissa desses métodos é que a matriz $G \times A$ possui estrutura: genótipos com perfis de resposta similares *devem* comportar-se de forma parecida ao longo dos ambientes, e ambientes com condições análogas provocam respostas análogas nos genótipos. Essa redundância é o que torna a predição viável, conhecendo o perfil de um genótipo nos ambientes observados, é possível estimar seu desempenho no ambiente faltante, pois ele segue o mesmo padrão subjacente.

O algoritmo **EM-AMMI** (Paderewski, 2013) opera em duas etapas iterativas. Na etapa E (*Expectation*), as células faltantes são preenchidas com as estimativas atuais do modelo. Na etapa M (*Maximization*), o modelo AMMI completo é reajustado à matriz preenchida e os parâmetros são atualizados. O processo itera até que a diferença entre imputações sucessivas seja inferior a um limiar de convergência. A inicialização convencional usa os efeitos aditivos ($\hat{\mu} + \hat{\alpha}_i + \hat{\beta}_j$) como primeiro preenchimento.

O método **SVD iterativo de Yan** (2013) segue lógica análoga, mas opera diretamente na aproximação de posto reduzido da matriz de dupla entrada, sem a separação explícita entre efeitos aditivos e multiplicativos. A cada iteração, a SVD de posto k da matriz parcialmente observada é calculada, e as células faltantes são substituídas pelos valores correspondentes na aproximação $\mathbf{M}_k = \mathbf{U}_k \mathbf{D}_k \mathbf{V}_k^T$. O método é conceitualmente simples e diretamente integrado ao ambiente GGE biplot. Uma limitação relevante é sua sensibilidade a valores discrepantes (*outliers*), que podem distorcer os vetores singulares e comprometer a qualidade das imputações; extensões robustas da SVD foram propostas para contornar esse problema.

Ambos os métodos exploram a estrutura multiplicativa intrínseca da $G \times A$ e tendem a se sair bem quando essa estrutura é de fato dominante nos dados.

3.2 Modelos mistos como “imputadores” naturais

No framework de modelos mistos multiambiente, a predição de células não observadas é uma consequência direta do modelo ajustado, não uma etapa adicional. Para o modelo geral com efeitos genotípicos e de interação aleatórios:

$$\mathbf{y} = \mathbf{X}\boldsymbol{\tau} + \mathbf{Z}_g \mathbf{g} + \mathbf{Z}_{ga} \mathbf{ga} + \boldsymbol{\varepsilon} \quad (4)$$

a equação de predição do BLUP para uma célula não observada (i, j) é derivada das equações de modelo misto (MME) e depende integralmente da estrutura de (co)variância adotada para os efeitos aleatórios. O preditor $\hat{y}_{ij}$ para uma combinação não observada é obtido combinando a solução para efeitos fixos (efeito de ambiente) com os BLUPs genotípicos e de interação, ponderados pela covariância entre o ambiente faltante e os ambientes com dados.

A consequência direta é que **a qualidade da imputação é função direta da estrutura de (co)variância especificada**. Sob estrutura de identidade (ID), onde não há covariância entre ambientes, a predição para um genótipo não avaliado em determinado local recorre apenas à média geral e ao BLUP genotípico — sem aproveitamento da similaridade entre locais. Sob estrutura de simetria composta (CS), uma correlação uniforme entre todos os pares de ambientes permite alguma transferência de informação. A estrutura não estruturada (UN) oferece a maior flexibilidade, estimando correlações heterogêneas entre cada par de ambientes e permitindo que locais geneticamente similares contribuam mais para a predição de células faltantes. O modelo fatorial analítico (FA), que aproxima a matriz de (co)variância por um número reduzido de fatores latentes, representa um equilíbrio entre flexibilidade e parcimônia, sendo particularmente recomendado quando o número de ambientes é grande. A conexão aqui com as Aulas 7 e 9 é direta: modelos com melhor ajuste aos dados observados são, necessariamente, melhores preditores para dados não observados.

3.3 Imputação por algoritmos de aprendizado de máquina

Os métodos da seção anterior pressupõem algum conhecimento prévio sobre a estrutura dos dados: o EM-AMMI assume uma estrutura multiplicativa; os modelos mistos assumem distribuição normal e especificam a forma da (co)variância. Quando essas suposições são duvidosas, ou quando o volume de dados faltantes é elevado, algoritmos agnósticos à estrutura constituem uma alternativa valiosa.

O **MICE** (*Multivariate Imputation by Chained Equations*; van Buuren & Groothuis-Oudshoorn, 2011) trata cada ambiente (coluna da matriz $G \times A$) como uma variável a ser imputada condicionalmente às demais. O algoritmo percorre ciclicamente todas as colunas com dados faltantes, ajustando para cada uma um modelo de regressão condicional $f(y_j | \mathbf{y}_{-j}, \hat{\boldsymbol{\theta}}_j)$ e amostrando novos valores para as células faltantes a partir dessa distribuição condicional. O processo itera até a convergência das distribuições condicionais. Uma vantagem distintiva é a *imputação múltipla*: o algoritmo gera m conjuntos completos de dados, cada um refletindo uma realização diferente da incerteza de imputação. Análises conduzidas sobre cada conjunto e combinadas pelas regras de Rubin propagam essa incerteza para as inferências finais — o que os métodos determinísticos (EM-AMMI, SVD) não fazem.

O **missForest** (Stekhoven & Bühlmann, 2012) substitui o modelo de regressão condicional do MICE por uma floresta aleatória (*random forest*). Para cada coluna com dados faltantes, ajusta-se uma floresta nas linhas observadas, usando todas as demais colunas como predictoras; os valores faltantes são então preditos pelos modelos treinados. O ciclo itera até que o erro OOB (*out-of-bag*) estabilize, o que fornece uma estimativa do erro de imputação sem necessidade de conjunto de teste separado. As vantagens do missForest são sua robustez a relações não lineares e interações complexas entre variáveis, a ausência de suposições distribucionais e a capacidade de lidar com dados mistos (contínuos e categóricos). A principal limitação, em contraste com o MICE, é que produz uma única imputação determinística por rodada, não propagando a incerteza de imputação.

4 Síntese Comparativa dos Imputadores (ou Preditores)

Antes de apresentar os critérios de avaliação, vale pontuar uma distinção importante sobre os modelos mistos. Sob estruturas de covariância simples — identidade (ID) ou simetria composta (CS) — a predição de uma célula faltante (i, j) recorre essencialmente ao BLUP médio do genótipo i , sem aproveitamento da similaridade específica entre o ambiente j e os ambientes observados. A imputação genuína, no sentido de transferência de informação entre ambientes, ocorre sob estruturas mais ricas: na não estruturada (UN), cada par de ambientes possui correlação estimada individualmente; no modelo fatorial analítico (FA), fatores latentes compartilhados entre ambientes funcionam como eixos de similaridade. A analogia com a matriz de relacionamento genômico (GRM) é direta — assim como a GRM permite prever valores genotípicos de indivíduos não genotipados via parentesco, a matriz de covariância entre ambientes (UN/FA) permite prever desempenho em locais não testados via similaridade ambiental estruturada.

Merece menção ainda o **imputePCA** do pacote `missMDA` (Josse & Husson, 2016), que imputa por PCA iterativo com seleção automática do número de componentes via validação cruzada. Sua extensão MIPCA produz imputações múltiplas, propagando a incerteza de forma análoga ao MICE. Conceitualmente, situa-se entre o SVD/Yan (determinístico, posto fixo) e o MICE (estocástico, múltiplo), sendo uma opção parcimoniosa quando a estrutura multiplicativa é razoável mas o número de componentes é desconhecido.

Os métodos diferem em suposições, flexibilidade e custo computacional. A Tabela 1 sintetiza essas dimensões: métodos que assumem estrutura $G \times A$ tendem a ser mais acurados quando essa estrutura existe nos dados, mas falham quando ela é fraca ou ausente; métodos agnósticos como MICE e `missForest` são mais robustos nesse cenário, ao custo de não aproveitarem a redundância multiplicativa da interação. A propagação de incerteza, ausente nos métodos determinísticos, é relevante quando os resultados da imputação alimentam inferências formais sobre parâmetros genéticos.

Tabela 1: Comparação dos principais métodos de imputação da matriz $G \times A$.

Método	Assume estrutura $G \times A$	Propaga incerteza	Robusto a <i>outliers</i>	Pacote R
EM-AMMI	Sim (multiplicativa)	Não	Parcial	<code>geneticae</code>
SVD/Yan	Sim (bilinear)	Não	Não (padrão)	<code>geneticae</code>
imputePCA/MIPCA	Sim (PCA iterativo)	Sim (MIPCA)	Parcial	<code>missMDA</code>
Mod. misto UN/FA	Sim (covariância)	Sim (via acurácia)	Moderado	<code>sommer</code> , <code>asreml</code>
MICE	Não	Sim (múltipla)	Moderado	<code>mice</code>
<code>missForest</code>	Não	Não	Sim	<code>missForest</code>

5 Acurácia Preditiva e Validação Cruzada

A qualidade de um imputador deve ser avaliada empiricamente. O instrumento padrão é a validação cruzada (*cross-validation*, CV), na qual observações reais são artificialmente removidas, o modelo é ajustado sobre os dados restantes, e as predições são comparadas aos valores verdadeiros.

Dois esquemas de CV são particularmente relevantes no contexto MET. O **CV2** remove células individuais dentro de ambientes já presentes na rede, simulando o cenário de rede incompleta com genótipos testados em subconjuntos de locais. O **CV1** remove ambientes inteiros, simulando a predição para um local não observado em nenhuma iteração do modelo. O CV1 é o cenário mais exigente e mais relevante do ponto de vista do melhoramento, pois corresponde à recomendação de cultivares para regiões sem histórico de ensaios.

A métrica central é a correlação de Pearson entre os valores preditos $\hat{y}_{ij}$ e os valores observados y_{ij} removidos:

$$\rho_{\text{pred}} = \text{cor}(\hat{y}_{ij}, y_{ij}) \quad (5)$$

Essa correlação é análoga à acurácia de seleção familiar ao melhorista, e sua interpretação é direta: $\rho_{\text{pred}} = 1$ corresponde à predição perfeita e valores próximos de zero indicam que o modelo não captura informação relevante sobre as células não observadas. A comparação de ρ_{pred} entre imputadores sob o mesmo esquema de CV é o critério formal para a escolha do método mais adequado a um dado conjunto de dados.

6 Estratégias de Seleção sob $G \times A$ com a Matriz Completa

Uma vez preenchida a matriz $G \times A$ — com observações reais nas células disponíveis e predições nas células faltantes — abre-se um conjunto de possibilidades estratégicas para a seleção que não existia com a matriz incompleta.

A **seleção para adaptação ampla** baseia-se no BLUP médio do genótipo calculado sobre todos os ambientes da rede, incluindo os preditos. Isso corrige uma assimetria importante: genótipos avaliados em mais locais tendem a ter estimativas mais estáveis simplesmente por terem mais dados, o que pode distorcer rankings em redes desbalanceadas. Com a matriz completa, todos os genótipos competem em pé de igualdade, independentemente de sua cobertura original na rede.

A **seleção para adaptação específica** utiliza os BLUPs por ambiente-alvo, incluindo aqueles derivados de predição. Um genótipo que nunca foi fisicamente testado em determinado local pode, ainda assim, receber uma estimativa de desempenho predito para esse local, e essa estimativa pode fundamentar uma recomendação regional ou a inclusão do material em ensaios focados. Essa capacidade de extrapolar recomendações para ambientes não testados é uma das contribuições mais práticas da predição multiambiente ao processo de melhoramento.

O **índice de seleção multi-ambiente** integra, sobre a matriz completa, as métricas de produtividade e estabilidade introduzidas na Aula 8. A média harmônica dos BLUPs (MHVG) e o índice harmônico de estabilidade e produtividade (HMRPGV) ganham novo significado quando calculados sobre uma matriz sem buracos: a estabilidade estimada reflete genuinamente o comportamento do genótipo ao longo dos ambientes da rede, e não um artefato do desbalanceamento. Em particular, genótipos com muitos dados faltantes poderiam aparecer como estáveis simplesmente por terem sido avaliados em ambientes favoráveis; a imputação elimina essa confusão.

Há ainda o cenário da **seleção antecipada para ambientes futuros**, que conecta a presente aula à Aula 9: utilizando a norma de reação ajustada por regressão aleatória, é possível extrapolar o desempenho esperado de genótipos em gradientes ambientais não cobertos pela rede atual. Aqui, a predição não opera mais sobre células de uma matriz fixa, mas sobre um contínuo ambiental, o que aumenta substancialmente o escopo das recomendações possíveis.

7 Atividade

A atividade compara dois imputadores — SVD iterativo (Yan, 2013) e missForest — sob validação cruzada CV2, usando o conjunto `data_ge` do pacote `metan`. O SVD iterativo é implementado manualmente em poucas linhas, tornando explícita a lógica do algoritmo apresentada na Seção 3. O objetivo é calcular ρ_{pred} para cada método e discutir as diferenças.

```

1 # Aula 10 - Predicao em MET: SVD iterativo vs missForest (CV2)
2 # Pacotes: metan, missForest
3
4 library(metan)
5 library(missForest)
6
7 # -----
8 # 1. Dados e matriz G x A
9 # -----
10
11 data("data_ge")
12
13 mat <- tapply(data_ge$GY, list(data_ge$GEN, data_ge$ENV), mean)
14 cat("Dimensoes da matriz G x A:", dim(mat), "\n")

```

```

1  # -----
2  # 2. CV2: remocao artificial de 20% das celulas
3  # -----
4
5  set.seed(42)
6  idx_miss <- sample(seq_along(mat), round(0.20 * length(mat)))
7  obs      <- mat[idx_miss]      # valores verdadeiros reservados
8  mat_miss <- mat
9  mat_miss[idx_miss] <- NA
10 cat("Celulas removidas:", length(idx_miss), "\n")
11
12 # -----
13 # 3. SVD iterativo (Yan, 2013) - implementacao manual
14 # -----
15
16 svd_impute <- function(M, ncomp = 2, maxiter = 100, tol = 1e-4) {
17   M_imp <- M
18   # inicializa NAs com a media da respectiva coluna (ambiente)
19   col_means <- colMeans(M, na.rm = TRUE)
20   for (j in seq_len(ncol(M_imp)))
21     M_imp[is.na(M_imp[, j]), j] <- col_means[j]
22
23   for (iter in seq_len(maxiter)) {
24     M_old <- M_imp
25     sv <- svd(M_imp)
26     # aproximacao de posto reduzido (rank = ncomp)
27     M_imp <- sv$u[, 1:ncomp, drop = FALSE] %*%
28       diag(sv$d[1:ncomp], ncomp) %*%
29       t(sv$v[, 1:ncomp, drop = FALSE])
30     dimnames(M_imp) <- dimnames(M)
31     M_imp[!is.na(M)] <- M[!is.na(M)] # preserva observacoes reais
32     if (max(abs(M_imp - M_old)) < tol) {
33       cat("SVD convergiu em", iter, "iteracoes.\n"); break
34     }
35   }
36   M_imp
37 }
38
39 mat_svd <- svd_impute(mat_miss, ncomp = 2)
40 pred_svd <- mat_svd[idx_miss]
41
42 # -----
43 # 4. missForest
44 # -----
45
46 imp_mf <- missForest(mat_miss, verbose = FALSE)
47 pred_mf <- imp_mf$ximp[idx_miss]
48
49 # -----
50 # 5. Acuracia preditiva
51 # -----
52
53 rho_svd <- cor(pred_svd, obs)
54 rho_mf <- cor(pred_mf, obs)
55
56 cat("\n--- Acuracia preditiva (CV2) ---\n")
57 cat(sprintf("  SVD iterativo : rho = %.3f\n", rho_svd))
58 cat(sprintf("  missForest      : rho = %.3f\n", rho_mf))

```

Referências

- Garrick, D. J., Taylor, J. F., & Fernando, R. L. (2009). Deregressing estimated breeding values and weighting information for genomic regression analyses. *Genetics Selection Evolution*, 41(1), 55.
- Stekhoven, D. J., & Bühlmann, P. (2012). MissForest — nonparametric missing value imputation for mixed-type data. *Bioinformatics*, 28(1), 112–118.
- Yan, W. (2013). Biplot analysis of incomplete two-way data. *Crop Science*, 53(1), 48–57.
- Paderewski, J. (2013). An R function for imputation of missing cells in two-way data sets by EM-AMMI algorithm. *Communications in Biometry and Crop Science*, 8(1), 60–69.
- van Buuren, S., & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67.
- Arciniegas-Alarcón, S., García-Peña, M., Krzanowski, W. J., & Dias, C. T. S. (2014). An alternative methodology for imputing missing data in trials with genotype-by-environment interaction: some new aspects. *Biometrical Letters*, 51(2), 75–88.
- Burgueño, J., Crossa, J., Cornelius, P. L., & Yang, R. C. (2008). Using factor analytic models for joining environments and genotypes without crossover genotype $\times$ environment interaction. *Crop Science*, 48(4), 1291–1305.
- Angelini, J., Cervigni, G. D. L., & Quagliano, M. B. (2024). New imputation methodologies for genotype-by-environment data: an extensive study of properties of estimators. *Euphytica*, 220(6), 92.

Nota: Material assistido pelo Claude Sonnet 4.6 e Overleaf.