

Biometria da Interação Genótipos $\times$ Ambientes ($G \times A$)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

1 de julho de 2026

Roteiro da aula 14: Ambientômica I – Modelagem Integrativa Ambientipagem em Larga-Escala–Genótipos

1 Introdução

Na Aula 13 montamos a matriz de covariáveis ambientais por ensaio: para cada local/ano/safra, extraímos clima, solo e atributos geográficos dentro da janela de cultivo, padronizamos referências e geramos descritores do ambiente. Aquela aula entregou os dados; esta trata de como convertê-los em unidades de modelagem que entram nos modelos de $G \times A$ ao lado da informação genética ou fenotípica. Esse passo define a **Ambientômica** (*enviromics*): tratar o ambiente em escala “ômica”, por analogia à genômica, de modo que cada local passe a ser descrito por marcadores ambientômicos.

O termo foi proposto pela primeira vez em um *preprint* no bioRxiv por Resende et al. em 2019, com publicação na *Theoretical and Applied Genetics* entre 2020 e 2021 (Resende et al., 2021). Convém demarcar o conceito, porque há confusão recorrente em três frentes. Ambientômica não se reduz a análise de melhoramento com SIG: o SIG (Aula 11) coleta e organiza camadas espaciais, mas é meio, não o método. Também não se reduz a usar covariáveis ambientais em um modelo: a covariável bruta é insumo, e vira marcador só após construção e validação. E a confusão mais frequente: Ambientômica não é o mesmo que ambientipagem (*envirotyping*) nem que fenômica (*phenomics*). A ambientipagem é a etapa de tipar o ambiente (a Aula 13); a fenômica mede o fenótipo em alta dimensão; a Ambientômica usa os ambiótipos como preditores em modelos genético-estatísticos para prever efeitos genotípicos em ambientes não avaliados (Resende et al., 2021; Costa-Neto & Fritsche-Neto, 2021).

A delimitação desta aula é a formalização conceitual e estatística (Ambientômica I). Os produtos de entrega (mapas de recomendação, definição de zonas de melhoramento por agrupamento e mapeamento de parâmetros genéticos) são apenas antecipados e ficam para a Aula 15. Não reabrimos: operações de raster e SIG (Aula 11), o *pipeline* de ambientipagem (Aula 13), a estratificação por correlações fenotípicas (Aula 12), a álgebra do fator analítico (Aulas 5 e 7) nem o arcabouço geral de predição e imputação da tabela $G \times A$ (Aula 10). Retomamos de forma pontual a norma de reação da Aula 9, que usava a média fenotípica do ambiente como índice; aqui o índice passa a ser construído a partir de covariáveis ambientais.

2 Termos e a analogia com a genômica

A nomenclatura segue a analogia ômica. O **ambiótipo** (*envirotipe*) é a entidade: o valor que uma covariável ambiental assume em um ponto do espaço e em uma janela de tempo, correspondente ao genótipo. O **ambientoma** (*envirome*) é o conjunto de ambiótipos de um local, correspondente ao genoma. O **marcador ambientômico** (*enviromic marker*) é a covariável, ou função dela, indexada a um raster ou *shapefile* com resolução espacial e temporal definida e usada como preditor no modelo, correspondente ao marcador genômico. A **variação ambientípica** é o polimorfismo do marcador entre locais, correspondente à variação genotípica. O adjetivo segue o uso genômico: “ambientômico” qualifica a abordagem e os dados em escala ômica (kernel ambientômico, marcador ambientômico); “ambientípico” qualifica a variação e os efeitos; “ambiental” fica para a covariável bruta de clima e solo, antes de virar marcador.

A Figura 1 organiza essa construção. Uma área de cultivo é descrita por camadas de marcadores ambientais (*rasters* de clima, solo, relevo), e cada pixel georreferenciado carrega um vetor desses marcadores, o seu perfil ambiental. Assim como um genótipo é descrito por estados alélicos em SNPs, um sítio é descrito por seu vetor de marcadores ambientais. PS.: Um *raster* é uma matriz espacial de pixels/células, em que cada célula possui um valor associado a uma posição geográfica.




Figura 1: Construção do marcador ambiental. Uma área de cultivo é representada por camadas (*rasters*) de covariáveis ambientais; sobrepostas, definem para cada pixel um vetor de marcadores que descreve o ambiótipo daquele sítio, em paralelo ao vetor de marcadores genômicos de um genótipo.

Há contrastes que separam os dois tipos de marcadores. O genoma é estático para o indivíduo; o ambiente varia no espaço e no tempo, com sazonalidade. Mutações são raras; tendências climáticas e mudança de uso da terra deslocam a distribuição ambiental com rapidez, o que pede atualização contínua da ambientipagem. O estado alélico é discreto (0/1/2); a medida ambiental é sinal contínuo ou discretizado, sujeito a ruído de sensor, falhas, nuvem e calibração entre sensores, o que exige controle de qualidade. Sensoriamento por satélite ampliou a escala e a resolução dessas camadas, ao ponto de viabilizar marcadores por pixel ao longo do ciclo (Resende et al., 2024).

3 Marcadores ambientais

Quatro premissas operacionais (Marcatti & Resende, 2026):

1. **Linearidade.** O marcador deve ter relação linear com o fenótipo *na etapa final* do modelo, em analogia ao tratamento de SNPs em modelos de reação linear.
2. **Potencial de sítio.** Um sítio com alto valor de um dado marcador (alto ambiótipo) tende a oferecer maior potencial de expressão do caráter, alinhado ao conceito de produtividade ambiental de Finlay e Wilkinson (1963).
3. **Favorabilidade heterogênea.** Um sítio favorável a um genótipo ou grupo não é favorável a todos; as respostas genotípicas ao mesmo marcador são heterogêneas.
4. **Dependência ambiótipo–genótipo.** Uma covariável influente para um grupo pode não ser para outro; polimorfismo ambientípico não implica uniformidade de resposta genética.

As premissas 3 e 4 justificam usar inclinações aleatórias por genótipo e seleção parcimoniosa de covariáveis. A premissa 1 não proíbe não-linearidade: relações causais ambiente→fenótipo podem ser não lineares antes da construção do marcador, desde que o ajuste final permaneça linear. O fundamento ecofisiológico é a Lei de Shelford: o desempenho de uma espécie é regulado por fatores ambientais dentro de uma faixa de valores mínimos e máximos (Resende et al., 2021).

3.1 Estratégias para construir marcadores ambientômicos

Há quatro estratégias para converter covariáveis ambientais em marcadores, com hipóteses e objetivos distintos:

1. **Covariável bruta como marcador.** Usa-se a própria covariável, com relação ambiente–fenótipo assumida global e linear. Custo baixo, interpretação direta. Exige padronizar escala, checar colinearidade e evitar extrapolação fora do envelope de treino.
2. **Transformações.** Aplicam-se funções (quadrática, log, exponencial, *splines*) para capturar não-linearidades suaves. Expande o conjunto de marcadores candidatos, ao custo de mais termos e colinearidade, o que pede seleção e penalização.
3. **Índices ecofisiológicos.** Combinam-se covariáveis em funções de processo (graus-dia, unidades fototérmicas, métricas de estresse hídrico ou térmico, combinações de radiação e evapotranspiração), que traduzem o sinal bruto em medidas ligadas à fisiologia e reduzem ruído.
4. **Marcadores engenheirados por IA (EEM).** Geram-se marcadores sintéticos por modelos não lineares que aprendem a relação ambiente→fenótipo e cujas previsões locais entram depois de forma linear (Resende et al., 2025). Capturam padrões de platô, sigmoide e multimodais, ao custo de computação e dependência da qualidade dos dados.

Regra prática: usar a estratégia 1 como referência inicial e passar às estratégias 2 a 4 quando o diagnóstico de resíduos revelar desvios de linearidade (Montesinos-López et al., 2024). As quatro podem coexistir no mesmo modelo, desde que a colinearidade induzida seja controlada por encolhimento, kernels ou redução de dimensionalidade.

4 Normas de reação e kernel ambientômico

A norma de reação descreve como o desempenho de um genótipo muda ao longo de um gradiente ambiental. Na Aula 9, o gradiente era a média fenotípica do ambiente. Aqui o gradiente passa a ser construído a partir das covariáveis ambientais, e há **duas rotas** para colocá-lo no modelo misto: resumir as covariáveis em um **kernel ambientômico** ou regredir o desempenho diretamente sobre os marcadores por **regressão aleatória**. As duas modelam a mesma norma de reação, com propriedades distintas.

4.1 O kernel ambientômico

Seja $\mathbf{W}$ a matriz de covariáveis ambientais padronizadas, de dimensão $q \times k$: q ambientes nas linhas, k marcadores ambientômicos nas colunas. O relacionamento ambiental entre sítios é resumido em um kernel $\mathbf{K}_E$, de dimensão $q \times q$, em analogia direta à matriz genômica $\mathbf{G}$. A forma linear é

$$\mathbf{K}_E = \frac{\mathbf{W}\mathbf{W}'}{\text{tr}(\mathbf{W}\mathbf{W}')/q}, \quad (1)$$

em que $\mathbf{W}\mathbf{W}'$ acumula a covariância entre ambientes ao longo dos k marcadores, e o denominador $\text{tr}(\mathbf{W}\mathbf{W}')/q$ é a média dos elementos da diagonal, que padroniza a escala de $\mathbf{K}_E$. Note a propriedade que importa para a Ambientômica: $\mathbf{K}_E$ tem dimensão $q \times q$ *qualquer que seja* k . O custo é fixado pelo número de ambientes, não pelo número de marcadores, então o kernel comporta milhares de marcadores ambientômicos sem alterar o tamanho do problema.

Quando a relação ambiente–fenótipo tem curvatura, $\mathbf{K}_E$ pode ser estimado por kernels não lineares. O Gaussiano é

$$\mathbf{K}_E = \exp\left(-h \mathbf{D}^2/Q\right), \quad \mathbf{D}_{jj'}^2 = \sum_{p=1}^k (w_{jp} - w_{j'p})^2, \quad (2)$$

aplicado elemento a elemento, em que $\mathbf{D}_{jj'}^2$ é a distância euclidiana ao quadrado entre os vetores ambientais dos sítios j e j' , Q é a mediana dessas distâncias e h é a largura de banda que controla a taxa de decaimento da similaridade (Jarquin et al., 2014; Costa-Neto et al., 2021). O *deep kernel* de arco-cosseno é outra opção, emulando camadas de uma rede neural (Costa-Neto et al., 2021).

Convém marcar o que $\mathbf{K}_E$ é e o que **não é**! Ele é calculado só a partir de $\mathbf{W}$, sem nenhum dado fenotípico, então mede *similaridade ambiental* entre sítios, definida *a priori*. Ele não é a correlação genética entre ambientes: essa é estimada do fenótipo (por estrutura não estruturada de covariância ou por fator analítico, Aulas 5 e 7) e informa se os mesmos genótipos respondem juntos em dois locais. O kernel ambientômico assume que similaridade ambiental serve de proxy para correlação genética; é essa aposta que permite prever em sítios não testados, por empréstimo entre locais ambientipicamente próximos.

A norma de reação por kernel entra no modelo misto por um efeito ambiental, um efeito genotípico e a interação entre eles:

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{Z}_E \mathbf{e} + \mathbf{Z}_g \mathbf{g} + \mathbf{g}_W + \varepsilon, \quad (3)$$

em que $\mathbf{y}$ é o vetor de fenótipos; $\mathbf{X}\beta$ reúne os efeitos fixos (média geral e efeitos de ambiente); $\mathbf{e} \sim N(\mathbf{0}, \mathbf{K}_E \sigma_E^2)$ é o efeito ambiental principal, com incidência $\mathbf{Z}_E$; $\mathbf{g} \sim N(\mathbf{0}, \mathbf{K}_g \sigma_g^2)$ é o efeito genotípico principal, com relacionamento genômico $\mathbf{K}_g$ e incidência $\mathbf{Z}_g$; $\varepsilon \sim N(\mathbf{0}, \mathbf{I} \sigma^2)$ é o resíduo. O termo de interação $\mathbf{g}_W \sim N(\mathbf{0}, \mathbf{K}_{gW} \sigma_{gW}^2)$ usa a covariância dada pelo produto de Hadamard entre o relacionamento ambiental e o genético,

$$\mathbf{K}_{gW} = (\mathbf{Z}_E \mathbf{K}_E \mathbf{Z}_E') \odot (\mathbf{Z}_g \mathbf{K}_g \mathbf{Z}_g'), \quad (4)$$

em que $\odot$ é o produto de Hadamard (elemento a elemento). Cada observação combina um sítio e um genótipo; a entrada correspondente de $\mathbf{K}_{gW}$ é o produto da similaridade ambiental dos seus sítios pela similaridade genética dos seus genótipos. A passagem da Aula 9 para esta é a substituição da identidade $\mathbf{I}_q$ (ambientes não relacionados) por $\mathbf{K}_E$ (ambientes relacionados por covariáveis estruturadas).

4.2 A regressão aleatória sobre marcadores

A rota alternativa não colapsa os marcadores em um kernel: regride o desempenho diretamente sobre eles, com coeficientes aleatórios por genótipo. Na forma de passo único (Resende et al., 2021),

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{P}\mathbf{w} + \mathbf{Z}_0 \mathbf{a}_0 + \mathbf{Z}_1 \mathbf{a}_1 + \mathbf{e}, \quad \begin{bmatrix} \mathbf{a}_0 \\ \mathbf{a}_1 \end{bmatrix} \sim N(\mathbf{0}, \mathbf{G} \otimes \Sigma_a), \quad (5)$$

em que $\mathbf{X}\beta$ são os efeitos fixos; $\mathbf{P}\mathbf{w}$ é a regressão fixa sobre o marcador, a norma de reação média da população ($\mathbf{P}$ guarda os valores do marcador, $\mathbf{w}$ os coeficientes fixos); $\mathbf{a}_0$ são os interceptos aleatórios por genótipo (incidência $\mathbf{Z}_0$) e $\mathbf{a}_1$ as inclinações aleatórias por genótipo sobre o marcador (incidência $\mathbf{Z}_1$); $\mathbf{e}$ é o resíduo. A covariância dos coeficientes fatora em $\mathbf{G} \otimes \Sigma_a$, com $\mathbf{G}$ o parentesco genômico entre genótipos e Σ_a a covariância entre intercepto e inclinação,

$$\Sigma_a = \begin{bmatrix} \sigma_{a_0}^2 & \sigma_{a_0 a_1} \\ \sigma_{a_0 a_1} & \sigma_{a_1}^2 \end{bmatrix}. \quad (6)$$

A consequência didática aparece ao escrever o valor genético de um genótipo i no ambiente j como $g_{ij} = a_{0i} + a_{1i} w_j$. A covariância genética entre dois ambientes vira função paramétrica dos valores do marcador:

$$\text{Cov}(g_{ij}, g_{ij'}) = \begin{bmatrix} 1 & w_j \end{bmatrix} \Sigma_a \begin{bmatrix} 1 \\ w_{j'} \end{bmatrix} = \sigma_{a_0}^2 + (w_j + w_{j'}) \sigma_{a_0 a_1} + w_j w_{j'} \sigma_{a_1}^2. \quad (7)$$

A regressão aleatória, então, gera uma correlação genética entre ambientes a partir das covariáveis e de Σ_a , o que o kernel não faz de forma explícita.

Na montagem do modelo misto, cada covariável ambiental entra como um bloco de efeitos aleatórios, e a matriz de incidência $\mathbf{Z}$ assume forma bloco-diagonal por ensaio, com a covariância dos efeitos dada pelo produto de Kronecker entre a covariância ambiental e a matriz de parentesco aditivo ($\Sigma \otimes \mathbf{A}$). Essa construção é compatível com pacotes de modelo misto e predição genômica como rrBLUP e BGLR (Trevisan et al., 2025), o que põe a regressão aleatória ambientômica ao alcance das ferramentas que o melhorista já usa.

O custo aparece na dimensão. Cada marcador adicional acrescenta uma inclinação por genótipo, e Σ_a cresce como $(k+1)(k+2)/2$ parâmetros; a rota é prática com poucas covariáveis, em geral após redução

de dimensionalidade ou engenharia de marcadores. É justamente o regime aberto pelo sensoriamento por satélite, que entrega marcadores ambientômicos por pixel e ao longo do ciclo, em volume alto demais para inclinações individuais (Resende et al., 2024). A saída é a regressão aleatória por *ensemble* sobre marcadores engenheirados (REEM), que combina muitos marcadores sintéticos preditos antes de entrarem, de forma linear, no modelo de inclinações aleatórias (Resende et al., 2024, 2025), reconciliando a interpretabilidade da regressão aleatória com a escala da Ambientômica baseada em satélite.

4.3 O que cada rota captura

As duas rotas modelam a mesma norma de reação, mas o objeto que cada uma estima é distinto. O kernel $\mathbf{K}_E$ resume os marcadores em uma similaridade ambiental entre sítios, fixada *a priori*: ele impõe que ambientes ambientoticamente próximos tenham desempenho genético próximo, sem estimar essa relação a partir dos dados. A regressão aleatória não impõe esse proxy; estima as sensibilidades de cada genótipo ao marcador (as inclinações $\mathbf{a}_1$) e, com elas e Σ_a , gera uma covariância genética entre ambientes que é função explícita das covariáveis.

A consequência prática separa os regimes de uso. O kernel comporta milhares de marcadores ambientômicos, porque $\mathbf{K}_E$ permanece $q \times q$ qualquer que seja k ; em troca, não devolve a sensibilidade a cada covariável e a não-linearidade fica embutida na escolha do kernel. A regressão aleatória entrega essas sensibilidades de forma legível e modela a covariância entre ambientes de forma paramétrica, mas só é prática com poucas covariáveis, porque Σ_a cresce em $(k+1)(k+2)/2$ parâmetros e cada marcador adiciona uma inclinação por genótipo. A Tabela 1 organiza esse contraste.

Aspecto	Kernel ambientômico	Regressão aleatória
O que modela	Similaridade ambiental entre sítios ($\mathbf{K}_E$, <i>a priori</i>)	Norma de reação por genótipo (intercepto e inclinações)
Nº de marcadores	Milhares; $\mathbf{K}_E$ é $q \times q$ qualquer que seja k	Poucos; cada um vira inclinação e Σ_a cresce em $(k+1)(k+2)/2$
Correlação genética entre ambientes	Não estima; assume proxy ambiental	Induzida pelas covariáveis e por Σ_a
Interpretação	Sensibilidade por marcador não é lida diretamente	Inclinações são sensibilidades por covariável
Não-linearidade	Direta, por kernel Gaussiano ou <i>deep</i>	Exige transformar ou engenheirar o marcador

Tabela 1: Rotas para a norma de reação ambientômica.

4.4 Portabilidade entre as rotas

Há um precedente exato na predição genômica do *efeito principal*: GBLUP e RRBLUP são parametrizações do mesmo ajuste. O GBLUP modela $\mathbf{g} \sim N(\mathbf{0}, \mathbf{G}\sigma_g^2)$ com $\mathbf{G} = \mathbf{M}\mathbf{M}'/c$; o RRBLUP modela os efeitos de marcador $\mathbf{m} \sim N(\mathbf{0}, \mathbf{I}\sigma_m^2)$ com $\mathbf{g} = \mathbf{M}\mathbf{m}$ e $\sigma_g^2 = c\sigma_m^2$. O “RR” é *ridge regression*: encolhimento homogêneo, a mesma variância para todo marcador. Ajustado um, recuperam-se os efeitos de marcador do outro. Com mais marcadores que unidades ($p > n$, o caso usual em genômica),

$$\hat{\mathbf{m}} = \mathbf{M}'(\mathbf{M}\mathbf{M}')^{-1}\hat{\mathbf{g}}, \quad (8)$$

a solução de mínima norma entre os infinitos vetores de marcador que reproduzem $\hat{\mathbf{g}}$. Com mais unidades que marcadores ($n > p$), vale a forma de mínimos quadrados $\hat{\mathbf{m}} = (\mathbf{M}'\mathbf{M})^{-1}\mathbf{M}'\hat{\mathbf{g}}$, que aí é única; ambas são a pseudoinversa de Moore–Penrose no seu regime. Convém o alerta: $\hat{\mathbf{m}}$ devolve efeitos que reproduzem $\hat{\mathbf{g}}$, não necessariamente os efeitos geradores. A mesma álgebra transfere para o *efeito ambiental principal*: ele pode ser ajustado como kernel $\mathbf{K}_E$ ou como efeitos de marcador ambientômico com encolhimento ridge, equivalentes nesse sentido exato.

A equivalência entre as duas rotas de *norma de reação* não é dessa forma, por duas razões. A primeira é estrutural: o efeito de marcador deixa de ser um vetor. Na norma de reação cada genótipo tem sua própria sensibilidade, então o que se recupera é uma matriz $\hat{\mathbf{B}} = [\hat{\mathbf{a}}_0 \mid \hat{\mathbf{a}}_1]$, de dimensão $V \times (k+1)$ para V genótipos e k marcadores. Reunindo os valores genéticos em $\mathbf{G}_*$ ($V \times q$) e a base ambiental em

$\mathbf{W}_d = [\mathbf{1} \mid \mathbf{W}]$ ($q \times (k+1)$), o análogo do back-solving é, por genótipo,

$$\hat{\mathbf{B}} = \mathbf{G}_* \mathbf{W}_d (\mathbf{W}_d' \mathbf{W}_d)^{-1}, \quad (9)$$

e a covariância genética entre ambientes que essa rota induz é $\mathbf{W}_d \Sigma_a \mathbf{W}_d'$. A segunda razão é distribucional: a regressão aleatória é *random regression*, não *ridge regression*. Ela estima Σ_a , a covariância entre intercepto e inclinações, o que admite sensibilidades heterogêneas e a covariância entre ambientes acima; isso é estrutura mais rica que o encolhimento homogêneo do ridge. O kernel-GxE, do outro lado, colapsa os marcadores em $\mathbf{K}_E$ e não devolve sensibilidades por marcador ou por genótipo. As duas rotas coincidem só no limite de uma covariável com efeitos i.i.d.; fora dele são famílias aparentadas, não a mesma álgebra. A escolha é de conveniência computacional, dimensão de $\mathbf{W}$ e interpretabilidade. A construção dessas matrizes ambientômicas em modelo misto, com $\mathbf{Z}$ bloco-diagonal por ensaio e covariância por produto de Kronecker entre a covariância ambiental e a matriz de parentesco ($\Sigma \otimes \mathbf{A}$), é compatível com pacotes como rrBLUP e BGLR (Trevisan et al., 2025).

5 Abordagem latente: fatores e PLS para ambientes não testados

Uma alternativa ao kernel é representar a informação ambiental por fatores latentes. O fator analítico (FA) resume a covariância genética entre ambientes em poucos fatores (a álgebra do FA é tratada nas Aulas 5 e 7; aqui só o uso para redução de dimensionalidade):

$$\mathbf{g} = (\hat{\mathbf{\Lambda}} \otimes \mathbf{I}_V) \tilde{\mathbf{f}} + \tilde{\boldsymbol{\delta}}, \quad \boldsymbol{\Upsilon} = \Delta (\hat{\mathbf{\Lambda}} \Delta \hat{\mathbf{\Lambda}}' + \hat{\boldsymbol{\Psi}}) \Delta, \quad (10)$$

com $\hat{\mathbf{\Lambda}}$ as cargas, $\tilde{\mathbf{f}}$ os escores genotípicos e $\boldsymbol{\Upsilon}$ a correlação genética entre ambientes. A integração ambientômica (GIS-FA, Araújo et al., 2024) prediz as cargas de ambientes não testados por regressão PLS sobre as covariáveis:

$$\hat{\mathbf{\Lambda}}^* = \mathbf{W} \mathbf{B}^* + \mathbf{E} \quad (\text{treino}), \quad \hat{\mathbf{\Lambda}}_U^* = \mathbf{\Omega} \mathbf{B}^* + \mathbf{E} \quad (\text{predição}), \quad \mathbf{g}_U = (\hat{\mathbf{\Lambda}}_U^* \otimes \mathbf{I}_V) \tilde{\mathbf{f}}^*, \quad (11)$$

em que $\mathbf{\Omega}$ guarda as covariáveis dos ambientes não observados. O PLS resolve a multicolinearidade e o caso $k \gg n$ (mais covariáveis que observações). A similaridade ambiental entre testado e não testado, por distância euclidiana das linhas padronizadas mais interpolação por inverso da distância (IDW), serve de métrica de confiabilidade da predição. Reduções não supervisionadas (PCA, FA) não usam a resposta e são auxiliares, não substitutas da seleção supervisionada.

Tem-se então duas representações da informação ambiental para o mesmo objetivo preditivo: relacionamento por kernel ou fatores latentes mais PLS. A escolha depende de dados, computação e do quanto a relação ambiente-fenótipo é linear, curva ou não linear.

6 Modelos baseline não ambientômicos

Modelos ambientômicos devem ser comparados contra **baselines não ambientômicos**. Esses modelos não usam coordenadas, rasters, covariáveis ambientais, similaridade ambiental nem marcadores ambientômicos. Eles tratam o ambiente novo como uma unidade não caracterizada: sua posição geográfica e seu perfil ambiental são ignorados. A função deles é servir como referência mínima para avaliar se a Ambientômica acrescenta capacidade preditiva além da informação genotípica e da estrutura fenotípica já disponível na rede.

O baseline mais simples usa apenas o efeito genotípico principal:

$$y_{ijr} = \mu + E_j + g_i + \varepsilon_{ijr}, \quad \mathbf{g} \sim N(\mathbf{0}, \mathbf{K}_g \sigma_g^2), \quad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \mathbf{I} \sigma^2). \quad (12)$$

Aqui y_{ijr} é o fenótipo do genótipo i no ambiente j e repetição r ; E_j é o efeito fixo de ambiente; g_i é o valor genético médio do genótipo, podendo usar parentesco genômico $\mathbf{K}_g$ ou identidade. Para um ambiente novo u , sem fenótipos e sem covariáveis ambientais, não há como estimar E_u ; portanto, a predição operacional para comparação entre genótipos é

$$\hat{y}_{iu} = \hat{\mu} + \hat{g}_i. \quad (13)$$

Esse modelo testa se o modelo ambientômico prediz melhor do que simplesmente recomendar os genótipos com maior desempenho médio genético na rede.

Um segundo baseline inclui interação $G \times E$, mas sem estrutura ambiental:

$$y_{ijr} = \mu + E_j + g_i + (gE)_{ij} + \varepsilon_{ijr}, \quad (14)$$

com

$$\mathbf{g} \sim N(\mathbf{0}, \mathbf{K}_g \sigma_g^2), \quad \mathbf{gE} \sim N(\mathbf{0}, \mathbf{K}_g \otimes \mathbf{I}_q \sigma_{gE}^2), \quad \varepsilon \sim N(\mathbf{0}, \mathbf{I} \sigma^2). \quad (15)$$

A matriz $\mathbf{I}_q$ assume que os ambientes são independentes entre si. Logo, para um ambiente novo u , o efeito $(gE)_{iu}$ tem esperança zero e não recebe informação específica dos ambientes testados:

$$E\{(gE)_{iu} \mid \text{treino}\} = 0, \quad \hat{y}_{iu} = \hat{\mu} + \hat{g}_i. \quad (16)$$

Esse baseline é útil porque permite ajustar a variância $G \times E$ no treino, mas não usa essa interação para extrapolar a um ambiente novo. Assim, ele quantifica o limite de um modelo $G \times E$ sem descritores ambientais.

Um terceiro baseline possível é o modelo multiambiente com covariância genética entre ambientes observados:

$$y_{ijr} = \mu_j + g_{ij} + \varepsilon_{ijr}, \quad \mathbf{g}_i = \begin{bmatrix} g_{i1} & \cdots & g_{iq} \end{bmatrix}' \sim N(\mathbf{0}, \Sigma_E), \quad (17)$$

ou, com parentesco genômico,

$$\text{Var}(\mathbf{g}) = \mathbf{K}_g \otimes \Sigma_E. \quad (18)$$

Esse modelo pode ser ajustado como matriz não estruturada, DIAG ou FA entre ambientes observados. Porém, em validação CV0 estrita, o ambiente u é retirado do treino; portanto, a linha e a coluna de Σ_E envolvendo u não são estimáveis. Se forem usadas informações fenotípicas do próprio ambiente u para estimar sua correlação com os demais, há vazamento. Assim, para ambiente inteiramente novo, esse baseline não prediz g_{iu} de forma específica; ele volta à predição média baseada em $\hat{g}_i$.

Portanto, a comparação honesta deve separar três casos: modelos sem $G \times E$, modelos com $G \times E$ iid e modelos com covariância fenotípica entre ambientes observados. Nenhum deles sabe onde o ambiente novo está, nem como ele é. Um modelo ambientômico só deve ser considerado superior se superar esses baselines sob o mesmo esquema de validação, sem usar fenótipos do ambiente-alvo na construção dos marcadores, seleção de covariáveis ou ajuste de hiperparâmetros.

7 Validação e tipos de “ambiente novo”

A pergunta de Piepho (2022) organiza a validação: “qual é o seu modelo?”. Predizer dentro do domínio amostral difere de extrapolar, e “ambiente novo” pode significar coisas distintas: novo local, novo ano, nova combinação local $\times$ ano ou novo perfil ambiental. Os esquemas usuais (Costa-Neto et al., 2021) são CV1 (genótipos não testados em nenhum ambiente), CV2 (*sparse testing*, rede incompleta) e CV0 (ambientes inteiramente novos, *leave-one-environment-out*); partições por região e por ano também se aplicam.

Atenção na hora de reportar capacidade preditiva. Quando se correlaciona predito contra observado juntando todas as observações de todos os ambientes, a correlação captura, em boa parte, a diferença de médias entre ambientes: ambientes de alta e de baixa produtividade se separam no eixo, e o modelo acerta essa separação mesmo que erre o ordenamento dos genótipos dentro de cada ambiente. O resultado pode ser um falso positivo, uma correlação alta que sugere um modelo bom quando ele apenas discrimina ambientes, não genótipos, um efeito de agregação “aparentado” ao *paradoxo de Simpson*.

Para validar marcadores sem vazamento, eles devem ser construídos apenas no treino, com hiperparâmetros congelados antes da predição cega. O ganho preditivo deve ser reportado contra quatro linhas-base: sem covariáveis; covariáveis brutas; transformadas e ecofisiológicas; engenheiradas por IA. O controle de qualidade segue o esquema tipo-SNP: completude por marcador e por pixel, cobertura, remoção de covariáveis quase constantes dentro da TPE e redução de colinearidade. Inferência sobre quais covariáveis importam vem depois da validação preditiva, não da inspeção isolada de coeficientes.

8 O que a Ambientômica entrega

Com marcadores ambientômicos validados, dois ganhos aparecem: definir zonas de alta correlação genética para seleção e escolher locais de ensaio que maximizam similaridade ambiental com a TPE, direcionando recomendações para sítios não testados. O alcance vai além da predição de desempenho: escolha de ambientes para multiplicação de sementes, recomendação agrônômica sítio-específica e definição de práticas em campo (Trevisan et al., 2025; Resende et al., 2024). O tratamento completo desses produtos (mapas de recomendação, agrupamento em zonas de melhoramento e mapeamento de parâmetros) é o tema da Aula 15.

9 Atividade

Com o conjunto didático de 14 observações (4 genótipos, 6 locais, covariáveis EC_1 a EC_5), ajuste a norma de reação ambientômica por regressão aleatória: cada genótipo recebe intercepto e cinco inclinações aleatórias sobre as covariáveis, com covariância $\mathbf{K} = \mathbf{A} \otimes \mathbf{I}_6$ ($\mathbf{A}$ o parentesco dos quatro genótipos). **Objetivo:** estimar os efeitos por genótipo e prever $\hat{y}$ em um local não testado. **Produto esperado:** a tabela de efeitos $\hat{u}_{ij}$, o $\hat{y}$ predito para o novo local e uma frase interpretando qual covariável mais desloca a resposta. **Critério:** discutir se a similaridade entre o local novo e os testados sustenta a predição.

Passos:

1. Monte $\mathbf{Z}$ bloco-diagonal (intercepto + EC_1 a EC_5 por genótipo).
2. Monte o kernel $\mathbf{K} \leftarrow \text{kronecker}(\mathbf{A}, \text{diag}(6))$.
3. Ajuste o modelo misto $\mathbf{y} = \mathbf{X}\mathbf{b} + \mathbf{Z}\mathbf{u} + \mathbf{e}$ com `mixed.solve`.
4. Extraia $\hat{\mathbf{u}}$ e prediga $\hat{y}$ de um local novo: escolha valores plausíveis de EC e aplique $\hat{y} = \hat{\beta}_0 + \hat{u}_{0g} + \sum_j \hat{u}_{jg} EC_j$.
5. Compare os genótipos: qual responde melhor ao local novo, e por quê?

```

1 library(Matrix); library(rrBLUP)
2
3 # --- Dados (toy example): copie e use diretamente -----
4 dat <- read.table(header = TRUE, text = "
5 loc lon lat gen EC1 EC2 EC3 EC4 EC5 y
6 L1 1 4 GA -0.230 -1.265 0.111 -0.050 -0.270 12.88
7 L5 2 5 GA 0.129 1.224 0.498 0.867 0.968 17.83
8 L6 3 6 GA 1.715 0.360 -1.967 1.061 -0.132 18.41
9 L2 2 2 GB -0.560 0.461 0.401 0.391 0.472 12.08
10 L1 1 4 GB -0.230 -1.265 0.111 0.022 -0.046 11.84
11 L4 4 4 GB 0.071 -0.446 1.787 0.580 0.710 15.82
12 L6 3 6 GB 1.715 0.360 -1.967 0.832 -0.486 18.16
13 L2 2 2 GC -0.560 0.461 0.401 0.588 0.322 12.34
14 L3 3 3 GC 1.559 -0.687 -0.556 0.522 0.166 16.11
15 L2 2 2 GD -0.560 0.461 0.401 0.770 0.692 15.25
16 L1 1 4 GD -0.230 -1.265 0.111 0.108 -0.142 14.91
17 L4 4 4 GD 0.071 -0.446 1.787 0.607 1.262 19.24
18 L5 2 5 GD 0.129 1.224 0.498 0.683 0.706 18.16
19 L6 3 6 GD 1.715 0.360 -1.967 1.052 -0.299 16.18
20 ")
21
22 # --- Parentesco dos 4 genotipos -----
23 A <- matrix(c(1,.5,.125,0, .5,1,.125,0,
24 .125,.125,1,.25, 0,0,.25,1), 4, 4, byrow = TRUE)
25 rownames(A) <- colnames(A) <- c("GA","GB","GC","GD")

```


Referencial teórico

- Araújo, M. S., Chaves, S. F. S., Dias, L. A. S., et al. (2024). GIS-FA: an approach to integrating thematic maps, factor-analytic, and envirotyping for cultivar targeting. *Theoretical and Applied Genetics*, 137, 80.
- Costa-Neto, G., & Fritsche-Neto, R. (2021). Enviromics: bridging different sources of data, building one framework. *Crop Breeding and Applied Biotechnology*, 21.
- Costa-Neto, G., Fritsche-Neto, R., & Crossa, J. (2021). Nonlinear kernels, dominance, and envirotyping data increase the accuracy of genome-based prediction in multi-environment trials. *Heredity*, 126, 92–106.
- Costa-Neto, G., Galli, G., Carvalho, H. F., Crossa, J., & Fritsche-Neto, R. (2021). EnvRtype: a software to interplay enviromics and quantitative genomics in agriculture. *G3: Genes|Genomes|Genetics*, 11(4), jkab040.
- Finlay, K. W., & Wilkinson, G. N. (1963). The analysis of adaptation in a plant-breeding programme. *Australian Journal of Agricultural Research*, 14, 742–754.
- Heslot, N., Akdemir, D., Sorrells, M. E., & Jannink, J. L. (2014). Integrating environmental covariates and crop modeling into the genomic selection framework to predict genotype by environment interactions. *Theoretical and Applied Genetics*, 127, 463–480.
- Jarquín, D., Crossa, J., Lacaze, X., et al. (2014). A reaction norm model for genomic selection using high-dimensional genomic and environmental data. *Theoretical and Applied Genetics*, 127, 595–607.
- Marcatti, G. E., & Resende, R. T. (2026). The Enviromic marker. *Crop Breeding and Applied Biotechnology*, 26(1), e54222611.
- Montesinos-López, O. A., Crespo-Herrera, L., Pierre, C. S., et al. (2024). Feature engineering of environmental covariates improves plant genomic-enabled prediction. *Frontiers in Plant Science*, 15, 1349569.
- Piepho, H. P. (2022). Prediction of and for new environments: what's your model? *Molecular Plant*, 15, 581–582.
- Piepho, H. P., & Blancon, J. (2023). Extending Finlay–Wilkinson regression with environmental covariates. *Plant Breeding*, 142, 621–631.
- Resende, R. T., Piepho, H. P., Rosa, G. J. M., et al. (2021). Enviromics in breeding: applications and perspectives on envirotypic-assisted selection. *Theoretical and Applied Genetics*, 134, 95–112.
- Resende, R. T., Hickey, L., Amaral, C. H., Peixoto, L. L., Marcatti, G. E., & Xu, Y. (2024). Satellite-enabled enviromics to enhance crop improvement. *Molecular Plant*, 17, 848–866.
- Resende, R. T., Xavier, A., Silva, P. I. T., Resende, M. P. M., Jarquín, D., & Marcatti, G. E. (2025). GIS-based G×E modeling of maize hybrids through enviromic markers engineering. *New Phytologist*, 245, 102–116.
- Tolhurst, D. J., Gaynor, R. C., Gardunia, B., Hickey, J. M., & Gorjanc, G. (2022). Genomic selection using random regressions on known and latent environmental covariates. *Theoretical and Applied Genetics*, 135, 3393–3415.
- Trevisan, B. A., Junqueira, V. S., Florêncio, B. M., Coelho, A. S. G., Marcatti, G. E., & Resende, R. T. (2025). A framework for building enviromics matrices in mixed models. *Brazilian Journal of Biometrics*, 43(4), e865. (Preprint arXiv:2501.04147.)
- Xu, Y. (2016). Envirotyping for deciphering environmental impacts on crop plants. *Theoretical and Applied Genetics*, 129, 653–673.

Nota: Material assistido pelo ChatGPT 5.3 e 5.4, Claude Sonnet 4.6 e Overleaf.