

Biometria da Interação Genótipos $\times$ Ambientes ($G \times A$)

– UFG – PPGGMP/UFG – GMP0164 –

Prof. Rafael Tassinari Resende

1 de julho de 2026

Roteiro da aula 15: Ambientômica II – Síntese e Integração Prática

1 Introdução

A Aula 14 formalizou como os marcadores ambientômicos entram nos modelos de $G \times A$: por kernel, regressão aleatória ou fatores latentes associados a covariáveis ambientais. Esta aula trata do passo seguinte: transformar predições, covariâncias e superfícies ambientais em produtos de decisão. O caminho vai do modelo ao uso: efeitos por genótipo, mapas de desempenho, mapas de recomendação, zonas de melhoramento, mapas de confiabilidade e critérios para desenho da rede experimental.

A diferença de escala organiza a aula. Um modelo $G \times A$ clássico descreve relações entre genótipos e ambientes observados. A Ambientômica acrescenta uma representação ambiental para cada sítio da população-alvo de ambientes (TPE), permitindo extrapolar a predição para locais ou pixels não ensaiados, desde que eles estejam dentro do domínio ambiental amostrado. A extrapolação exige validação e comparação com modelos baseline sob o mesmo esquema de treino e teste.

A parte prática em R percorre esse caminho passo a passo. Aqui fica a base teórica que organiza as decisões: definição da TPE, construção da matriz ambiental dos pixels, comparação com baselines, geração de mapas, validação, confiabilidade, zonas de melhoramento, *deployment* e escolha de locais futuros. A formalização estatística da Aula 14 entra aqui como ponto de partida.

2 Passo zero: a população-alvo de ambientes

Antes de qualquer mapa, define-se onde se quer recomendar. A população-alvo de ambientes (TPE) é o conjunto de sítios, anos, manejos e condições ambientais para os quais as cultivares se destinam. Com SIG, a TPE é representada simultaneamente como polígono geográfico e como nuvem de perfis ambientômicos: cada pixel da área-alvo carrega um vetor de marcadores ambientais padronizados.

A TPE corresponde ao domínio de recomendação, representado por locais ensaiados e pixels-alvo. Os locais ensaiados são amostras da TPE; os pixels da TPE representam o domínio onde a recomendação será projetada. Essa distinção separa interpolação dentro do domínio ambiental observado e extrapolação para pixels fora do envelope de treino. Portanto, a delimitação da TPE antecede zonas, mapas e escolha de locais.

A unidade ambiental deve ser explicitada: local, local $\times$ ano, local $\times$ safr ou local $\times$ ano $\times$ manejo. A resolução espacial e a janela temporal dos marcadores também devem ser fixadas. Uma recomendação baseada em normais climáticas responde a uma pergunta diferente de uma recomendação baseada em uma safra específica.

3 Pipeline operacional

A aplicação ambientômica segue uma sequência mínima:

$$\text{rasters} \rightarrow \mathbf{W}_{\text{train}} \rightarrow \text{padronização} \rightarrow \mathbf{W}_{\text{TPE}} \rightarrow \hat{g}_{ig}, \hat{y}_{ig} \rightarrow \text{rankings, mapas e zonas.} \quad (1)$$

A matriz $\mathbf{W}_{\text{train}}$ contém os marcadores dos ambientes ensaiados. A matriz $\mathbf{W}_{\text{TPE}}$ contém os mesmos marcadores para todos os pixels ou sítios-alvo. A padronização deve usar apenas médias e desvios-padrão estimados no treino:

$$w_{ip}^* = \frac{w_{ip} - \bar{w}_{p,\text{train}}}{s_{p,\text{train}}}, \quad (2)$$

em que w_{ip} é o marcador p no pixel i . Padronizar a TPE com estatísticas calculadas sobre ela própria altera a escala do problema e pode mascarar extrapolação.

Depois de padronizada, $\mathbf{W}_{\text{TPE}}$ é projetada no modelo ajustado. O produto inicial é uma matriz de predições:

$$\hat{\mathbf{Y}}_{\text{TPE}} = [\hat{y}_{ig}], \quad (3)$$

com pixels ou sítios nas linhas e genótipos nas colunas. Os mapas de recomendação, ganho, risco e zonas são derivados dessa matriz combinada com medidas de confiabilidade.

4 Por que precisa ser ômica

Há uma tentação recorrente: escolher duas ou três covariáveis ambientais óbvias, como precipitação, altitude e temperatura média, e esperar que elas expliquem a interação. Em muitos dados reais, isso captura apenas parte do sinal. O crossover genotípico tende a ser governado por gradientes ambientais múltiplos, colineares, temporais e dependentes do estágio fenológico. O sinal que importa para $G \times A$ raramente está concentrado em uma única variável.

A escala ômica exige muitos marcadores ambientais organizados por critério biológico, espacial e estatístico. A unidade de análise passa a ser o perfil ambiental do sítio. Modelos ecofisiológicos, transformações e marcadores engenheirados ajudam a construir descritores, mas a predição da TPE depende da cobertura da variação ambiental.

Isso parece colidir com a parcimônia da regressão aleatória, que comporta poucas covariáveis por ajuste. A reconciliação é o *ensemble*: ajustam-se muitos modelos, cada um com um subconjunto pequeno de marcadores, e combinam-se as predições. A combinação pode ser feita por média simples, média ponderada pelo desempenho em validação ou empilhamento, com pesos definidos apenas no treino. Assim, cada ajuste permanece computacionalmente tratável, enquanto o conjunto recupera a escala ambientômica.

5 Modelos baseline para comparação

Modelos ambientômicos devem ser comparados contra modelos baseline. Esses modelos usam apenas informação genotípica e fenotípica da rede experimental, sem coordenadas, rasters, covariáveis ambientais, similaridade ambiental ou marcadores ambientômicos. A função deles é medir quanto se prediz com a estrutura já disponível nos ensaios.

O baseline mais simples usa apenas o efeito genotípico principal:

$$y_{ijr} = \mu + E_j + g_i + \varepsilon_{ijr}, \quad \mathbf{g} \sim N(\mathbf{0}, \mathbf{K}_g \sigma_g^2), \quad \varepsilon \sim N(\mathbf{0}, \mathbf{I} \sigma^2). \quad (4)$$

Aqui y_{ijr} é o fenótipo do genótipo i no ambiente j e repetição r ; E_j é o efeito fixo de ambiente; g_i é o valor genético médio do genótipo, com $\mathbf{K}_g$ genômico ou $\mathbf{I}$ iid. Para um ambiente novo u , sem fenótipos e sem covariáveis ambientais, a predição operacional para comparação entre genótipos é

$$\hat{y}_{iu} = \hat{\mu} + \hat{g}_i. \quad (5)$$

Um segundo baseline inclui $G \times E$, mas sem estrutura ambiental:

$$y_{ijr} = \mu + E_j + g_i + (gE)_{ij} + \varepsilon_{ijr}, \quad (6)$$

com

$$\mathbf{g} \sim N(\mathbf{0}, \mathbf{K}_g \sigma_g^2), \quad \mathbf{gE} \sim N(\mathbf{0}, \mathbf{K}_g \otimes \mathbf{I}_q \sigma_{gE}^2), \quad \varepsilon \sim N(\mathbf{0}, \mathbf{I} \sigma^2). \quad (7)$$

A matriz $\mathbf{I}_q$ assume independência entre ambientes. Para um ambiente novo u , o efeito $(gE)_{iu}$ tem esperança condicional zero:

$$E\{(gE)_{iu} \mid \text{treino}\} = 0, \quad \hat{y}_{iu} = \hat{\mu} + \hat{g}_i. \quad (8)$$

Esse baseline permite estimar a variância $G \times E$ no treino, mas sua predição para o ambiente novo continua baseada no valor genético médio.

Um terceiro baseline é o modelo multiambiente com covariância genética entre ambientes observados:

$$y_{ijr} = \mu_j + g_{ij} + \varepsilon_{ijr}, \quad \mathbf{g}_i = [g_{i1} \ \cdots \ g_{iq}]' \sim N(\mathbf{0}, \Sigma_E), \quad (9)$$

ou, com parentesco genômico,

$$\text{Var}(\mathbf{g}) = \mathbf{K}_g \otimes \Sigma_E. \quad (10)$$

Esse modelo pode ser ajustado como DIAG, FA ou matriz não estruturada entre ambientes observados. Em validação CV0 estrita, o ambiente u é retirado do treino; portanto, a linha e a coluna de Σ_E envolvendo u ficam fora da estimação. Usar fenótipos do ambiente u para estimar sua correlação com os demais gera vazamento. Assim, para ambiente inteiramente novo, esse baseline retorna à predição baseada em $\hat{g}_i$.

Um modelo ambientômico apresenta ganho real quando supera esses baselines sob a mesma partição de treino e validação, com marcadores e hiperparâmetros definidos sem informação fenotípica do ambiente-alvo.

6 Do efeito ao mapa

Na regressão aleatória ambientômica, o objeto genotípico entregue pelo modelo é a matriz de coeficientes por genótipo,

$$\hat{\mathbf{B}} = [\hat{\mathbf{a}}_0 \mid \hat{\mathbf{a}}_1],$$

com uma linha por genótipo e uma coluna para o intercepto mais as inclinações associadas aos marcadores. Para um pixel i com vetor ambiental aumentado $\mathbf{w}_{d,i} = [1 \ \mathbf{w}_i]$, o valor genético predito do genótipo g naquele pixel é

$$\hat{g}_{ig} = \hat{\mathbf{B}}_g \mathbf{w}_{d,i}' = \hat{a}_{0g} + \sum_{p=1}^k \hat{a}_{pg} w_{ip}. \quad (11)$$

Para ranquear genótipos dentro do mesmo pixel, a parte fixa comum aos genótipos cancela. Para mapear produtividade ou desempenho absoluto, inclui-se a parte fixa do modelo:

$$\hat{y}_{ig} = \hat{\mu} + \hat{f}(\mathbf{w}_i) + \hat{g}_{ig}, \quad (12)$$

em que $\hat{f}(\mathbf{w}_i)$ representa a norma de reação média, quando ela foi incluída como regressão fixa sobre marcadores. Quando o modelo contém apenas intercepto fixo, $\hat{f}(\mathbf{w}_i) = 0$.

No caso de modelos por kernel, a lógica é análoga, mas o objeto projetado são similaridades entre o perfil ambiental do pixel novo e os ambientes testados. Nesse caso, os mapas de desempenho podem ser obtidos, e a interpretação por covariável exige análise adicional.

7 Validação operacional e confiabilidade

A validação deve corresponder à pergunta de uso. Para prever ambiente não testado, o esquema adequado é CV0 ou *leave-one-environment-out*. Se o alvo é local novo, usa-se *leave-one-location-out*. Se o alvo é safra futura, usa-se validação temporal. Se o alvo é expansão regional, usa-se validação por região. Misturar observações de todos os ambientes em uma única correlação pode inflar a capacidade preditiva, porque a correlação passa a capturar diferenças de média entre ambientes, não o ordenamento genotípico dentro de cada ambiente.

A capacidade preditiva deve ser reportada de forma compatível com a decisão:

$$r_{\text{within}} = \text{cor}(\hat{g}_{ig}, \hat{g}_{ig}^{\text{obs}}) \quad \text{dentro de cada ambiente,} \quad (13)$$

ou como acerto de ranking, ganho contra testemunha, acerto do melhor grupo ou superioridade média do genótipo recomendado. Para recomendação, a pergunta principal é se o modelo escolhe melhor que os baselines.

A confiabilidade espacial deve acompanhar o mapa de recomendação. Uma medida simples é a distância do pixel i ao ambiente testado mais próximo no espaço dos marcadores:

$$d_i = \min_j \|\mathbf{w}_i - \mathbf{w}_j\|. \quad (14)$$

Também podem ser usados distância de Mahalanobis, média das distâncias aos k vizinhos mais próximos, proporção de marcadores fora do intervalo observado no treino e variância entre modelos do *ensemble*. Pixels fora do envelope ambiental de treino devem ser marcados como extrapolação.

8 Mapeamento espacial de parâmetros genéticos

Na regressão aleatória, a variância genética depende do ambiente. Para um modelo único, com covariância dos coeficientes Σ_a , tem-se:

$$v_G(\mathbf{w}_d) = \mathbf{w}_d \Sigma_a \mathbf{w}_d'. \quad (15)$$

Como $\mathbf{w}_d$ varia no espaço, v_G também varia. Portanto, a variância genética passa a ser uma superfície sobre a TPE.

A herdabilidade em nível de observação simples pode ser escrita como

$$h_{\text{obs}}^2(\mathbf{w}_d) = \frac{v_G(\mathbf{w}_d)}{v_G(\mathbf{w}_d) + \sigma_e^2}. \quad (16)$$

Para médias genotípicas por ambiente, a forma útil deve considerar repetição, delineamento e erro médio:

$$h_{\text{mean}}^2(\mathbf{w}_d) = \frac{v_G(\mathbf{w}_d)}{v_G(\mathbf{w}_d) + \sigma_e^2/r(\mathbf{w}_d)}. \quad (17)$$

Se r varia no espaço ou entre ensaios, o mapa de herdabilidade também depende da estrutura experimental. Por isso, regiões com maior v_G indicam maior potencial de discriminação genética, mas seleção eficaz também depende de erro, repetição, acurácia, conectividade e representatividade da TPE.

A correlação genética entre dois sítios deriva da mesma estrutura:

$$r_G(\mathbf{w}_{d,i}, \mathbf{w}_{d,j}) = \frac{\mathbf{w}_{d,i} \Sigma_a \mathbf{w}_{d,j}'}{\sqrt{v_G(\mathbf{w}_{d,i})} \sqrt{v_G(\mathbf{w}_{d,j})}}. \quad (18)$$

Valores próximos de 1 indicam ordenamento genotípico preservado; valores baixos ou negativos indicam maior chance de crossover.

Se a predição foi feita por *ensemble*, cada modelo possui sua própria Σ_a . Nesse caso, os mapas de v_G , h^2 e r_G devem ser calculados por modelo e depois agregados, ou então restritos ao subconjunto de modelos para os quais esses parâmetros têm interpretação comum. Usar uma única matriz Σ_a para representar um *ensemble* heterogêneo exige declarar essa aproximação.

9 Zonas de melhoramento

Uma zona de melhoramento é um agrupamento de sítios com alta correlação genética interna. Dentro da zona, o ordenamento dos genótipos tende a ser estável; entre zonas, há maior risco de crossover. Uma forma direta de delimitar zonas é usar a dissimilaridade

$$d_{ij}^G = 1 - r_G(\mathbf{w}_{d,i}, \mathbf{w}_{d,j}), \quad (19)$$

seguida de agrupamento hierárquico, particionamento ou segmentação espacial. A escolha do número de zonas é um balanço: poucas zonas escondem crossover; muitas zonas fragmentam a recomendação e reduzem a base de inferência por zona.

Mega-ambientes tradicionais são definidos a partir de padrões observados em ensaios, frequentemente via correlações fenotípicas, AMMI ou GGE. Zonas de melhoramento ambientômicas podem ser projetadas para pixels não ensaiados, porque usam a representação ambiental desses pixels. A interpretação depende do modelo: em regressão aleatória, as inclinações ajudam a identificar quais marcadores caracterizam a zona; em modelos por kernel, a interpretação por marcador exige análise adicional.

Zonas também podem ser definidas por estabilidade de ranking, matriz de recomendação, similaridade ambiental ou combinação desses critérios. O critério deve acompanhar a pergunta: zoneamento para seleção, zoneamento para recomendação comercial ou zoneamento para desenho da rede experimental.

10 Mapas de recomendação genotípica

Da matriz de predições saem mapas distintos.

O mapa *which-won-where* identifica, para cada pixel, o genótipo com maior desempenho predito:

$$g_i^* = \arg \max_g \hat{y}_{ig}. \quad (20)$$

Ele responde qual genótipo vence em cada região da TPE. O mapa de desempenho do vencedor mostra

$$\hat{y}_{i,g_i^*}, \quad (21)$$

ou seja, a produtividade ou desempenho predito do genótipo recomendado no pixel i . O ganho genético é calculado por contraste com uma referência:

$$\Delta_i = \hat{y}_{i,g_i^*} - \hat{y}_{i,g_{\text{ref}}}, \quad (22)$$

em que g_{ref} pode ser testemunha, cultivar atual, média da rede ou recomendação anterior. Também podem ser produzidos mapas de adaptação específica, para um genótipo fixo g :

$$A_{ig} = I(\hat{y}_{ig} \geq c), \quad (23)$$

em que c é um limiar técnico ou comercial. Para comparações entre dois genótipos, usa-se

$$D_{i,g_1g_2} = \hat{y}_{ig_1} - \hat{y}_{ig_2}. \quad (24)$$

Esses mapas respondem perguntas diferentes: onde um genótipo vence, onde supera um limiar e onde supera uma testemunha. Todo mapa de recomendação deve ser acompanhado por uma camada de confiabilidade. A recomendação em pixels próximos ao domínio ambiental de treino é interpolativa; em pixels distantes, é extrapolativa. A segunda situação muda a leitura técnica do mapa.

11 Deployment: da predição à alocação

Recomendar e implantar são passos distintos. A predição indica qual genótipo vence em cada pixel sob o modelo. O *deployment* decide o que será efetivamente alocado no território, considerando restrições que o mapa puro não contém: número de cultivares que o programa consegue lançar e manter, disponibilidade de sementes, escala mínima de produção, risco de extrapolação, estabilidade temporal, aceitação comercial e logística.

Assim, o *deployment* transforma a superfície contínua de recomendação em uma decisão discreta de portfólio. Dois genótipos podem vencer em regiões pequenas e descontínuas, mas não justificar lançamento separado. Um genótipo pode não ser o vencedor absoluto em todos os pixels, mas ser escolhido por estabilidade, menor risco ou maior viabilidade logística. A ambientômica fornece a base espacial da decisão; o *deployment* impõe as restrições do programa.

12 Decisão da rede experimental

O mapa também se lê ao contrário: em vez de recomendar genótipos dado o sítio, escolhem-se sítios para ensaiar. Bons locais de ensaio devem representar a TPE, cobrir zonas distintas, evitar redundância, manter conectividade genética e permitir discriminação entre genótipos.

Uma forma sintética de pensar a escolha de locais é:

$$S_j = \alpha R_j + \beta D_j - \gamma U_j - \eta C_j, \quad (25)$$

em que R_j mede representatividade do local j em relação à TPE, D_j mede capacidade de discriminação genética, U_j mede redundância com locais já existentes e C_j representa custo ou restrição logística. Os pesos dependem da etapa do programa.

A representatividade pode ser avaliada por similaridade ambiental com a TPE. A redundância aparece quando dois locais ocupam a mesma região do espaço ambientômico. A capacidade de discriminação pode ser aproximada por h^2 , acurácia seletiva, variância genética local ou erro-padrão preditivo. A conectividade depende do compartilhamento de genótipos entre ensaios e deve entrar no desenho da rede.

13 Quando usar o quê

O fechamento da disciplina organiza os métodos por etapa do programa, não por preferência. A Tabela 1 resume.

Etapa do programa	Ferramenta principal
Delimitar a TPE	SIG, rasters, polígonos e marcadores ambientômicos
Caracterizar a rede observada	Modelos mistos, AMMI, GGE, FA e correlações entre ambientes
Estimar variâncias e correlações entre ambientes observados	Modelos DIAG, FA, UNS e estruturas de covariância genética
Predizer genótipos em ambientes não testados	Kernel ambientômico, regressão aleatória, fatores latentes + PLS ou <i>ensemble</i>
Comparar ganho real da ambientômica	Baselines sob a mesma validação
Recomendar e alocar cultivares	Mapas de recomendação, mapas de ganho, confiabilidade e <i>deployment</i>
Desenhar a rede futura	Representatividade da TPE, cobertura de zonas, redundância, conectividade e custo

Tabela 1: Métodos da disciplina por etapa do melhoramento.

A mensagem é de complementaridade. Modelos mistos clássicos descrevem a rede observada e estimam variâncias e correlações com base nos ensaios. A ambientômica acrescenta a representação ambiental necessária para extrapolar para sítios não ensaiados. O programa combina os dois: estima bem no observado e projeta com controle no não observado.

14 Cenários aplicados e de decisão no programa de melhoramento

Os três cenários abaixo fecham a aula com decisões de programa, usando os produtos já definidos.

- **TPE heterogênea com crossover.** Quando o ranking dos genótipos muda entre partes da TPE, a recomendação média perde utilidade. O produto esperado é um mapa *which-won-where*, zonas de melhoramento e uma tabela com o genótipo recomendado por zona. A decisão passa de “qual é o melhor genótipo da rede” para “qual genótipo recomendar em cada parte da TPE”.
- **Sítio-alvo sem ensaio.** Quando há um local comercial ou experimental sem fenótipo observado, mas com coordenadas e marcadores ambientais disponíveis, o modelo ambientômico gera ranking predito para esse sítio. A decisão depende da camada de confiabilidade: locais dentro do envelope ambiental do treino sustentam recomendação; locais distantes são extrapolação.
- **Escolha de novos locais de ensaio.** Quando a rede tem locais redundantes e baixa cobertura em parte da TPE, os mapas ajudam a redesenhar a próxima safra. A decisão combina cobertura ambiental, redundância, conectividade genética, capacidade de discriminação e custo. O produto esperado é uma lista priorizada de locais candidatos.

15 Atividade

Questões para discussão e entrega (respostas curtas, argumentadas; favor tente **não** usar I.A.):

1. A ambientômica é tratada como uma “ômica”. Justifique a analogia com a genômica em três pontos: o que faz o papel de marcador, o que faz o papel de genótipo e o que faz o papel de variação entre indivíduos.
2. Por que escolher duas ou três covariáveis “óbvias” tende a capturar apenas parte da interação? Relacione sua resposta à ideia de escala ômica.
3. A parcimônia da regressão aleatória parece conflitar com a exigência de muitos marcadores. Explique como o *ensemble* reconcilia as duas coisas.
4. Distinga $\hat{g}_{ig}$, $\hat{y}_{ig}$ e Δ_i em um mapa de recomendação. Por que produtividade predita do vencedor e ganho esperado são quantidades diferentes?
5. A herdabilidade deixa de ser um número e vira um mapa. Explique por quê, a partir da dependência de v_G em relação ao ambiente, e diga o que isso muda na escolha de locais de ensaio.
6. Uma zona de melhoramento definida por correlação genética difere de um mega-ambiente clássico em dois aspectos: extrapolação e origem da informação. Comente cada um.
7. O que é vazamento em validação CV0? Dê um exemplo envolvendo o uso indevido de fenótipos do ambiente-alvo.
8. Distinga predição de *deployment*. Que restrições o *deployment* impõe que um mapa *which-won-where* sozinho ignora?
9. Diferente do genoma, o ambientoma muda no tempo. Que consequência isso traz para a validade de um mapa de recomendação ao longo dos anos?
10. Em um programa real, em que etapas você usaria modelos mistos clássicos e em que etapas usaria ambientômica? Justifique a complementaridade.

Referências

- Araújo, M. S., Chaves, S. F. S., Dias, L. A. S., et al. (2024). GIS-FA: an approach to integrating thematic maps, factor-analytic, and envirotyping for cultivar targeting. *Theoretical and Applied Genetics*, 137, 80.
- Bahia, M. A. M., Marcatti, G. E., Breseghello, F., Melo, P. G. S., Dias, K. O. G., Xu, Y., et al. (2025). Predictive ability of enviromic modeling in G×E interactions for upland rice site recommendations. *Euphytica*, 221, 11.
- Costa-Neto, G., & Fritsche-Neto, R. (2021). Enviromics: bridging different sources of data, building one framework. *Crop Breeding and Applied Biotechnology*, 21.
- Cruz, D. D., Heinemann, A. B., Marcatti, G. E., & Resende, R. T. (2025). Defining the target population of environments (TPE) for enviromics studies using R-based GIS tools. *Crop Breeding and Applied Biotechnology*, 25(1), e50822519.
- Fernandes Filho, C. C., Andrade, M. H. M. L., Nunes, J. A. R., Jarquin, D. H., & Rios, E. F. (2023). Genomic prediction for complex traits across multiples harvests in alfalfa (*Medicago sativa* L.) is enhanced by enviromics. *The Plant Genome*, 16(2), e20306.
- Gevartosky, R., Carvalho, H. F., Costa-Neto, G., Montesinos-López, O. A., Crossa, J., & Fritsche-Neto, R. (2023). Enviromic-based kernels may optimize resource allocation with multi-trait multi-environment genomic prediction for tropical maize. *BMC Plant Biology*, 23(1), 10.
- Heinemann, A. B., Costa-Neto, G., Fritsche-Neto, R., da Matta, D. H., & Fernandes, I. K. (2022). Enviromic prediction is useful to define the limits of climate adaptation: a case study of common bean in Brazil. *Field Crops Research*, 286, 108628.

- Jarquín, D., Crossa, J., Lacaze, X., Du Cheyron, P., Daucourt, J., Lorgeou, J., Piraux, F., Guerreiro, L., Pérez, P., Calus, M., et al. (2014). A reaction norm model for genomic selection using high-dimensional genomic and environmental data. *Theoretical and Applied Genetics*, 127, 595–607.
- Marcatti, G. E., & Resende, R. T. (2026). The Enviromic Marker. *Crop Breeding and Applied Biotechnology*, 26(1), e54222611.
- Paludeto, J. G. Z., Marcatti, G. E., Estopa, R. A., Klápště, J., Bessalho-Filho, J. C., et al. (2026). Integrating enviromics to predict performance and guide clonal deployment in *Eucalyptus* spp. *Forest Ecology and Management*, 608, 123604.
- Piepho, H. P. (2022). Prediction of and for new environments: what's your model? *Molecular Plant*, 15, 581–582.
- Resende, R. T., Piepho, H. P., Rosa, G. J. M., et al. (2021). Enviromics in breeding: applications and perspectives on envirotypic-assisted selection. *Theoretical and Applied Genetics*, 134, 95–112.
- Resende, R. T., Chenu, K., Rasmussen, S. K., Heinemann, A. B., & Fritsche-Neto, R. (2022). EDITORIAL: Enviromics in plant breeding. *Frontiers in Plant Science*, 13, 935380.
- Resende, R. T., Hickey, L., Amaral, C. H., Peixoto, L. L., Marcatti, G. E., & Xu, Y. (2024). Satellite-enabled enviromics to enhance crop improvement. *Molecular Plant*, 17, 848–866.
- Resende, R. T. (2025). How to enviromically predict breeding genotypes as if they were commercial cultivars? *bioRxiv*, 2025.05.28.656616.
- Resende, R. T., Xavier, A., Silva, P. I. T., Resende, M. P. M., Jarquín, D., & Marcatti, G. E. (2025). GIS-based G×E modeling of maize hybrids through enviromic markers engineering. *New Phytologist*, 245, 102–116.
- Tolhurst, D. J., Gaynor, R. C., Gardunia, B., Hickey, J. M., & Gorjanc, G. (2022). Genomic selection using random regressions on known and latent environmental covariates. *Theoretical and Applied Genetics*, 135, 3393–3415.
- Trevisan, B. A., Junqueira, V. S., Florêncio, B. M., Coelho, A. S. G., Marcatti, G. E., & Resende, R. T. (2025). A framework for building enviromics matrices in mixed models. *Brazilian Journal of Biometrics*, 43(4), e865.

Nota: Material assistido pelo ChatGPT 5.5, Claude Sonnet 4.6 e Overleaf.